



دانشکده مهندسی برق

## افزایش دقیق موقعیت یابی فناوری UWB با استفاده از روش‌های یادگیری عمیق در محیط‌های NLOS/LOS

پایان‌نامه برای دریافت درجه کارشناسی ارشد

در رشته مهندسی برق گرایش کنترل

نام دانشجو

محمدعلی قائمی‌فر

استاد راهنما:

دکتر سعید عباداللهی

۱۴۰۲ بهمن ماه



دانشکده مهندسی برق

# افزایش دقیق موقعیت یابی فناوری UWB با استفاده از روش‌های یادگیری عمیق در محیط‌های NLOS/LOS

پایان‌نامه برای دریافت درجه کارشناسی ارشد

در رشته مهندسی برق گرایش کنترل

نام دانشجو

محمدعلی قائمی‌فر

استاد راهنما:

دکتر سعید عباداللهی

۱۴۰۲ بهمن ماه

بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ

## تأییدیهی هیئت داوران جلسه‌ی دفاع از پایان‌نامه/رساله

نام دانشکده: مهندسی برق

نام دانشجو: محمد علی قائمی فر

عنوان پایان‌نامه یا رساله: افزایش دقیق موقعیت‌یابی فناوری UWB با استفاده از روش‌های یادگیری عمیق در محیط‌های NLOS/LOS

تاریخ دفاع:

رشته: مهندسی برق

گرایش: کنترل

ردیف	سمت	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا مؤسسه	امضا
۱	استاد راهنما	دکتر سعید عبدالهی	استادیار	علم و صنعت ایران	
۲	استاد مدعو داخلی	دکتر سعید شمقدری	دانشیار	علم و صنعت ایران	
۳	استاد مدعو خارجی	دکتر ایمان زمانی	استادیار	شاهد	

## تأییدیه‌ی صحت و اصالت نتایج

### باسم‌ه تعالی

اینجانب محمد علی قائمی فر به شماره دانشجویی ۹۹۶۱۶۱۰۱ دانشجویی رشته مهندسی برق گرایش کنترل مقطع تحصیلی کارشناسی ارشد تأیید می‌نمایم که کلیه‌ی نتایج این پایان‌نامه ارساله حاصل کار اینجانب و بدون هرگونه دخل و تصرف است و موارد نسخه‌برداری شده از آثار دیگران را با ذکر کامل مشخصات منبع ذکر کرده‌ام. در صورت اثبات خلاف مندرجات فوق، به تشخیص دانشگاه مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انصباطی...) با اینجانب رفتار خواهد شد و حق هرگونه اعتراض درخصوص احراق حقوق مکتب و تشخیص و تعیین تخلف و مجازات را از خویش سلب می‌نمایم. در ضمن، مسئولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذی‌صلاح (اعم از اداری و قضایی) به عهده اینجانب خواهد بود و دانشگاه هیچ‌گونه مسئولیتی در این خصوص نخواهد داشت.

نام و نام خانوادگی:

امضا و تاریخ:

## مجوز بهره‌برداری از پایان‌نامه

بهره‌برداری از این پایان‌نامه در چهارچوب مقررات کتابخانه و باتوجه به محدودیتی که توسط استاد راهنمای شرح زیر تعیین می‌شود، بلامانع است:

- بهره‌برداری از این پایان‌نامه/ رساله برای همگان بلامانع است.
- بهره‌برداری از این پایان‌نامه/ رساله با اخذ مجوز از استاد راهنمای، بلامانع است.
- بهره‌برداری از این پایان‌نامه/ رساله تا تاریخ ..... ممنوع است.

نام استاد راهنمای: دکتر سعید عباداللهی

تاریخ:

امضا:

## تشکر و قدردانی:

با افتخار و احترام ابتدا خود را به شدت متعهد به تقدير و امتنان از خدمات فراوان و تلاش‌های بی‌دريغ جناب آقای دکتر سعید عباداللهی، استاد راهنمای بندۀ، قرار می‌دهم. طی سالهای گذشته، ايشان با صبر و تحمل فراوان، نقاط ضعف اينجانب را پوشش داده و به شكل كامل راهنمایي کرده‌اند تا اين پايان‌نامه به نحو احسن به انجام برسد. از ايشان بابت همراهی و تلاش‌های بی‌دريغ تشکر و قدردانی می‌نمایم.

همچنین از دوست عزيزم، جناب آقای حميد عرب سرخى، که در انجام اين پايان‌نامه با دلسوزی و مشارکت فعال خود، به من ياري رسانده‌اند، کمال سپاس و قدردانی را به جا می‌آورم و برای ايشان آرزوی توفيق و موفقیت در زندگی دنيا و آخرت را دارم.

## چکیده

گذران زیاد وقت کاربران در محیط‌های سرپوشیده بهمنظور ردیابی اشیا و یا مکان‌یابی شخص سبب شده که مسائل راهیابی و هدایت درون این محیط‌ها به فرایندی چالش‌برانگیز تبدیل شود. طبق تحقیقات انجام شده انسان حدود ۹۰-۷۰ درصد زمان زندگی و کار خود را در محیط‌های داخلی صرف می‌گذراند؛ بنابراین تهیه سیستم‌هایی برای ارائه خدمات مناسب به کاربران در محیط‌های بسته امری ضروری به نظر می‌رسد. مکان‌یابی کاربر و دستگاه، دارای کاربردهای گسترده در بخش بهداشت، صنعت، مدیریت بحران، مدیریت ساختمان، نظارت و بخش‌های مختلف دیگر است. فناوری‌های مختلفی در سیستم مکان‌یابی داخلی وجود دارد. فناوری‌های موقعیت‌یابی متعددی در حاضر قابل دسترسی هستند، که در این پایان نامه فناوری پهنه‌ای باند عریض (UWB) به دلیل دقت بالا در امر موقعیت‌یابی داخلی مورد بررسی قرار گرفته است. با این حال، محیط‌های داخلی پر از اشیاء و اشخاص است بنابراین سیگنال‌های ارسالی ممکن است توسط موانع منعکس شوند. در مقایسه با سیگنال خط دید مستقیم (LOS)، تاخیر مسیر ارسال سیگنال موجود در سیگنال خط دید غیرمستقیم (NLOS) باعث ایجاد خطاهای مثبت فاصله و در نتیجه خطاهای موقعیت‌یابی می‌شود.

بهمنظور اینکه بتوان اثر شرایط خط دید غیرمستقیم را برای امر موقعیت‌یابی کاهش داد، در این پایان‌نامه سعی شده در ابتدا با ارائه شبکه‌های یادگیری عمیق و با استفاده از داده‌های پاسخ ضربه کانال به عنوان ورودی بدون دانستن هیچ پیش‌دانشی از محیط به کمک این شبکه‌ها بتوان تفکیک بادقت بالا برای شرایط LOS و NLOS داشته باشیم. همچنین نتیجه این طبقه‌بندی با دو مرجع دیگر که از مجموعه‌داده یکسان استفاده نموده‌اند مقایسه می‌شود. پس از شناسایی شرایط NLOS با ارائه شبکه‌های رگرسیونی متفاوت سعی بر تخمین موقعیت تحت دو حالت ۱) در نظر گرفتن شرایط NLOS و ۲) بدون در نظر گرفتن شرایط NLOS شده است. نتایج شبیه‌سازی در بخش اول یعنی دسته‌بندی سیگنال‌های NLOS/LOS نشان می‌دهد که شبکه‌های عصبی کانولوشنالی (CNN) و تلقینی (Inception) پیشنهاد شده نسبت به روش‌های شبکه عصبی مرسوم (شبکه‌های عصبی پیشخور با تعداد لایه‌های مخفی و نورون‌های متفاوت) دقت بالاتری را در امر تشخیص این دو محیط از یکدیگر دارند و همچنین در بخش موقعیت‌یابی با استفاده از الگوریتم‌های رگرسیونی، در هر دو حالت، شبکه ماشین بردار پشتیبان (SVM) خطای کمتری در تخمین موقعیت تگ از خود به نمایش گذاشته است.

واژگان کلیدی: موقعیت‌یابی در محیط‌های داخلی، فناوری UWB، طبقه‌بندی NLOS، شبکه عصبی کانولوشنالی، شبکه عصبی تلقینی، الگوریتم‌های رگرسیون، تخمین موقعیت

## فهرست مطالب

۱	فصل ۱: مقدمه
۱	۱-۱- مقدمه
۳	۲-۱- تعریف مساله
۴	۳-۱- اهداف و دستاوردهای پژوهش
۴	۴-۱- ساختار پایان نامه
۶	فصل ۲: مروری بر منابع
۶	۲-۱- مقدمه
۷	۲-۲- تعاریف و عوامل عملکرد
۸	۲-۳-۱- تخمین فاصله
۸	۲-۳-۲- شدت (قدرت) سیگنال دریافتی
۹	۲-۳-۳- زاویه ورود (AOA)
۱۰	۲-۳-۴- زمان رسیدن (ToA)
۱۱	۲-۳-۵- اختلاف زمان رسیدن (TDoA)
۱۲	۲-۳-۶- فاز دریافتی (PoA)
۱۳	۲-۳-۷- اثر انگشت یا انگشت نگاری
۱۴	۲-۴-۱- الگوریتم های رایج موقعیت یابی
۱۴	۲-۴-۲- روش سه و جهی سازی ( مثلث بندی )
۱۵	۲-۴-۳- روش چهار و جهی سازی
۱۶	۲-۴-۴- معیارهای ارزیابی عملکرد تخمین موقعیت
۱۶	۲-۴-۵-۱- معیار میانگین مربعات خطأ (MSE)
۱۷	۲-۴-۵-۲- معیار ریشه میانگین مربعات خطأ (RMSE)

۱۷	۳-۵-۲- معیار میانگین قدرمطلق خطای (MAE)
۱۸	۲-۶- فناوری‌های موقعیت‌یابی مورداستفاده در محیط داخلی
۱۸	۱-۶-۲- سیستم‌های مبتنی بر RSS
۲۰	۲-۶-۲- سیستم‌های مبتنی بر زمان
۲۲	۳-۶-۲- سایر فناوری‌ها
۲۴	۴-۶-۲- فناوری‌های ترکیبی
۲۶	۷-۲- مزایای UWB
۲۶	۸-۲- کاربردهای UWB
۲۸	۹-۲- جمع بندی
۲۹	فصل ۳: راهکارهای پیشنهادی بهبود دقت موقعیت‌یابی
۲۹	۱-۳- مقدمه ایی بر یادگیری عمیق
۳۲	۲-۳- توابع فعالساز
۳۲	۱-۲-۳- سیگموید
۳۲	۲-۲-۳- تانژانت هایپربولیک
۳۳	۲-۲-۳- واحد خطی اصلاح شده ReLU
۳۳	۳-۳- روش‌های یادگیری عمیق
۳۴	۱-۳-۳- الگوریتم‌های دسته بندی
۳۹	۲-۳-۳- رگرسیون
۴۱	۴-۳- چالش‌های فناوری UWB
۴۲	۱-۴-۳- خط دید غیرمستقیم
۴۳	۲-۴-۳- پدیده چند راهه
۴۳	۳-۴-۳- تداخل
۴۳	۴-۴-۳- امنیت

۴۴	هزینه ..... ۳-۴-۵
۴۴	سایر چالشها ..... ۳-۴-۶
۴۵	فصل ۴: نتایج و تفسیر آنها
۴۵	۱-۱- تجزیه و تحلیل پایگاهداده ..... ۸-۱-۱
۴۵	۱-۱-۱- سخت افزار مورداستفاده برای جمع آوری داده ..... ۸-۱-۱-۱
۴۷	۱-۱-۲- سیستم اندازه گیری ..... ۸-۱-۲
۴۷	۱-۱-۳- توضیحات مجموعه داده ..... ۸-۱-۳
۴۸	۱-۱-۴- وضعیت نمونه برداری ..... ۸-۱-۴
۴۸	۱-۲- فرمت دادهها ..... ۸-۲
۴۹	۱-۳- متغیرهای مورداستفاده از مجموعه داده ..... ۸-۳
۵۰	۲- پاسخ ضربه کانال (CIR) ..... ۹-۲
۵۱	۳- پیش پردازش دادههای ورودی ..... ۹-۳
۵۲	۳-۱- پاکسازی دادهها ..... ۹-۳-۱
۵۲	۳-۲- تبدیل روی دادههای CIR ..... ۹-۳-۲
۵۳	۳-۳- استانداردسازی دادههای CIR ..... ۹-۳-۳
۵۵	۴- سخت افزار شبیه سازی ..... ۹-۴
۵۵	۴-۱- تفکیک شرایط LOS و NLOS از یکدیگر ..... ۹-۴-۱
۵۶	۴-۲- ساختار شبکه عصبی کانولوشنال ..... ۹-۴-۲
۶۱	۴-۳- ساختار شبکه عصبی پیشخور ..... ۹-۴-۳
۶۷	۴-۴- شبکه Inception پیشنهادی ..... ۹-۴-۴
۷۱	۴-۵- خلاصه نتایج تفکیک سیگنال NLOS/LOS ..... ۹-۵-۶
۷۲	۴-۶- موقعیت یابی با استفاده از الگوریتم های رگرسیون ..... ۹-۶-۷
۷۳	۴-۷- ساختار الگوریتم های رگرسیون پیشنهادی ..... ۹-۷-۸

۷۳	۱-۸-۴	- تخمین موقعیت بدون درنظر گرفتن شرایط NLOS
۷۵	۲-۸-۴	- تخمین موقعیت به همراه درنظر گرفتن شرایط NLOS
۷۷	فصل ۵: جمع بندی و پیشنهادها	
۷۷	۱-۵	- جمع بندی
۷۸	۲-۵	- پیشنهادها
۷۹	پیوست الف	
۸۰	پیوست ب	
۸۱	مراجع	

## فهرست اشکال

..... شکل (۱-۲) محلی‌سازی بر مبنای RSSI	۹
..... شکل (۲-۲) موقعیت‌یابی بر مبنای AoA	۱۰
..... شکل (۳-۲) محدوده دقت فناوری‌های موقعیت‌یابی بر حسب استفاده در داخل یا خارج ساختمان موقعیت‌یابی بر مبنای روش ToA	۱۱
..... شکل (۴-۲) موقعیت‌یابی بر مبنای روش TDoA به کمک چهار گره مرجع	۱۲
..... شکل (۵-۲) محلی‌سازی بر مبنای PoA	۱۲
..... شکل (۶-۲) شماتیک موقعیت‌یابی روش سه‌وجهی (a) سناریو ایده‌آل سه‌وجهی (b) سناریو عملی بدون تقاطع (c) سناریو عملی بدون تقاطع واضح (d) سناریو عملی با چندین منطقه تقاطع	۱۵
..... شکل (۷-۲) تأثیر دو مژول متفاوت IMU را از نظر خطای رانش در کاربرد موقعیت‌یابی (نمودار قرمزنگ مژول گران‌قیمت‌تری نسبت به آبی‌رنگ است)	۲۳
..... شکل (۸-۲) نحوه قرارگرفتن بخش‌های متفاوت فناوری RFID بر روی نمونه عملی لیفتراک	۲۵
..... شکل (۹-۲) ساختار ترکیب روش IMU و UWB	۳۸
..... شکل (۱-۳) دسته بندی شبکه‌های هوش مصنوعی	۳۰
..... شکل (۲-۳) نمونه‌ای از ساختار شبکه عصبی مصنوعی	۳۱
..... شکل (۳-۳) توابع فعال‌ساز خطی، سیگموید و تانژانت هایپربولیک	۳۳
..... شکل (۴-۳) دسته بندی دودویی و چند کلاسه	۳۵
..... شکل (۵-۳) رگرسیون منطقی برای طبقه‌بندی دودویی	۳۶
..... شکل (۶-۳) ساختار یک بعدی CNN	۵۶
..... شکل (۷-۳) شبکه تلقینی، شکل سمت چپ تلقیتی از نوع naive و شکل سمت راست از نوع کاهش ابعاد است	۵۷
..... شکل (۸-۳) مثالی از تفاوت رگرسیون و طبقه‌بندی	۵۹
..... شکل (۹-۳) ماشین بردار پشتیبان	۶۳
..... شکل (۱۰-۳) مثالی از سناریو LoS(سمت چپ) و NLoS(سمت راست)	۶۸

..... ۴۵	شکل (۱-۴) نسخه تجاری مازول DWM1000
..... ۴۷	..... شکل (۲-۴) سیستم جمع‌آوری داده [۸۳]
..... ۴۸	..... شکل (۳-۴) مختصات انکرها و مسیر حرکت تگ در دو بعد [۸۴]
..... ۵۰	..... شکل (۴-۴) برشی از داده‌های پاسخ ضربه کانال
..... ۵۱	..... شکل (۵-۴) پاسخ ضربه کانال برای دو سیگنال LoS و NLoS
..... ۵۴	..... شکل (۶-۴)تابع هزینه و همگرايی پارامترهای يادگيری به ازای ورودی های بدون نرماليزه شده
..... ۵۴	..... شکل (۷-۴)تابع هزینه و همگرايی پارامترهای يادگيری به ازای ورودی های نرماليزه شده
..... ۵۸	..... شکل (۸-۴) ساختار شبکه عصبی کانوولوشنال پیشنهادی
..... ۵۹	..... شکل (۹-۴) دقت و تابع ضرر مدل برای شبکه CNN با $\text{DropOut} = 0.5$
..... ۶۰	..... شکل (۱۰-۴) ماتریس سردرگمی برای شبکه عصبی CNN با $\text{DropOut} = 0.5$
..... ۶۰	..... شکل (۱۱-۴) دقت و تابع ضرر مدل برای شبکه CNN با $\text{DropOut} = 0.8$
..... ۶۱	..... شکل (۱۲-۴) ماتریس سردرگمی برای شبکه عصبی CNN با $\text{DropOut} = 0.8$
..... ۶۱	..... شکل (۱۳-۴) نمونه ساختار شبکه عصبی پیشخور با دو لایه مخفی
..... ۶۳	..... شکل (۱۴-۴) مرحله انتشار روبه‌عقب [۹۱]
..... ۶۴	..... شکل (۱۵-۴) شبکه عصبی پیشخور با ورودی پاسخ ضربه
..... ۶۵	..... شکل (۱۶-۴) نمودار تابع هزینه برای نرخ يادگيری های متفاوت
..... ۶۶	..... شکل (۱۷-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۱
..... ۶۶	..... شکل (۱۸-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۲
..... ۶۷	..... شکل (۱۹-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۳
..... ۶۷	..... شکل (۲۰-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۴
..... ۶۹	..... شکل (۲۱-۴) دقت و تابع ضرر مدل برای شبکه تلقینی نوع ۱
..... ۷۰	..... شکل (۲۲-۴) دقت و تابع ضرر مدل برای شبکه تلقینی نوع ۲
..... ۷۰	..... شکل (۲۳-۴) دقت مدل برای شبکه تلقینی نوع ۳

- شکل (۲۴-۴) ساختار شبکه رگرسیونی تخمین موقعیت پیشنهادی ..... ۷۲
- شکل (۲۵-۴) دقت و تابع ضرر مدل رگرسیونی چند متغیره بدون در نظر گرفتن شرایط NLOS ..... ۷۳
- شکل (۲۶-۴) میانگین خطای مطلق به ازای نرخ یادگیری‌های مختلف ..... ۷۴
- شکل (۲۷-۴) دقت و تابع ضرر مدل رگرسیونی کانوولوشنی بدون در نظر گرفتن شرایط NLOS ..... ۷۴

## فهرست جدول

جدول (۱-۲) خلاصه ایی از رویکردهای مورد استفاده در سیستم های موقعیت یاب ..... ۱۳
جدول (۲-۲) خلاصه ایی از مهمترین فناوری های مورد استفاده در محیط های سرپوشیده ..... ۲۲
جدول (۱-۳) مزایا و معایب استفاده از رگرسیون منطقی ..... ۳۶
جدول (۱-۴) پارامترهای نسخه تجاری ماژول DWM1000 ..... ۴۶
جدول (۲-۴) پارامترهای مهم نسخه تجاری ماژول DWM1000 ..... ۴۹
جدول (۳-۴) جزئیات ساختار شبکه CNN پیشنهادی ..... ۵۸
جدول (۴-۴) ساختار شبکه عصبی پیشخور ..... ۶۵
جدول (۵-۴) جزئیات پارامترهای شبکه تلقینی ..... ۶۹
جدول (۶-۴) خلاصه نتایج شبکه های عصبی برای طبقه بندی شرایط NLOS/LOS ..... ۷۱
جدول (۷-۴) میانگین خطای مطلق موقعیت یابی بدون درنظر گرفتن شرایط NLOS ..... ۷۵
جدول (۸-۴) میانگین خطای مطلق موقعیت یابی به همراه درنظر گرفتن شرایط NLOS ..... ۷۶

## علائم اختصاری

<b>AoA</b>	Angle of Arrival
<b>BLE</b>	Bluetooth low energy
<b>BS</b>	Base station
<b>CNN</b>	Convolutional Neural Networks
<b>dBm</b>	decibel-milliwatts
<b>DL</b>	Deep Learning
<b>FPE</b>	FingerPriting Estimation
<b>GPS</b>	Global Positioning System
<b>IPS</b>	Indoor Positioning System
<b>KF</b>	Kalman Filter
<b>IMU</b>	Inertial measurement unit
<b>LLSE</b>	Linearized Least Square Estimation
<b>LoS</b>	Line of Sight
<b>ML</b>	Machine Learning
<b>NLoS</b>	Non-line of Sight
<b>PoA</b>	Phase-of-Arrival
<b>RN</b>	Reference Node
<b>RFID</b>	Radio frequency identification
<b>RSS</b>	Received Signal Strength
<b>RSSI</b>	RSS Indication
<b>RTLS</b>	Real Time Location Services
<b>Rx</b>	Receiver
<b>SVM</b>	Support Vector Machine
<b>TDoA</b>	Time Difference of Arrival
<b>ToA</b>	Time of Arrival
<b>Tx</b>	Transmitters
<b>UHF</b>	Ultra-high Frequency
<b>VLC</b>	Visual Light Communication
<b>WLAN</b>	Wireless Local Area Network
<b>WLS</b>	Weighted Least Squares

## فصل ۱: مقدمه

### ۱-۱-۱- مقدمه

گذران زیاد وقت کاربران در محیط‌های سرپوشیده به منظور ردیابی اشیا و یا مکان‌یابی شخص سبب شده که مسائل راهیابی و هدایت درون این محیط‌ها به فرایندی چالش‌برانگیز تبدیل شود. طبق تحقیقات انجام شده انسان حدود ۹۰-۷۰ درصد زمان زندگی و کار خود را در محیط‌های داخلی صرف می‌گذراند؛ بنابراین تهیه سیستم‌های برای ارائه خدمات مناسب به کاربران در محیط‌های بسته امری ضروری به نظر می‌رسد. اولین فناوری ارائه شده و احتمالاً مشهورترین و بیشترین استفاده برای اهداف محلی‌سازی در فضای باز است، این سامانه موقعیت‌یاب جهانی یا با اختصار GPS نامیده می‌شود. توسعه این فناوری در سال ۱۹۷۳ آغاز شده و در دسامبر سال ۱۹۹۳ به قابلیت عملیات اولیه ICO<sup>۱</sup> دست یافت.<sup>[۱]</sup> در سال ۱۹۹۴، سامانه موقعیت‌یاب جهانی به قابلیت عملیات FCO<sup>۲</sup> دست یافت. معرفی سیستم موقعیت‌یابی جهانی منجر به ایجاد انبوهی از برنامه‌های کاربردی جدید شده است. توانایی به دست آوردن مکان دقیق یک فرد یا شی تا چندمتری نه تنها در نحوه پیمایش ما تأثیر داشته؛ بلکه منجر به تعدادی خدمات مبتنی بر مکان و برنامه‌های مصرف‌کننده مانند اطلاعات آب و هوای محلی، ردیابی، تناسب‌اندام و غیره شده است که این کاربردها به خوبی در شرایط بیرونی، جایی که نمای واضحی از آسمان سیستم GPS را قادر می‌سازد تا اطلاعات دقیق را به آنها منتقل سازد، کار می‌کند.<sup>[۲]</sup> سیستم موقعیت‌یابی جهانی فناوری کارآمد و متناسب با فضاهای بیرونی است و برای محیط‌های سرپوشیده و داخلی به دلیل اینکه سیگنال‌های ماهواره‌ای توانایی عبور از موانع و دیوارها را ندارند، نامناسب است. با توجه به این موضوع که سیستم GPS چندان در محیط‌های سرپوشیده کاربردی نیست سیستم‌های موقعیت‌یابی داخلی ایجاد شده اند.<sup>[۳]</sup>.

موقعیت‌یابی به معنای فرآیند تعیین موقعیت افراد، تجهیزات و سایر اشیاء است که در سال‌های اخیر حوزه تحقیقاتی بسیار فعال بوده است. بیشتر تحقیقات در زمینه موقعیت‌یابی بر استفاده از فناوری‌های موجود برای مقابله با چالش موقعیت‌یابی متمرکز شده است. بسته به محیطی که موقعیت‌یابی در آن انجام می‌شود، موقعیت‌یابی را می‌توان به دو گروه موقعیت‌یابی در فضای باز و مکان‌یابی داخلی طبقه بندی کرد. در حالی که موقعیت‌یابی

<sup>1</sup> Initial Capability Operation

<sup>2</sup> Full Capability Operation

در فضای باز و خارج از ساختمان‌ها و موقعیت‌یابی داخلی در داخل ساختمان انجام می‌شود. (مثلًاً خانه‌ها، بیمارستان‌ها و مراکز خرید). با توجه به نوع محیط، فناوری‌های موقعیت‌یابی متفاوتی وجود دارد.

سیستم‌های موقعیت‌یابی به بخشی جدایی ناپذیر از زندگی ما تبدیل شده‌اند. یکی از رایج‌ترین سیستم‌های موقعیت‌یابی، سیستم موقعیت‌یابی محلی است. سیستم موقعیت‌یابی داخلی (IPS) نوعی از سیستم‌های موقعیت‌یابی محلی است که می‌تواند تخمین موقعیت را برای مکان‌یابی افراد یا اشیاء در داخل ساختمان ارائه دهد. سیستم جهانی ناوبری ماهواره‌ای نقش مهمی در ارائه اطلاعات مکان دقیق ایفا کرده است [۴] اما به دلیل ناتوانی در ارائه موقعیت دقیق در محیط‌های داخلی، راه حل ایده‌آلی برای موقعیت‌یابی داخلی نیست [۵].

در طول چند دهه گذشته، مطالعات گسترده‌ای در مورد محلی‌سازی دستگاه‌های داخلی انجام شده است و ما شاهد افزایش استفاده از IPS هستیم. امروزه سیستم‌های موقعیت‌یابی داخلی دارای کاربردهای گسترده‌ای در اینترنت اشیا [۶]، ساختمان‌های هوشمند [۷]، تلفن‌های هوشمند [۸]، ناوبری وسایل نقلیه زمینی بدون سرنشیان (UGV) [۹] و غیره هستند.

در عصر جدید با پیشرفت علم و فناوری، لزوم پرداخت به مباحث هوشمندسازی بیشتر می‌شود و تلاش شده که تمامی کارهایی که برای انسان زمان بر و خسته‌کننده شده است، توسط وسایل و الگوریتم‌های هوشمند انجام پذیرد. بر خلاف فضای بیرونی، محیط‌های داخلی بسیار پیچیده با اجسام ثابت و متحرک هستند که این موضوع به طور قابل توجهی انتشار سیگنال‌های رادیویی خط دید<sup>۳</sup> (LoS) و غیرخط دید<sup>۴</sup> (NLoS) را تغییر می‌دهند و باعث تضعیف غیرقابل‌پیش‌بینی، پراکندگی و ایجاد نقاط کور می‌شوند که به طور قابل توجهی دقت موقعیت‌یابی داخلی را کاهش می‌دهد.

فناوری‌های مختلفی در سیستم مکان‌یابی داخلی وجود دارد. این راه‌حل‌ها بر اساس تکنولوژی‌های بی‌سیم مانند بلوتوث، زیگبی، سیگنال‌های برج‌های سلولی، WIFI، RFID، UWB و غیره ارائه می‌شود که هر کدام از این فناوری‌ها تحت الگوریتم و تکنیک‌های مختلف قابل پیاده‌سازی است که در اینجا به طور خاص به موقعیت‌یابی در محیط‌های سرپوشیده به کمک فناوری UWB خواهیم پرداخت. فناوری UWB برای موقعیت‌هایی که دقت بالا اهمیت دارد بسیار مناسب است. دقت موقعیت‌یابی در این فناوری در حد سانتی‌متر خواهد رسید که با استفاده از روش‌هایی مانند فیلتر کالمون، ترکیب دو فناوری، کالیبراسیون آنتن، الگوریتم تخمین وزنی مرکز، الگوریتم‌های هوش مصنوعی و غیره می‌توان عملکرد و دقت این مدل سیستم‌ها را بهبود بخشد.

<sup>3</sup> Line Of Sight

<sup>4</sup> Non Line Of Sight

باین حال، استقرار عملی سیستم‌های UWB هنوز با تعدادی چالش فنی، از جمله دریافت سیگнал، تداخل چند کاربر [۱۰]، اثرات چندمسیره [۱۱] و انتشار NLOS مواجه است که چالش NLOS اخیراً برای سیستم‌های محلی‌سازی با وضوح بالا حیاتی است، زیرا که انتشار NLOS منجر به تخمین‌های دامنه با بایاس مثبت می‌شود که به نوبه خود عملکرد و دقت محلی‌سازی را کاهش می‌دهد.

در سال‌های اخیر، الگوریتم‌های هوش مصنوعی، یادگیری ماشین و یادگیری عمیق موفقیت خوبی در محلی‌سازی محیط‌های سرپوشیده پیدا کرده‌اند [۱۲]. مزیت اصلی رویکردهای یادگیری ماشین و هوش مصنوعی توانایی آنها در تصمیم‌گیری مؤثر با استفاده از داده‌های مشاهده شده بدون فرمول‌بندی دقیق ریاضی است. در محیط‌های داخلی به دلیل وجود اشیا مختلف سیگنال‌های UWB ممکن است توسط آنها مسدود شود و سیگنال منعکس شده دریافت شود. بدون تشخیص سیگنال‌های NLoS دقت موقعیت‌یابی کاهش خواهد یافت [۱۳].

## ۱-۲- تعریف مساله

در فناوری UWB مبتنی بر IPS شناسایی NLoS برای به‌دست‌آوردن اطلاعات فاصله تمیز بسیار اهمیت دارد. تشخیص NLoS مقدمه اصلاح دقت موقعیت‌یابی است و رویکردهای بسیاری در مقالات گذشته برای مقابله با این مشکل ارائه شده است که این روش‌ها را می‌توان به سه نوع مختلف زیر دسته‌بندی نمود.

۱. روش اول بر اساس تفاوت پارامترهای آماری اطلاعات فاصله تخمینی تحت شرایط LoS/NLoS ساخته شده است [۱۴].

۲. مورد دوم بر اساس مدل ازدستدادن مسیر انتشار سیگنال یا مطالعه پاسخ ضربه کانال (CIR) است. ایده اصلی پشت این راه حل این است که انرژی مسیر اول به طور محسوسی بیشتر از انرژی مسیرهای تأخیری است.

۳. در نهایت مورد سوم استفاده از روش‌های یادگیری ماشین بدون پارامتر برای طبقه‌بندی LoS/NLoS استفاده می‌شوند. از نمونه روش‌های یادگیری ماشین می‌توان به عنوان مثال به ماشین بردار پشتیبانی (SVM) ادراک چندلایه (MLP) و درخت تصمیم اشاره نمود [۱۵].

در فناوری UWB مبتنی بر IPS اطلاعات فاصله از کانال‌های متفاوت برای محاسبه نتایج مکان به دست می‌آید. از آنجایی که روش زمان رسیدن (ToA) دارای مزیت دقت بالا است، در فناوری UWB مورد استفاده قرار می‌گیرد. هنگام استفاده از روش TOA، اطلاعات فاصله از طریق اندازه‌گیری‌های CIR استخراج می‌شود [۱۶]. طبق اندازه‌گیری‌های انجام شده در مقالات می‌توان نتیجه گرفت که CIR برای دو محیط LOS و NLOS متفاوت است و می‌توان مشاهده کرده که CIR در محیط LOS در قیاس با محیط NLOS بزرگ‌تر می‌باشد و منحنی‌های این

دو محیط نیز با یکدیگر متفاوت هستند. روش‌های یادگیری عمیق (DL) مانند LSTM و یا CNN می‌توانند برای مقابله با طبقه‌بندی شرایط NLOS/LOS به عنوان ورودی استفاده شوند.

### ۱-۳-۱- اهداف و دستاوردهای پژوهش

در این پایان‌نامه به بررسی الگوریتم‌های یادگیری عمیق به منظور افزایش بهبود عملکرد و دقت سیستم UWB در محیط‌های داخلی با درنظرگرفتن شرایط LoS و NLoS پرداخته می‌شود. همچنین سعی می‌شود که الگوریتم‌های ارائه شده را از لحاظ دقت با سایر الگوریتم‌ها مقایسه شود و در گام بعد از داده‌ها در محیط و مکان‌های مختلف برای استفاده در الگوریتم‌های یادگیری عمیق استفاده خواهد شد. در نهایت ارائه الگوریتمی با دقت مناسب در تشخیص سیگنال‌های LoS و NLoS در دستور کار این پایان‌نامه قرار گرفته است.

در نهایت پس از شناسایی و تفکیک شرایط LOS/NLOS با استفاده از الگوریتم‌های رگرسیونی متفاوت تخمین موقعیت تگ در حال حرکت مورد بررسی قرار می‌گیرد. نتایج شبیه‌سازی نشان می‌دهد خطای تخمین موقعیت کمتر از تحقیقات انجام شده در این حوزه می‌باشد.

۴-۱ ساختار پایان نامه

این پایان‌نامه در ۵ فصل مطابق زیر مطرح شده است:

در فصل اول، مقدمه‌ای از ضرورت فناوری موقعیت‌یابی داخلی مطرح گردید و پس از آن کاربردهای این فناوری‌ها مورد استفاده قرار گرفت. سپس به بررسی چالش‌های موقعیت‌یابی داخلی پرداخته و روش‌هایی برای برطرف‌سازی این چالش‌ها ذکر شده است.

در فصل دوم، به بررسی کلی روش‌های رایج در امر موقعیت‌یابی و معیارهای مقایسه عملکرد روش‌های تخمین موقعیت می‌پردازیم. همچنین انواع فناوری‌های موقعیت‌یابی داخلی معرفی شده و به اختصاص از انواع مزایای فناوری UWB صحبت به عمل آمده است و در نهایت کاربردهای عملی فناوری UWB در محیط‌های واقعی مطرح می‌شود.

در فصل سوم، مقدمه‌ای بر الگوریتم‌های یادگیری عمیق از جمله توابع فعال‌ساز مورداستفاده در این پژوهش آورده شده است. بعد از آن دو روش یادگیری عمیق یعنی روش دسته‌بندی و رگرسیون که در نتایج مورداستفاده قرار گرفته شده را مطرح می‌نماییم. همچنین در این فصل مجموعه‌داده مورداستفاده به‌منظور تفکیک شرایط NLOS/LOS و تخمین موقعیت به طور کامل مورد تجزیه و تحلیل، قرار می‌گیرد.

در فصل چهارم، در ابتدا به پیش‌پردازش اولیه بر روی داده‌های ورودی پرداخته شده و پس از آن به تفکیک شرایط NLOS/LOS و مقایسه نتایج این دسته‌بندی با یکدیگر و سایر مراجع مرتبط با این حوزه و همچنین تعدادی الگوریتم رگرسیون مطرح شده برای تخمین موقعیت تگ استفاده شده است. نتایج شبیه‌سازی تأییدی بر دقیق بالاتر و خطای کمتر نسبت به سایر تحقیقات می‌باشد.

در فصل پنجم، نیز به طور کلی به جمع‌بندی پایان‌نامه و همچنین سایر پیشنهادتی در آینده می‌توان به آن پرداخت را مطرح می‌نماییم.

## فصل ۲: مروجی بر منابع

### ۱-۱-۴- مقدمه

علی‌رغم دردسترس‌بودن بسیار از فناوری‌های موقعیت‌یابی داخلی مانند ارتباطات مبتنی بر نور، بینایی کامپیوتر، رادیو فوق باند، بلوتوث و RFID سیستم‌های موقعیت‌یابی داخلی به کارگیری گسترده‌ای نداشته‌اند. شاید بتوان گفت که دلیل این موضوع عدم وجود یک فناوری که راه حل تمامی چالش‌های محیط‌های سرپوشیده را داشته باشد و به این معنی است که در بعضی از کاربردها تنها با یک فناوری خاص نمی‌توان به هدف دلخواه دست‌یافت. با افزایش دردسترس‌بودن سیستم‌های موقعیت‌یابی داخلی انتظار می‌رود که خدمات موقعیت‌یابی داخلی در زمینه‌هایی مانند ناوبری<sup>۵</sup> و ردیابی، بازاریابی، بازیابی اطلاعات، سرگرمی و امنیت در دسترس قرار بگیرد [۱۷].

اصطلاح سیگنال UWB امروزه رایج‌تر شده است (بهویژه در حوزه‌های رادار، ارتباطات، تداخل الکترومغناطیسی و انرژی هدایت‌شده با توان بالا)، حتی اگر خود این فناوری سال‌ها پیش کشف شده باشد. تحقیقات روی فناوری UWB درست همراه با کشف ارتباطات رادیویی آغاز شد. گفته می‌شود که تاریخ تولد UWB حدود سال ۱۸۸۵ بود، زمانی که گوگلیلمو مارکونی از فرستنده‌های شکاف جرقه برای ارتباطات رادیویی (کد مورس) بر فراز اقیانوس اطلس استفاده کرد [۱۸]. البته استفاده از UWB در آن زمان با روشی که امروزه در بازار تجاری استفاده می‌شود کاملاً متفاوت بوده است.

به دلیل کاربردهای نظامی، استفاده از UWB تا سال ۱۹۹۰ در ایالات متحده آمریکا ممنوع بود. پس از سال ۱۹۹۰ اولین محصولات تجاری و دارای مجوز عرضه شدند که منجر به عملیات بدون مجوز عمومی (بین ۳.۱ تا ۱۰.۶ گیگاهرتز [۱۹]) در سال ۲۰۰۲ از کمیسیون ارتباطات فدرال<sup>۶</sup> (FCC) شد. با وجود دسترسی عمومی، این فن آوری در این سال‌ها چندان محبوب نشد که بیشتر به دلیل هزینه پیاده‌سازی بالا و عملکرد اولیه پایین بود. نزدیک به دو دهه طول کشید تا بازار به اندازه کافی بالغ شود تا تراشه‌های UWB در دسترس عموم قرار بگیرند. امروزه،

<sup>۵</sup> Navigation

<sup>۶</sup> Federal Communication Commission

تراشهای UWB به اندازه کافی ارزان و کوچک هستند که آنها را درون دستگاه‌های دیگر مانند گوشی‌های هوشمند قرار دهند و به طور گسترده مورداستفاده قرار گیرند.

## ۲-۲-تعاریف و عوامل عملکرد

برای مقایسه سیستم‌های موقعیت‌یابی داخلی از نظر بهبود عملکرد می‌توان از معیارهای زیر استفاده نمود:

دقت جنبه‌ایی مهم در هنگام انتخاب نوع سیستم موقعیت‌یابی داخلی است و برای اطمینان از مفیدبودن داده‌های دریافتی، بسیار مهم است. دقت را می‌توان میزان فاصله موقعیت اندازه‌گیری شده هدف با نقطه واقعی تعریف نمود و برای اینکه داده‌های سیستم در نظر گرفته شده را معتبر دانست می‌باشد عدم دقت از ۲-۳ متر کمتر باشد و یا به بیانی دیگر خطای خود کمترین مقدار پایین نگه داشته شود.

تأخر هنگام درنظرگرفتن هدفی متحرک، این معیار دارای اهمیت است. تأخیر را می‌توان به صورت زمانی که سیستم داده‌ها را به دست می‌آورد تا زمانی که پردازش آن به پایان می‌رسد، تعریف نمود؛ بنابراین تأخیر زیاد منجر به کاهش زیاد دقت در عمل موقعیت‌یابی می‌شود.

هزینه هر جسم که مورد ردیابی قرار می‌گیرد می‌باشد تا حداقل مقدار ممکن پایین نگه داشته شود تا امکان ردیابی چندین شی فراهم شود. به منظور نشان دادن اهمیت این معیار، فرض کنید در مدیریت انبارداری هوشمند که هزاران کالا در انبار وجود دارند موقعیت تک‌تک اشیا اهمیت دارد در صورتی که هزینه ردیابی کالایی زیاد شود به طبع در مقیاس بزرگ نیز هزینه کل مدیریت انبارداری بسیار بالاتر خواهد شد.

استحکام سیستم به میزان قابل اعتماد بودن دقت در محیط‌های سخت دلالت می‌کند. میزان خطای خطا و اختشاشات فاکتورهای تأثیرگذاری در این قابل اعتماد بودن به شمار می‌روند. پس هر چه سیستم موقعیت‌یاب استحکام بالاتری داشته باشد، داده‌های اندازه‌گیری شده مقبولیت بیشتری را برای کاربر دارد.

مقیاس‌پذیری تعداد اهدافی است که سیستم احتمالاً می‌تواند ردیابی کند و اینکه چه میزان آسان است که سیستم را بر اساس نیازهای مختلف از نظر اندازه مقیاس‌بندی کنند. این معیار باید در اکثر برنامه‌های موقعیت‌یابی داخلی مناسب باشد چرا که به طور معمول منطقه‌ای وسیع که باید تحت پوشش قرار گیرد و اهداف زیادی برای ردیابی وجود دارد. مقیاس‌پذیری عاملی مهم برای این پژوهه خواهد بود، زیرا هدف ایجاد سیستمی است که می‌تواند در مکان‌های عمومی نصب شود و قابلیت ردیابی چندین هدف را داشته باشد.

پیچیدگی به موضوع اینکه نصب سیستمی موقعیت‌یاب در محیط جدید و یا کالیبره آن در صورت نیاز چه میزان سخت و زمان بر است، اشاره دارد و همچنین عاملی بسیار مهم در راستای تجاری‌شدن سیستم است.

صرف انرژی نیز جزو معیارهایی است که در انتخاب سیستم موقعیت‌یابی داخلی لحاظ می‌شود. بهمنظور اینکه سیستم موقعیت‌یاب، قابل حمل و منعطف باشد مصرف برق آن را به میزانی می‌بایست کم نگه داشت که بتوان از بااتری تغذیه کرد و نیز به طور مداوم سیستم موقعیت‌یاب نیاز به شارژ مجدد نداشته باشد.

قابل حمل بودن توصیف اینکه سخت‌افزاری که به عنوان هدف استفاده شده، چه میزان راحت می‌تواند حرکت کند. این معیار نیز بادقت لحاظ می‌شود؛ زیرا قابلیت پیاده‌سازی جسم ردیابی شونده در بعضی از موارد هدف است و در صورت عدم درنظر گرفتن معیار، در ردیابی هدف امکان ایجاد اختلال وجود دارد.

امنیت و یکپارچگی نیز عامل مهمی است؛ زیرا اگر سیستم موقعیت‌یاب بهمنظور ردیابی گوشی همراه مورد استفاده قرار گیرد، در صورتی که به استبهای شخصی را دنبال کند و اطلاعات آن شخص را ذخیره کند، ممکن است منجر به خطر امنیتی گردد. در این گزارش به مبحث امنیت و یکپارچگی کمتر پرداخته می‌شود.

### ۳-۲- تخمین فاصله

در این بخش روش‌ها یا الگوریتم‌های مختلف اندازه‌گیری فاصله پرکاربرد را برای چندین سیستم محبوب مورد مطرح کرده سپس فاصله به دست آمده را با استفاده روش سه‌وجهی سازی که در بخش بعد آورده شده است، برای به دست آوردن موقعیت هدف موردنظر استفاده می‌نماییم.

### ۴-۱- شدت (قدرت) سیگنال دریافتی<sup>۷</sup>

دیدگاه شدت سیگنال دریافتی یکی از ساده‌ترین و همچنین گسترده‌ترین دیدگاه‌ها برای عمل موقعیت‌یابی در مکان‌های سرپوشیده است. RSS قدرت یا شدت سیگنال دریافتی در گیرنده سیستم تعریف می‌شود. هر چه مقدار RSS بیشتر باشد به این معنی است که فاصله بین فرستنده و گیرنده کمتر است و معمولاً در واحد دسی‌بل-میلی‌وات (dBm) و یا میلی‌وات (mW) اندازه‌گیری می‌شود. رویکرد RSS می‌تواند در تخمین فاصله بین دستگاه فرستنده<sup>۸</sup> (Tx) و گیرنده<sup>۹</sup> (Rx) استفاده شود و با استفاده از تعدادی مدل مختلف انتشار سیگنال و توجه به اینکه توان انتقال یا توان در نقطه مرجع (گیرنده) معلوم است، فاصله مطلق را تخمین زد.<sup>[۲۰]</sup>

RSSI که نشانگر RSS می‌باشد رنج اندازه‌گیری نسبی ای است که این رنج اندازه‌گیری برای هر نوع تراشه متفاوت است. برای مثال تراشه نوع وای‌فای Atheros RSSI از مقدار ۰ و ۶۰ استفاده می‌نماید در حالی که

<sup>7</sup> Received Signal Strength

<sup>8</sup> Transmitter

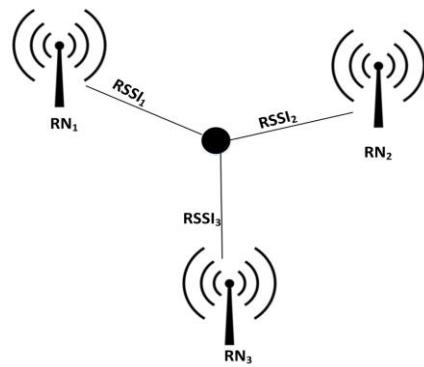
<sup>9</sup> Receiver

تراشه نوع Cisco بین بازه  $0^{\circ}$  و  $100^{\circ}$  اندازه‌گیری را انجام می‌دهد. با استفاده از RSSI و یک نمونه مدل ساده مسیر ازدستداده انتشار [۲۱]، فاصله بین فرستنده و گیرنده از رابطه زیر قابل محاسبه است:

$$RSSI = -10n\log_{10}(d) + A \quad (1-2)$$

که  $n$  توان ازدستدادن مسیر و  $A$  مقدار RSSI در فاصله مرجع از گیرنده است. محلی‌سازی بر مبنای RSS که در شکل ۱-۲ نمونه ایی از آن آورده شده است، نیازمند استفاده از روش سه‌وجهی سازی دارد که در بخش بعد به طور کامل این الگوریتم موقعیت‌یابی توضیح داده شده است.

در حالی که رویکرد مبتنی بر RSS ساده و مقرن‌به‌صرفه است، به دلیل تضعیف سیگنال در اثر عبور از دیوارها و سایر مواد بزرگ که نتیجه آن نوسانات شدید RSS و همچنین محوشدن اثر چندمسیره در فضای داخلی است، پس رویکرد RSS از دقت محلی‌سازی ضعیف (به‌ویژه در شرایط NLoS) رنج می‌برد و بسیار دور از واقعیت است که بدون استفاده از الگوریتم‌ها پیچیده، دقت محلی‌سازی بالایی را بتوان به دست آورد.

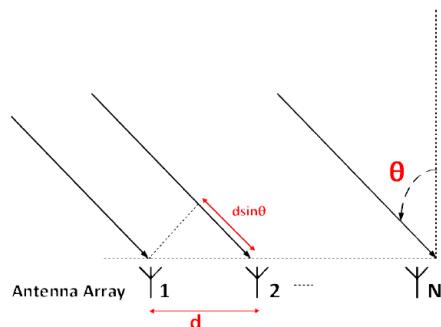


شکل (۱-۲) محلی‌سازی بر مبنای RSSI

### ۲-۳-۲-زاویه ورود (AOA)

رویکردهای مبتنی بر زاویه ورود (AOA) استفاده از آنتن‌های آرایه ایی [۲۲] در سمت گیرنده برای تخمین زاویه برخورد سیگنال ارسالی به گیرنده با بهره‌برداری و محاسبه اختلاف زمانی رسیدن به عناصر جداگانه آنتن آرایه ایی است. مزیت اصلی AOA در این است که موقعیت دستگاه یا کاربر را می‌توان به ترتیب با دو نمایشگر در محیط دو بعدی یا سه نمایشگر در محیط سه‌بعدی تخمین زد. اگرچه AOA می‌تواند تخمین دقیقی را در زمانی که فاصله فرستنده - گیرنده کم است، ارائه دهد؛ اما در مقایسه با تکنیک‌های با رویکرد RSS به سخت‌افزار پیچیده و کالیبراسیون دقیق‌تری نیاز دارد. دقت رویکرد AOA با افزایش فاصله فرستنده و گیرنده که در آن خطای جزئی در محاسبه زاویه ورود، بدتر می‌شود و منجر به خطای بزرگ در تخمین موقعیت هدف خواهد شد. علاوه بر این، به دلیل اثرات چندمسیره در محیط‌های داخلی، AOA از نظر خط دید (LoS) اغلب به سختی به دست می‌آید.

شکل زیر نشان می‌دهد که چگونه می‌توان از روش AoA برای تخمین مکان کاربر استفاده کرد (زوایای ورود سیگنال‌ها که توسط آنتن آرایه ای دریافت می‌شود می‌تواند به مکان‌یابی دستگاه و یا کاربر کمک کند).



شکل (۲-۲) موقعیت‌یابی بر مبنای AoA

### ۳-۳-۲- زمان رسیدن<sup>۱۰</sup> (ToA)

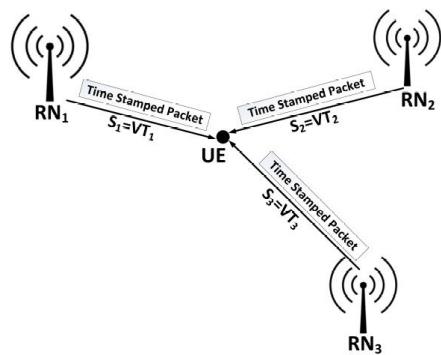
زمان رسیدن (ToA) ساده‌ترین روش تخمین فاصله مبتنی بر زمان است و از ارتباطات یک‌طرفه برای تخمین استفاده می‌کند. روش ToA نیازمند همگام‌سازی دقیق بین فرستنده و گیرنده می‌باشد (باتوجه‌به نوع پروتکل ارتباطی همگام‌سازی متفاوت می‌شود). در این روش کلید اصلی که در دقت تخمین بسیار مؤثر می‌باشد یکی پهنانی باند و دیگری نرخ نمونه‌برداری سیگنال است. نرخ نمونه‌برداری کم (در زمان) دقت ToA را به دلیل اینکه امکان دارد در بازه بین دو نمونه‌برداری سیگنال به گیرنده برسد، کاهش می‌دهد و در این روش پهنانی باند بیشتر به معنای دقت بالاتر تخمین است.<sup>[۲۳]</sup> اگر چه تکنیک پهنانی باند بزرگ می‌تواند باعث بهبود عملکرد ToA شود با این حال نمی‌تواند به طور کامل باعث حذف اثر خطای موقعیت‌یابی که ناشی از مانعی بین فرستنده و گیرنده وجود دارد شود و به این دلیل است که مانع باعث انحراف سیگنال منتشر شده می‌شود که این انحراف منجر به افزایش زمان رسیدن سیگنال از فرستنده به گیرنده و در نتیجه خطای موقعیت‌یابی ایجاد می‌نماید.

روش ToA از زمان انتشار سیگنال برای محاسبه فاصله بین فرستنده  $T_x$  و گیرنده  $R_x$  استفاده می‌نماید به این صورت که حاصل ضرب زمان اندازه‌گیری شده در سرعت نور، فاصله فیزیکی بین فرستنده و گیرنده را محاسبه می‌کند. اگر  $t_1$  را زمان ارسال پیام از فرستنده  $i$  به گیرنده  $j$  که در لحظه  $t_2$  دریافت می‌کند، قرار بدیم جایی که  $t_p$  مدت زمانی است که سیگنال پیام از  $T_x$  به  $R_x$  می‌رسد؛ بنابراین فاصله بین دو نقطه  $i$  و  $j$  از رابطه زیر محاسبه می‌شود.

$$D_{ij} = (t_2 - t_1) \times v \quad (2-2)$$

<sup>10</sup> Time of Arrival

که در رابطه بالا ۷ سرعت سیگنال است. دقت در روش ToA بسیار به همگام‌سازی ساعت فرستنده و گیرنده بستگی دارد. برای درک این میزان وابستگی محاسبه شده است که تأخیر یک نانوثانیه در همگام‌سازی منجر به خطای ۳۰ سانتی‌متری در موقعیت‌یابی می‌گردد. مشابه رویکرد RSS از روش ToA نیز می‌توان برای بهدست‌آوردن موقعیت هدف استفاده نمود. به عنوان نمونه در شکل ۲-۳ از سه گره مرجع<sup>۱۱</sup> (RN) برای موقعیت‌یابی کاربر یا دستگاه در محیط دو بعدی استفاده شده است.



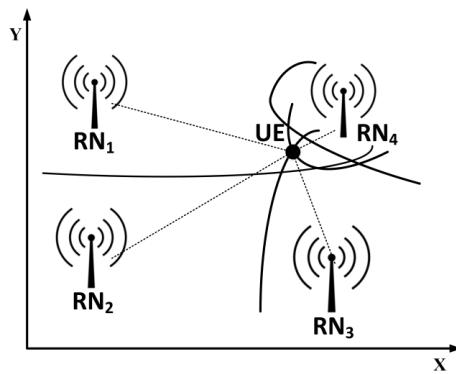
شکل (۳-۲) محدوده دقت فناوری‌های موقعیت‌یابی بر حسب استفاده در داخل یا خارج ساختمان موقعیت‌یابی بر مبنای روش ToA

#### ۴-۳-۲ اختلاف زمان رسیدن<sup>۱۲</sup> (TDoA)

روش اختلاف زمان رسیدن از اختلاف زمان انتشار سیگنال‌ها از فرستنده‌های مختلف که در گیرنده اندازه‌گیری شده است، استفاده می‌کند. رویکرد TDoA با روش ToA که در آن از زمان انتشار سیگنال مطلق استفاده می‌کند متفاوت است و مشابه رویکرد ToA برای محاسبه فاصله از سرعت نور بهره برده می‌شود. در روش TDoA برای محاسبه مختصات دقیق هدف حداقل سه گیرنده با موقعیت‌های مشخص می‌باشد. شکل ۴-۲ نشان می‌دهد که چگونه ۴ گره مرجع مختلف می‌تواند برای تعیین موقعیت هر هدفی مورد استفاده قرار گیرد. دقت تخمین TDoA (مشابه روش ToA) به پهنای باند سیگنال، نرخ نمونه‌برداری در گیرنده و وجود حالت خط دید مستقیم بین گیرنده و فرستنده بستگی دارد. در این روش همگام‌سازی دقیق نیز موردنیاز است؛ اما برخلاف روش ToA که در آن به همگام‌سازی بین فرستنده و گیرنده نیاز است، در مورد TDOA تنها همگام‌سازی بین فرستنده‌ها کفایت می‌کند. در مرجع [۲۴] عنوان شده وظیفه این همگام‌سازی در این مدل از سیستم‌ها به عهده ۴ گره رئیس یا مرجع می‌باشد و در صورتی که به هر دلیلی این گره آسیبی بینند تمام سیستم موقعیت‌یابی دچار مشکل خواهد شد.

<sup>11</sup> Reference node

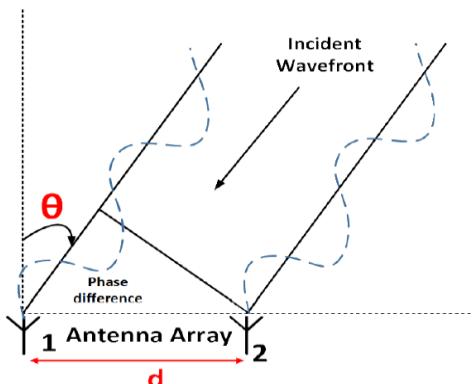
<sup>12</sup> Time Difference of Arrival



شکل (۴-۲) موقعیت یابی بر مبنای روش TDoA به کمک چهار گره مرجع

### ۵-۳-۲- فاز دریافتی<sup>۱۳</sup> (PoA)

دیدگاه روش فاز دریافتی استفاده از فاز یا اختلاف فاز سیگنال حامل برای تخمین فاصله بین فرستنده و گیرنده می‌باشد. فرض معمولی که برای تعیین فاز سیگنال در طرف گیرنده می‌باشد این است که سیگنالی که از آنتن و  $R_x$  یا از دستگاه سینوسی خالص ارسال می‌شود دارای انحراف فاز صفر باشد. تکنیک‌هایی برای تخمین فاصله بین  $R_x$  و  $T_x$  با استفاده از روش PoA موجود است. یکی از روش‌ها به این صورت است که فرض شود تأخیر محدودی در ارسال سیگنال بین فرستنده و گیرنده وجود دارد که می‌توان آن را به صورت کسری از طول موج سیگنال بیان کرد. همان‌طور که در شکل ۵-۲ دیده می‌شود سیگنال با اختلاف فاز به آنتن آرایه ای می‌رسد که می‌توان به کمک آن موقعیت هدف را به دست آورد. روش PoA را می‌توان با روش‌هایی مانند RSSI، ToA و TDoA برای بهبود دقیقیت یابی و ارتقا عملکرد سیستم ترکیب نمود. مسئله ایی که در این الگوریتم وجود دارد این است که شرایط محیط سرپوشیده در تعیین دقیقیت یابی بسیار تأثیرگذار است.



شکل (۵-۲) محل‌سازی بر مبنای PoA

<sup>13</sup> Phase of Arrival

### ۱۴-۳-۲-اثر انگشت یا انگشت‌نگاری<sup>۱۴</sup>

به طور معمول روش محلی‌سازی مبتنی بر تحلیل صحنه، به بررسی محیطی برای بهدست آوردن ویژگی‌های محیطی که در آن سیستم محلی ساز قرار است استفاده شود، می‌پردازد. در ابتدا اندازه‌گیری‌های مختلف RSSI در فاز آفلاین جمع‌آوری شده و پس از استقرار سیستم، اندازه‌گیری آنلاین (که در زمان واقعی به دست می‌آیند) با اندازه‌گیری‌های آفلاین مقایسه می‌شوند تا مکان کاربر را تخمین بزنند. اندازه‌گیری‌های بخش آفلاین گسسته است نه پیوسته و ممکن است در بخش آنلاین نقطه ای برای اندازه‌گیری قرار گیرد که در بخش آفلاین داده ای برای آن نقطه ذخیره نشده باشد پس با کاهش فاصله بین نقاط اندازه‌گیری آفلاین، می‌توان گفت تخمین تقریباً پیوسته است و به طبع هرچه میزان داده‌های بخش آفلاین بیشتر باشد دقت تخمین بالاتر رفته است که این امر ملزم به زمان زیاد برای انگشت‌نگاری است. روش اثر انگشت یکی از مهم‌ترین روش‌ها برای تخمین موقعیت NLoS بادقت بالا است [۲۴].

جدول (۱-۲) خلاصه ایی از رویکردهای مورد استفاده در سیستم‌های موقعیت‌یاب

رویکرد	مزایا	معایب
RSS	پیاده‌سازی راحت، مقرر به صرفه، قابلیت استفاده در چندین فناوری	مستعد محو شدن پدیده چندمسیره و نویز محیطی، دقت محلی‌سازی کم، می‌تواند نیاز به اثر انگشت داشته باشد.
AoA	فرام ساختن دقت محلی‌سازی بالا بدون نیاز به استفاده از روش انگشت‌نگاری	ممکن است به آنتن‌های جهت‌دار و سخت‌افزار پیچیده نیاز داشته باشد، به الگوریتم‌ها و عملکرد نسبتاً پیچیده نیاز دارد با افزایش فاصله بین فرستنده گیرنده عملکرد سیستم خراب می‌شود.
ToF-ToA	فرام ساختن دقت محلی‌سازی بالا بدون نیاز به استفاده از روش انگشت‌نگاری	نیاز به همگام‌سازی زمانی بین فرستنده‌ها و گیرنده‌ها، برای عملکرد دقیق نیاز به محیط LoS دارد.
TDoA	عدم نیاز به همگام‌سازی ساعت در بین گره‌های مرجع، عدم نیاز به روش انگشت‌نگاری	ممکن است نیاز به همگام‌سازی ساعت بین گره‌های مرجع داشته باشد، به پهنای باند بزرگ‌تری نیاز دارد
PoA	قابلیت ترکیب با رویکردهای TDoA,RSS,ToA به منظور بهبود دقت محلی‌سازی در مجموع	عملکرد ضعیف در غیاب خط دید

<sup>۱۴</sup> Fingerprinting

تغییر حتی کوچک در محیط آزمایش، نیاز به اثر انگشت جدید است.	فراهم ساختن دقت محلی‌سازی بالا، قابلیت استفاده راحت	Fingerprinting
--	---	----------------

## ۴-۲-الگوریتم‌های رایج موقعیت‌یابی

در این بخش از روش‌های اندازه‌گیری فاصله که در بالا به آن ذکر شده استفاده کرده و موقعیت هدف را تعیین می‌نماییم. از بین دو الگوریتم سه‌وجهی سازی و چهاروجهی سازی به دلیل هزینه پایین‌تر و همچنین دقت مناسب، روش موقعیت‌یابی سه‌وجهی سازی مقبولیت بالاتری را دارد.

### ۴-۲-۱-روش سه‌وجهی سازی (مثلاً بندی)<sup>۱۵</sup>

اصل موقعیت‌یابی بر مبنای RSS و غیره اندازه‌گیری زمان یا توان ارسال سیگنال از هدف به هر کدام از مراجع می‌باشد. بر اساس این زمان یا توان و معلوم بودن سرعت نور یا سیگنال C، فاصله بین هدف و منبع قبل محاسبه می‌باشد. (رابطه ۲-۲). برای محاسبه موقعیت تگ با استفاده از الگوریتم سه‌وجهی سازی مختصات موقعیت حداقل سه مرجع یا انکر<sup>۱۶</sup> موردنیاز است [۲۵]. در صورتی که موقعیت هر منبع را در فضای دو بعدی به صورت  $(x_i, y_i)$  در نظر بگیریم و موقعیت هدف را نیز به صورت  $(x_0, y_0)$  و فاصله بین هر منبع با هدف را با  $d_i$  نشان دهیم. با استفاده از شماتیک موقعیت‌یابی که در شکل ۲-۶ بخش الف نشان داده شده است برای به دست آوردن موقعیت هدف به معادله ۳-۲ می‌رسیم.

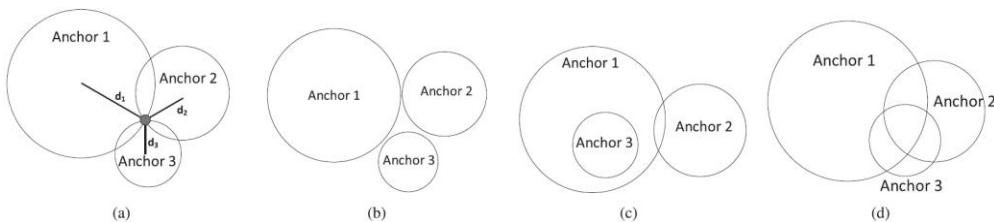
$$d_i^2 = (x_i - x_0)^2 + (y_i - y_0)^2 \quad (3-2)$$

در فناوری GPS مختصات ماهواره‌ها مشخص است و در فناوری‌های موقعیت‌یابی داخلی نیز مختصات منابع مشخص است و فاصله بین هدف و منبع مطابق رابطه فوق محاسبه می‌شود. محدودیت اصلی در اجرای دقیق الگوریتم سه‌وجهی، محاسبه دقیق فاصله بین منبع و هدف است. اولین شکل از سمت چپ شرایطی ایده‌آل را برای اجرای الگوریتم سه‌وجهی [۲۶] نشان می‌دهد که در آن سه دایره به طور دقیق تنها در یک نقطه برخورد دارند اما در عمل مقداری خطأ در محاسبه فاصله وجود دارد و به دلیل این خطأ، دقت موقعیت‌یابی نیز کاهش پیدا می‌کند. شکل های ۲-۶ بخش‌های ب ج د سه مورد را نشان می‌دهد که در آنها خطاهای موقعیت‌یابی مشهود است در همه موارد به دلیل اندازه‌گیری نادرست فاصله، دایره‌ها یا روی هم قرار می‌گیرند و یا اصلاً قطع نمی‌شوند. شکل ۶ ب نشان می‌دهد که دایره‌ها هیچ تلاقی با هم ندارند در این مورد نمی‌توان سه‌وجهی را اجرا کرد. شکل ۶ ب نشان می‌دهد که منبع ۳ با منبع ۱ هم پوشانی دارد اما هیچ تقاطعی بین منبع ۲ و ۳ وجود ندارد در این

<sup>15</sup> Trilateration

<sup>16</sup> Anchor

موردنیز نمی‌توان سه‌وجهی را اجرا کرد. در شکل زیر بخش د چندین منطقه تقاطع را بین منابع نشان می‌دهد سه‌وجهی را در این سناریو می‌توان اجرا نمود اما دقت کمتری در تخمین موقعیت خواهیم داشت.



شکل (۶-۲) شماتیک موقعیت‌یابی روش سه‌وجهی (a) سناریو ایده‌آل سه‌وجهی (b) سناریو عملی بدون تقاطع (c) سناریو عملی بدون تقاطع واضح (d) سناریو عملی با چندین منطقه تقاطع

## ۴-۴-۲-روش چهاروجهی سازی

معادلات زیر روابط موقعیت‌یابی در فضای ۳ بعد را بیان می‌کند که از چهار انکر بهمنظور موقعیت‌یابی استفاده گردیده است در صورتی که محور Z به روابط اضافه شود، معادله موقعیت‌یابی در فضای ۳ بعدی را خواهیم داشت و در صورتی که از ۴ منبع برای موقعیت‌یابی استفاده نماییم و مختصات نقاط مرجع  $(x_A, y_A, z_A)$  و مختصات هدف را با  $(x, y, z)$  نشان دهیم با استفاده از روابط مرتبط، خواهیم داشت: [۲۴]

$$\begin{aligned} & 2(x_1 - x_2)x + 2(y_1 - y_2)y + 2(z_1 - z_2)z = \\ & (d_2^2 - d_1^2) - (x_2^2 - x_1^2) - (y_2^2 - y_1^2) - (z_2^2 - z_1^2) \end{aligned} \quad (4-2)$$

$$\begin{aligned} & 2(x_1 - x_3)x + 2(y_1 - y_3)y + 2(z_1 - z_3)z = \\ & (d_3^2 - d_1^2) - (x_3^2 - x_1^2) - (y_3^2 - y_1^2) - (z_3^2 - z_1^2) \end{aligned} \quad (5-2)$$

$$\begin{aligned} & 2(x_1 - x_4)x + 2(y_1 - y_4)y + 2(z_1 - z_4)z = \\ & (d_4^2 - d_1^2) - (x_4^2 - x_1^2) - (y_4^2 - y_1^2) - (z_4^2 - z_1^2) \end{aligned} \quad (6-2)$$

سه معادله بالا را به طور خلاصه با رابطه زیر نیز می‌توان بیان کرد.

$$X = M^{-1}N \quad (7-2)$$

که X در رابطه ۷-۲، بردار ستونی بیانگر مختصات هدف، M ماتریسی با ابعاد  $3 \times 3$  و N نیز بردار ستونی می‌باشد:

$$M = \begin{bmatrix} 2(x_1 - x_2) & 2(y_1 - y_2) & 2(z_1 - z_2) \\ 2(x_1 - x_3) & 2(y_1 - y_3) & 2(z_1 - z_3) \\ 2(x_1 - x_4) & 2(y_1 - y_4) & 2(z_1 - z_4) \end{bmatrix} \quad (8-2)$$

$$N = \begin{bmatrix} (d_2^2 - d_1^2) - (x_2^2 - x_1^2) - (y_2^2 - y_1^2) - (z_2^2 - z_1^2) \\ (d_3^2 - d_1^2) - (x_3^2 - x_1^2) - (y_3^2 - y_1^2) - (z_3^2 - z_1^2) \\ (d_4^2 - d_1^2) - (x_4^2 - x_1^2) - (y_4^2 - y_1^2) - (z_4^2 - z_1^2) \end{bmatrix} \quad (9-2)$$

در مجموع می‌توان گفت برای یافتن موقعیت هدف  $N$  بعدی حداقل  $N+1$  نقطه مرجع می‌بایست وجود داشته باشد. پس با استفاده از الگوریتم سه‌وجهی سازی موقعیت یک هدف را در صفحه دو بعدی و الگوریتم چهار وجهی سازی موقعیت هدف را در فضا می‌توان به دست آورد. الگوریتم موقعیت‌یابی با استفاده از روش حداقل مربعات و حداقل مربعات وزن‌دهی شده سازی که در بخش پیوست آورده شده است، حل می‌شوند.

## ۵-۲- معیارهای ارزیابی عملکرد تخمین موقعیت

معیارهای ارزیابی عملکرد تخمین موقعیت، شاخص‌هایی هستند که برای سنجش دقت و صحت یک مدل تخمین موقعیت استفاده می‌شوند. این معیارها بر اساس اختلاف بین موقعیت واقعی شیء و موقعیت تخمینی آن توسط مدل محاسبه می‌شوند. انتخاب معیار مناسب برای ارزیابی عملکرد تخمین موقعیت به عوامل مختلفی از جمله نوع داده‌های ورودی، نوع مدل تخمین موقعیت و اهداف کاربردی بستگی دارد. به طور کلی، MSE معیار همه‌کاره است که برای اکثر کاربردها مناسب است. RMSE نیز معیاری مناسب است که نسبت به MSE کمتر تحت تأثیر مقادیر پرت قرار می‌گیرد. MAE نیز معیاری مناسب است که نسبت به MSE و RMSE کمتر حساس به مقادیر پرت است. در مجموع انتخاب معیار مناسب برای ارزیابی عملکرد تخمین موقعیت تصمیم وابسته به شرایط است.

### ۱-۵-۲- معیار میانگین مربعات خطأ (MSE)

میانگین مربعات خطأ (MSE) معیاری مهم برای ارزیابی عملکرد مدل‌های رگرسیون است. دقت کلی مدل را با ارزیابی میانگین مجدد اختلاف بین مقادیر پیش‌بینی شده و مقادیر واقعی می‌سنجد. MSE پایین‌تر نشان‌دهنده یک مدل با عملکرد بهتر است و همچنین نشان می‌دهد که پیش‌بینی‌های آن به مقادیر واقعی نزدیک‌تر است. هدف الگوریتم‌های رگرسیون به حداقل‌رساندن MSE با تنظیم ضرایب مدل برای به حداقل‌رساندن اختلاف کلی بین مقادیر پیش‌بینی شده و واقعی است. این فرآیند تضمین می‌کند که مدل الگوهای اساسی در داده‌ها را ثبت کرده و پیش‌بینی‌های دقیقی ایجاد می‌کند.

فرمول MSE برای رگرسیون به صورت زیر است:

$$MSE = \frac{1}{n} \sum_{j=1}^n (P_j - A_j)^2 \quad (10-2)$$

که در آن  $P_j$  مقدار پیش‌بینی شده نمونه  $j$  است،  $A_j$  مقدار هدف واقعی نمونه  $j$  و  $n$  تعداد نمونه‌ها است. نقطه ضعف اصلی میانگین مربعات خطأ ( $MSE$ ) در این است که این اندازه‌گیری، اطلاعات کافی درباره تبادل داده‌های مربوط به هر کلاس را فراهم نمی‌کند به عبارت دیگر،  $MSE$  نمی‌تواند به خوبی ارزیابی کند که چقدر تفاوت‌ها و اختلافات بین داده‌های مختلف کلاس‌ها مهم هستند که ممکن است باعث شود فرآیند تصمیم‌گیری برای انتخاب جواب به طور نامناسبی انجام شود. همچنین، این معیار بهشت به مقدار اولیه وزن‌ها وابسته است. در مورد مسئله کلاس‌های نامتوازن، اگر وزن‌های ابتدایی به درستی انتخاب نشوند ممکن است فرآیند تصمیم‌گیری به راه حل غیربهینه منجر شود.] [۲۷]

## ۲-۵-۲- معیار ریشه میانگین مربعات خطأ (RMSE)

در معیار RMSE، مقدار خطأ با محاسبه ریشه دوم از میانگین مربعات خطأ بدست می‌آید. این به این معناست که واحدهای RMSE با واحدهای اصلی مقدار هدف پیش‌بینی یکسان هستند؛ بنابراین، استفاده از معیار MSE برای آموزش مدل پیش‌بینی رگرسیون متداول است، و در همین حال، استفاده از RMSE برای ارزیابی و گزارش عملکرد آن نیز رایج می‌باشد.

را می‌توان از رابطه زیر محاسبه نمود:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (11-2)$$

## ۲-۵-۳- معیار میانگین قدر مطلق خطأ (MAE)

میانگین خطای مطلق (MAE) یکی دیگر از معیارهای رایج مورد استفاده برای عملکرد مدل‌های رگرسیونی است. شبیه معیار MSE است که تفاوت بین مقادیر پیش‌بینی شده و واقعی را اندازه‌گیری می‌کند، اما این کار را با گرفتن قدر مطلق تفاوت به جای مجذور کردن آن انجام می‌دهد. این به این معنی است که MAE نسبت به MSE حساسیت کمتری نسبت به داده‌های دورافتاده دارد. در نتایج تخمین موقعیت بخش بعدازاین معیار برای نشان‌دادن میزان خطای موقعیت واقعی و تخمین زده شده استفاده شده است. MAE به صورت رابطه زیر قابل‌بیان است:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (12-2)$$

## ۶-۲- فناوری‌های موقعیت‌یابی مورداستفاده در محیط داخلی

فناوری‌های متعددی برای حل مشکل موقعیت‌یابی در فضای داخلی وجود دارد که هر کدام مزایا و معایب خاص خود را دارند. اکثر این فناوری‌ها نیاز دارند که هدف موردنظر برای موقعیت‌یابی یا ردیابی بدنوعی سخت‌افزار مجهز شود که با سرور محلی ساز ارتباط برقرار می‌کند و اطلاعات مورداستفاده برای تعیین موقعیت اهداف را منتقل سازد. در این بخش مروری بر سیستم‌های مرتبط با این روش‌ها و فناوری‌ها ارائه می‌شود و در پایان خلاصه‌ای بر ویژگی‌های کلیدی فناوری‌های نامبرده شده، ارائه می‌گردد. در بخش قبل روش‌ها و الگوریتم‌های مختلفی برای اندازه‌گیری فاصله بین فرستنده و گیرنده ارائه شده است که در این فصل از روش‌های مطرح شده برای گروه‌بندی فناوری‌ها مورداستفاده در مکان‌های سرپوشیده استفاده می‌گردد.

### ۶-۲-۱- سیستم‌های مبتنی بر RSS

در این بخش فناوری‌هایی که از رویکرد RSS به عنوان روش اندازه‌گیری استفاده می‌کند، موربدبخت قرار می‌گیرد. همان‌طور که در بخش ۳-۲ نیز عنوان شد این فناوری‌ها عموماً ارزان قیمت، کم دقت، بازه اندازه‌گیری بسیار محدودتر و در محیط‌های ترکیبی مشکل بررسی و تجزیه تحلیل را دارند.

#### ۶-۲-۱-۱- شبکه محلی بی‌سیم (WLAN)

استاندارد IEEE 802.11 و یا شبکه محلی بی‌سیم که به عنوان وای‌فای<sup>۱۸</sup> نیز شناخته می‌شود در فعالیت‌های صنعتی، علمی و پزشکی مورداستفاده قرار می‌گیرد و در درجه اول برای ارائه قابلیت‌های شبکه و اتصال اینترنت به دستگاه‌های مختلف در محیط‌های شخصی، عمومی و تجاری مورداستفاده قرار می‌گیرد. فناوری وای‌فای آمادگی پذیرش محدوده ۱۰۰ متر [۲۸]، که اکنون تا ۱ کیلومتر نیز قابل ارتقاست، را دارا می‌باشد [۲۹]. در حال حاضر عمدۀ تلفن‌های هوشمند، رایانه‌ها و سایر دستگاه‌های قابل حمل دارای فناوری وای‌فای می‌باشند که این ویژگی فناوری وای‌فای را کاندیدای مناسبی به منظور موقعیت‌یابی در مکان‌های سرپوشیده معرفی می‌کند. با وجود اینکه نقاط دسترسی<sup>۱۹</sup> وای‌فای سیستم‌های موقعیت‌یابی پایه می‌توانند بدون نیاز به هیچ زیرساخت اضافی راه اندازی شوند، از شبکه‌های وای‌فای به طور معمول در ارتباطات بیشتر از فعالیت‌های موقعیت‌یابی استفاده می‌شود زیرا که در این فناوری به الگوریتم‌های موثری برای بهبود دقت موقعیت‌یابی نیاز است. از رویکردهای ذکر شده در این فصل مانند AoA, ToA, RSS و یا ترکیبی از این روش‌ها (عمدتاً از RSS استفاده می‌کنند) می‌توان برای بهبود موقعیت‌یابی بر مبنای فناوری وای‌فای استفاده نمود. برای اطلاعات بیشتر در مورد این فناوری به مرجع [۳۰] رجوع شود.

<sup>17</sup> Wireless Local Area Network

<sup>18</sup> WiFi

<sup>19</sup> Access Points

## ۲-۶-۱-۲ دستگاه شناسایی فرکانس رادیویی (RFID)

اساساً فناوری RFID برای انتقال و ذخیره داده‌ها با استفاده از انتقال الکترومغناطیسی از سمت فرستنده به هر مدار سازگار با فرکانس رادیویی (RF) در نظر گرفته شده است. سیستم RFID شامل بخشی به عنوان خواننده است که می‌تواند با گیرنده‌های (تگ<sup>۲۱</sup>) RFID ارتباط برقرار کند. تگ‌های RFID داده ایی که خواننده آن می‌تواند بخواند را به کمک RF از پیش تعریف شده و پروتکلی که برای خواننده از قبل شناخته شده است، انتشار می‌دهد. در مجموع سیستم‌های RFID به دودسته کلی مشابه با مرجع [۳۱] تقسیم‌بندی می‌شوند:

- **RFID فعال:** این نوع سیستم‌ها در محدوده فرکانس‌های بسیار بالا و مایکروویو عمل می‌نمایند. این مدل از سیستم‌ها برای تأمین انرژی به منبع برق محلی متصل می‌شوند و به طور متناوب در حال ارسال شناسه (ID) مخصوص به خود هستند که توانایی اجرا از فاصله ده‌ها متری خواننده RFID را دارند. RFID فعال را می‌توان به دلایل برد مناسب، هزینه کم و قابلیت جاسازی در اجسام برای محلی‌سازی و ردیابی اشیا استفاده نمود. با این حال این نوع سیستم دارای دقت زیر یک متر را ندارد و همچنین در بیشتر دستگاه‌های قابل حمل در دسترس نیست.
- **RFID غیرفعال یا پسیو:** RFID غیرفعال به رنج بین ۱-۴ متر محدود شده‌اند و هم چنین بدون داشتن منبع تغذیه عمل می‌نمایند. این مدل از RFID نسبت به نوع فعال آن از لحاظ ابعاد کوچک‌تر و ارزان‌تر می‌باشد. این نوع سیستم توانایی کار در فرکانس‌های بالا پایین را دارا می‌باشد. با توجه به محدوده کم عملکرد قابلیت استفاده برای موقعیت‌یابی در کارهای تجاری را ندارد اگرچه می‌توان به عنوان جایگزین تجهیز بارکد از مدل RFID غیرفعال بهره برد.

## ۲-۶-۱-۳ بلوتوث

فناوری بلوتوث (IEEE 802.15.1) مانند فناوری وای‌فای برای تخمین موقعیت هدف از اندازه‌گیری با رویکرد RSS بهره می‌برد، پس از مشکلات مشابه مانند دقت و برد اندازه‌گیری کم رنج نیز خواهد برد و همچنین دارای مزایایی مشترک همچون امکان ردیابی به کمک گوشی‌های هوشمند و عدم نیاز به سخت‌افزار اضافی را دارا می‌باشد. [۲۳] آخرین نسخه فناوری بلوتوث با مصرف انرژی پایین که تحت عنوان بلوتوث هوشمند نیز شناخته می‌شود می‌تواند نرخ داده‌های بهتری با محدوده تحت پوشش ۷۰ متری را با مصرف انرژی کمتری در مقایسه با نسخه‌های قدیمی‌تر فراهم سازد. در حالی که فناوری<sup>۲۳</sup> BLE می‌تواند از روش‌های مختلفی مانند RSSI AoA استفاده نماید؛ اما بیشترین الگوریتم مورداستفاده در این فناوری بر مبنای RSS می‌باشد. دو پروتکل بر

<sup>20</sup> Radio Frequency Identification Device

<sup>21</sup> Tag

<sup>22</sup> Bluetooth

<sup>23</sup> Bluetooth Low Energy

مبنای BLE تحت عنوان iBeacons توسط شرکت اپل و Eddystone گوگل ارائه شده است که برای اطلاعات بیشتر می‌توان به سایت رسمی این شرکتها می‌توان رجوع کرد.

### ۲-۶-۱-۴ زیگبی

هدفی که توسط فناوری (IEEE 802.15.4) زیگبی تعریف شده، ساده‌تر و ارزان‌تر بودن نسبت به سایر شبکه‌های شخصی بی‌سیم مانند بلوتوث یا وای‌فای است.<sup>[۳۲]</sup> کاربرد های این تکنولوژی شامل چراغ های برق بی‌سیم، کنترل کننده های مصرف برق به همراه نمایشگر های داخل خانه، سیستم‌های مدیریت ترافیک و سایر تجهیزات مصرفی و صنعتی که به انتقال داده بی‌سیم، کوتاه برد و با نرخ انتقال پایین نیاز دارند می‌باشد. مصرف توان کم این سیستم فاصله انتقال را به ۱۰ تا ۱۰۰ متر شاعع دید محدود می‌کند که میزان دقیق آن به توان خروجی خصوصیات محیطی بستگی دارد. دستگاه‌های زیگبی می‌توانند با گذراندن داده‌ها از یک شبکه توری از دستگاه‌های واسطه آن ها را در فواصل طولانی نیز منتقل کنند. فناوری زیگبی معمولاً در کاربرد های با نرخ انتقال داده کم، که به عمر باتری طولانی و شبکه‌های ایمن نیاز دارند، استفاده می‌شود و نرخ انتقال داده تعریف شده ای برابر ۲۵۰ کیلوبیت در ثانیه دارد که برای انتقال داده‌ها به صورت متناوب از یک حسگر یا دستگاه ورودی بسیار مناسب است. با توجه به اینکه این فناوری به راحتی و انبوه در اکثر تجهیزات کاربران موجود نمی‌باشد پس روش زیگبی آنچنان برای موقعیت‌یابی در مکان‌های داخلی محبوب نمی‌باشد.

### ۲-۶-۲ سیستم‌های مبتنی بر زمان

در این بخش از فناوری‌های که بر مبنای زمان توانایی موقعیت‌یابی را دارا هستند، صحبت خواهد شد. در این فصل نیز بیان کردیم که فناوری‌های مبتنی بر زمان به نسبت فناوری‌های مبتنی بر RSS دقیق‌تر اما هزینه و پیچیدگی بیشتری را برای تعیین فاصله خواهند داشت.

### ۲-۶-۲-۱ سیگنال صوتی (اکوستیک)

فناوری سیگنال صوتی بر پایه محلی‌سازی در حال حاضر در تمامی گوشی‌های هوشمند که دارای حسگر میکروفون می‌باشد موجود است. روش مرسوم مورداستفاده برای محلی‌سازی مبتنی بر آکوستیک انتقال سیگنال مدوله شده که حاوی اطلاعات مربوط به زمان است که توسط حسگرهای میکروفون برای تخمین ToA استفاده می‌شود. مطابق با نتایج مرجع<sup>[۳۳]</sup>، اگر چه فناوری سیگنال صوتی نشان داده که دقت بالایی به منظور محلی‌سازی دارد اما تنها پنهانی باند سیگنال صوتی قابل شنیدن (کمتر از ۲۰ کیلو هرتز) می‌تواند دقت تخمین کافی را فراهم سازد. به همین دلیل می‌بایست توان انتقال به اندازه‌ای کافی کم باشد تا منجر به آلودگی صوتی نگردد و همچنین الگوریتم‌های پردازش سیگنال پیشرفت‌هایی برای بهبود تشخیص توان کم سیگنال دریافتی در گیرنده نیاز است. در هر حال این فناوری نیاز به زیر ساخت مانند منابع صوتی، گره‌های مرجع به منظور عمل موقعیت‌یابی می‌باشد.

<sup>24</sup> ZigBee

<sup>25</sup> Acoustic Signal

که باعث شده است فناوری سیگنال صوتی در امر محلی‌سازی جز فناوری‌های بسیار محبوب و کاربردی به شمار نرود.

## ۲-۶-۲ فراصوت

فناوری محلی ساز مبتنی بر فراصوت، عمدتاً به اندازه‌گیری ToA سیگنال‌های فراصوت و سرعت صوت به‌منظور محاسبه فاصله بین فرستنده و گیرنده متکی است. در مقایسه با سایر رویکردهای مبتنی بر زمان مهم‌ترین مزیت این فناوری عدم نیاز به همگام‌سازی فرستنده یا گیرنده می‌باشد. در مرجع [۳۴] نشان‌داده شده است که دقت مکان‌یابی با فناوری فراصوت در سطح سانتی‌متر خواهد بود. با این حال این فناوری به‌شدت تحت تأثیر نویز محیط قرار می‌گیرد و اگر چه الگوریتم‌های پیچیده پردازش سیگنال می‌توانند تا حدودی نویز را فیلتر کنند؛ اما یک منبع نویز دائمی ممکن است عملکرد سیستم را به‌شدت کاهش دهد و همچنین این فناوری تنها در محیط LoS کاربرد دارد و از دیگر معایب این فناوری مطابق با مرجع [۳۵] در امر موقعیت‌یابی می‌توان به محدوده اندازه‌گیری پایین آن اشاره نمود که این موارد منجر به استفاده محدود از فناوری فراصوت در محیط‌های داخلی شده است.

## ۲-۶-۳ فرآپهن باند (UWB)

UWB پروتکل رادیویی سریع، ایمن و کم‌صرف است که برای تعیین مکان‌های مسافت کوتاه بادقت بالاتری نسبت به سایر فناوری‌های بی‌سیم (در عرض چندسانسی متر) استفاده می‌شود. علاوه بر این، به لطف چگالی طیفی کم‌توان، سیگنال‌های UWB تداخل بسیار کمی با سیستم رادیویی باند باریک موجود ایجاد می‌کنند. سیگنال‌های فراپهن باند به دلیل داشتن پهنه‌ای باند گسترده (۷/۵۰۰ گیگاهرتز)، نرخ بیت بسیار بالا و توان مصرفی بسیار پایین، تفکیک زمانی بسیار خوبی را فراهم می‌کند. این سیستم‌ها به‌جای استفاده از حامل‌های سینوسی برای انتقال سیگنال، از پالس‌های بسیار باریک (تقرباً ۰/۲ نانوثانیه) که دارای پهنه‌ای باند بسیار وسیعی هستند، بهره می‌برند. فناوری UWB یکی از جدیدترین، دقیق‌ترین و امیدوارکننده‌ترین فناوری‌های موقعیت‌یابی در مکان‌های سرپوشیده است که به عنوان فناوری بدون باند، ضربه‌ای و بدون حامل شناخته می‌شود. [۳۶] در حالی که استفاده از روش RSS در این فناوری امکان پذیر است اما در اغلب موارد از روش‌های مبتنی بر زمان که در بخش ۲-۲ مورد بحث قرار گرفت، استفاده می‌شود. و به دلیل داشتن پهنه‌ای فرکانسی وسیع در برابر تداخل ناشی از سیگنال‌های بازتابی مقاوم است و همچنین محتوای انرژی بالا سیگنال می‌تواند به بسیاری از مواد نرم نفوذ کند.

چالش اصلی فناوری UWB این است که نسبت به سایر فناوری‌ها مانند وای‌فای و یا بلوتوث که در گوشی‌های همراه و دستگاه‌های قابل حمل به کاررفته، مورد استفاده قرار نگرفته بنابراین نیاز به سخت‌افزار جداگانه دارد که این

موضوع منجر به گران‌تر شدن این فناوری می‌شود که بزرگ‌ترین نگرانی در مورد سیستم‌های مبتنی بر این فناوری است.

جدول (۲-۲) خلاصه‌ایی از مهم‌ترین فناوری‌های مورداستفاده در محیط‌های سرپوشیده

فناوری‌ها	حداکثر برد	میزان مصرف انرژی	مزایا	معایب
WLAN	در محیط‌های خارجی ۲۵۰ متر در محیط‌های داخلی ۳۵ متر	در حد متوسط	به طور گستردگی در دسترس، دقت بالا، سخت‌افزار اضافی پیچیده نیاز ندارد.	نیاز به الگوریتم‌های پیچیده پردازش، امکان تداخل سیگنال و مستعد ابتلا به نویز
RFID	۲۰۰ متر	کم	صرف انرژی کم، محدوده عملکرد به نسبت بالا	دقت محلی‌سازی پایین
Bluetooth	۱۰۰ متر	کم	توان عملیاتی بالا، برد دریافت، مصرف انرژی پایین	دقت محلی‌سازی کم، مستعد ابتلا به نویز
Ultrasound	چندین متر	در حد متوسط - کم	عدم نیاز به همگام‌سازی فرستنده و گیرنده	وابستگی زیاد به محل سنسور
UWB	۶۰-۸۰ متر	در حد متوسط	ایمن در برابر تداخل سیگنال، دقت بالا و عملکرد بهتر در شرایط مختلف و هزینه بالا	نیاز به سخت‌افزار اضافی در دستگاه‌های کاربری مختلف و هزینه بالا
NLoS				

### ۳-۶-۲- سایر فناوری‌ها

#### ۲-۶-۳-۱- ارتباط نور مرئی (VLC)<sup>۲۷</sup>

ارتباط نور مرئی، فناوری در حال ظهور برای انتقال داده با سرعت بالا می‌باشد که از نور مرئی در بازه بین ۴۰۰ تا ۸۰۰ THz استفاده می‌نماید. روش موقعیت‌یابی به کمک نور مرئی از حسگرهای نوری برای اندازه‌گیری فاصله و همچنین ساطع کننده‌های LED استفاده می‌نماید. به عبارت دیگر LED سیگنال را ارسال می‌کند که توسط گیرنده و یا حسگر می‌توان موقعیت‌یابی انجام گیرد. برای این فناوری الگوریتم AoA که بیشترین دقت موردنیاز را به کاربر می‌دهد در نظر گرفته شده است. مزیت اصلی فناوری نور مرئی بر پایه موقعیت‌یابی محدوده وسیع آن می‌باشد (حتی بیشتر از فناوری وای‌فای). در هر حال اساسی‌ترین محدودیت این روش مطابق با گفته‌های مرجع [۳۷] وجود مانع بین حسگر و LED می‌باشد(NLoS) که باعث کاهش شدید دقت موقعیت‌یابی خواهد شد.

<sup>27</sup> Visual light communication

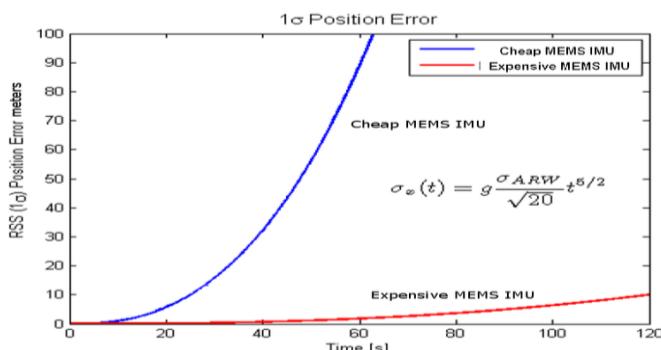
## ۲-۳-۶ واحد اندازه‌گیری اینرسی<sup>۲۸</sup> (IMU)

اصطلاح IMU به معنای «واحد اندازه‌گیری اینرسی» است، و از آن برای توصیف یک مجموعه از ابزارهای اندازه‌گیری استفاده می‌کنیم. هنگامی که این واحد در دستگاه نصب می‌شود، این ابزارها می‌توانند داده‌های مربوط به حرکت دستگاه را ثبت کنند. فناوری IMU سنسورهای شتاب‌سنج‌ها، ژیروسکوپ‌ها<sup>۲۹</sup>، و جاذبه سنج‌ها را در بر می‌گیرد.

هر بخش در IMU برای ثبت انواع داده مختلف استفاده می‌شود که می‌توان به سه دسته زیربخش بندی نمود

- **شتتاب‌سنج:** سرعت و شتاب را اندازه‌گیری می‌کند.
- **ژیروسکوپ:** چرخش و سرعت چرخشی را اندازه‌گیری می‌کند.
- **جاذبه سنج:** جهت اصلی (راستای جهت‌دار) را مشخص می‌کند.

فناوری IMU عمدها در تجهیزات ناوبری مانند هوایپیمای سرنشیین‌دار و بدون سرنشیین، سامانه‌های موقعیت‌یابی GPS (فناوری IMU مکمل برای سامانه‌های موقعیت‌یابی GPS عمل می‌کنند، و این امکان را فراهم می‌کنند که تجهیز ناوبری در صورت ازدستدادن اتصال ماهواره‌ای با موقعیت تخمین زده شده، ادامه دهد). و اغلب تلفنهای هوشمند به کار می‌روند. نقطه ضعف اصلی فناوری IMU این است که آنها مستعد خطا‌هایی هستند که باگذشت زمان روی‌هم جمع می‌شوند که این مدل خطاها را، خطای رانش<sup>۳۰</sup> می‌نماید و این خطا منجر به عدم دقت در کاربردهای موقعیت‌یابی خواهد شد. برای درک بهتر از خطا رانش، شکل زیر می‌تواند دیدگاه بهتری را نسبت به این موضوع بیان نماید و همچنین می‌توان تفاوت دو مازول<sup>۳۱</sup> متفاوت (از لحاظ هزینه) IMU را از نظر خطای رانش در کاربرد موقعیت‌یابی مشاهده نمود.<sup>[۳۸]</sup>



شکل (۷-۲) تأثیر دو مازول متفاوت IMU را از نظر خطای رانش در کاربرد موقعیت‌یابی (نمودار قمزرنگ مازول گران‌قیمت‌تری نسبت به آبی‌رنگ است)

<sup>28</sup> Inertial Measurement Unit

<sup>29</sup> Gyroscope

<sup>30</sup> Drift

<sup>31</sup> Module

## ۴-۶-۲- فناوری‌های ترکیبی

از فناوری‌های مطرح شده در بخش قبل می‌توان استفاده نمود و سیستمی ترکیبی ایجاد کرد. یکی از مزایا فناوری‌های ترکیبی این است که هر کدام از فناوری می‌توانند معاوی سایر فناوری‌ها را پوشانده و دقت و عملکرد بهتری را برای کاربر به همراه آورد. به عنوان مثال گفته شد که در سیستم‌های موقعیت‌یاب UWB هزینه راه‌اندازی بالایی نیاز است؛ اما با ترکیب این فناوری با فناوری RFID می‌توان هزینه را تا حدود زیادی کاهش داد که در ادامه این مثال بیشتر شرح داده شده است.

## ۴-۶-۱- سیستم قرکیبی RFID-UWB

سیستم‌های UWB به نسبت سایر سیستم‌های موقعیت‌یابی داخلی گران‌قیمت‌تر می‌باشند که این مورد ممکن است در کاربردهایی مانند انبارداری هوشمند که نیاز به تعداد زیادی از این فناوری باشد، مقرن به صرفه نباشد به همین منظور باهدف به کارگیری مدیریت هوشمند و درنظرگرفتن تعادل بین هزینه و دقت، یک طرح و سیستم جدید را برای سنجش کالا و آگاهی از مکان اتخاذ می‌شود. در مرجع [۳۹] از یک سمت، خواننده RFID روی لیفتراک<sup>۳۲</sup> و تگ‌های RFID را بر روی بسته بندی کالاهای می‌چسبند. خواننده RFID علاوه بر اطلاعات کالا، وضعیت بارگیری و تخلیه کالا را نیز تعیین می‌کند. از سوی دیگر، از فناوری UWB برای مکان‌یابی لیفتراک که به طور غیر مستقیم از محل کالا مطلع است، استفاده می‌شود. و به منظور کاهش هزینه از نصب تگ UWB، گران‌تر است، بر روی هر کالایی خودداری می‌شود. ساختار سیستم RFID از سه قسمت خواننده، آنتن<sup>۳۳</sup>، تگ تشکیل شده است و به منظور ترکیب دو فناوری RFID و UWB در مدیریت انبار داری هوشمند از ساختار زیر استفاده می‌توان بهره برد. در شکل زیر می‌توان نحوه قرار گرفتن اجزا سیستم موقعیت‌یابی ترکیبی را بر روی لیفتراک به صورت عملی مشاهده نمود

- (۱) تگ<sup>۳۴</sup> UHF RFID که بر روی بسته‌بندی کالا قرار می‌گیرد. هر تگ حاوی یک شماره شناسایی منحصر به فرد که نشان‌دهنده کالاهای خاص است.
- (۲) خواننده‌ها و آنتن‌های UHF RFID که برای خواندن تگ RFID بر روی لیفتراک نصب می‌شوند.
- (۳) انکر که به عنوان ایستگاه‌های پایه مرجع برای موقعیت‌یابی در بالای انبار نصب می‌شوند.
- (۴) پایانه‌های موبایل هوشمند که روی لیفتراک نیز نصب می‌شوند. پایانه شامل ۲ عملکرد است: انتقال سیگнал UWB و سنجش کالا (خواندن تگ RFID و تصمیم‌گیری در مورد بارگیری و تخلیه)

<sup>32</sup> Forklift

<sup>33</sup> Antenna

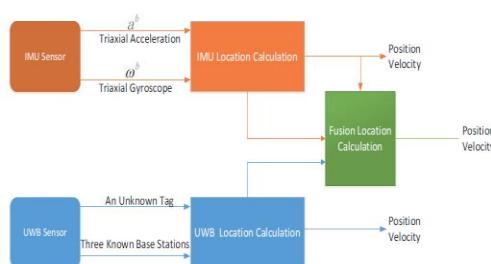
<sup>34</sup> Ultra High Frequency



شکل (۸-۲) نحوه قرارگرفتن بخش‌های متفاوت فناوری RFID بر روی نمونه عملی لیفتراک

## ۲-۶-۲ سیستم ترکیبی UWB-IMU

در بخش‌های قبل گفته شد که اصلی‌ترین عیب فناوری IMU، خطای رانش می‌باشد و همچنین گفته شد که چالش اساسی موقعیت‌یابی در محیط‌های داخلی شرایط NLoS می‌باشد. با توجه به این دو چالش در ادامه روش ترکیبی تحت عنوان IMU-UWB مورداستفاده قرار گرفته که دو چالش خطای رانش و محیط NLoS را برطرف سازد. در ابتدا معماری سیستم موقعیت‌یابی و ناوبری داخلی را بر اساس ادغام فناوری‌های IMU و UWB شرح می‌دهیم و سپس الگوریتم‌های موقعیت‌یابی مبتنی بر IMU و UWB را معرفی می‌کنیم. در شکل ۹-۲ معماری و ساختار سیستم موقعیت‌یابی داخلی را بر اساس ترکیب IMU و UWB توصیف می‌کند. حسگر IMU از یک شتاب‌سنج و ژیروسکوپ سه محوره تشکیل شده است. حسگرهای UWB از یک تگ با موقعیت ناشناخته و سه BS(انکر) با موقعیت‌های شناخته شده تشکیل شده‌اند. سیستم ترکیبی ارائه شده به این صورت عمل می‌کند که شتاب و سرعت زاویه ایی هدف موردنظر به کمک فناوری IMU اندازه‌گیری شده و همچنین موقعیت تگ نیز توسط حسگر UWB تعیین می‌شود سپس داده‌های هر فناوری از موقعیت تخمین زده شده وارد بلوک محاسبه مکان فیوژن شده و با ترکیب اندازه‌گیری‌های به دست آمده در نهایت موقعیت تخمین زده شده به عنوان خروجی این سیستم ترکیبی به دست می‌آید. در شکل زیر می‌توان نمونه مأذول ترکیبی این دو فناوری را مشاهده نمود.



شکل (۹-۲) ساختار ترکیب روش UWB و IMU

## ۷-۲- مزایای UWB

متفاوت از سایر فناوری‌های UWB به طور خاص طراحی شد تا اندازه‌گیری دقیق، ایمن و بی‌درنگ مکان را انجام دهد، در حالی که هم‌زمان از ارتباطات دو طرفه پشتیبانی می‌کند [۴۰]. نقطه قوت کلیدی این فناوری این است که فاصله بین دستگاه‌ها را از طریق زمان ورود سیگنال‌ها محاسبه می‌کند. این تفاوت ساده با سایر فناوری‌های بی‌سیم، مانند Wi-Fi و بلوتوث (که از نشانگر قدرت سیگنال دریافتی - RSSI استفاده می‌کنند) منجر به دقت دقیق‌تری می‌شود. سیگنال‌های UWB از پهنهای باند بسیار بیشتری نسبت به فناوری‌های باند باریک رایج استفاده می‌کند که منجر به سیگنال‌های کوتاه و طول موج بسیار کوتاه می‌شود پهنهای باند کanal بیشتر اجازه می‌دهد تا انرژی بیشتری به کanal منتقل شود. این نشان می‌دهد که سیگنال‌های UWB وضوح زمانی بسیار بالایی دارند (معمولًاً به ترتیب نانوثانیه) که امکان تعیین دقیق ToA را فراهم می‌کند. علاوه بر این، UWB مزایایی را با توجه به موارد زیر ارائه می‌دهد:

- نرخ انتقال داده: نرخ انتقال مؤثر بیش از ۱۰۰ مگابیت بر ثانیه را در مقایسه با بلوتوث (حداکثر ۱ مگابیت بر ثانیه) ارائه می‌دهد.
- عملکرد بالا در کanal‌های چند مسیری: به دلیل مدت زمان کوتاه پالس
- مصرف برق کم: از آنجایی که پالس‌ها فقط در درصد کمی از زمان انتقال ارسال می‌شوند، میانگین توان ساطع شده توسط فرستنده بسیار کم است (به میزان میکرووات).
- سادگی پیاده‌سازی

## ۸-۲- کاربردهای UWB

UWB به عنوان راه حلی همه‌کاره و امیدوارکننده با طیف گسترده‌ای از کاربردها در صنایع مختلف ظهر کرده است. فناوری UWB ترکیبی قانع‌کننده از دقت، مقیاس‌پذیری و قابلیت اطمینان را ارائه می‌دهد که آن را برای کاربردهای داخلی ایده‌آل می‌کند. ردیابی مؤثر افراد و دارایی‌ها را امکان‌پذیر می‌سازد و کنترل دقیق وسایل نقلیه هدایت‌شونده خودکار<sup>۳۵</sup> (AGVs) را امکان‌پذیر می‌سازد [۴۱][۴۲].

کاربردهای فناوری مبتنی بر UWB به سیستم‌های رباتیک داخلی مختلف گسترش می‌یابد که شامل وظایفی از تمیزکردن خانه تا حمل و نقل انبار می‌شود. قابل ذکر است که نقش مهمی در توسعه راه حل‌های تحویل خودکار در آخرین مایل دارد، منطقه‌ای که رشد و نوآوری سریعی را تجربه می‌کند. UWB قابلیت‌های محلی‌سازی، نقشه‌برداری و ناوبری دقیق را امکان‌پذیر می‌کند و پلتفرم‌های رباتیک را برای کارکرد مؤثر در محیط‌های داخلی

<sup>۳۵</sup> Automated guided vehicles

پویا و پیچیده توانمند می‌سازد. این برنامه‌ها با بهره‌گیری از فناوری UWB، انقلابی در نحوه عملکرد سیستم‌های رباتیک ایجاد می‌کنند و کارایی، سازگاری و عملکرد کلی آنها را افزایش می‌دهند. [۴۳]

در سال ۲۰۰۲، کمیسیون ارتباطات فدرال فناوری UWB را به عنوان زمینه امیدوارکننده و نوظهور با پتانسیل گستردگی برای پیشرفت در برنامه‌های متعدد تأیید کرد [۴۴]. این برنامه‌ها طیف گسترده‌ای از حوزه‌ها، از جمله سیستم‌های تصویربرداری، رادارهای نفوذی زمین<sup>۳۶</sup> (GPRs) را در بر می‌گیرند. سیستم‌های تصویربرداری دیواری، سیستم‌های پزشکی، سیستم‌های ناظارتی، سیستم‌های رادار و سایل نقلیه و همچنین سیستم‌های ارتباطی و اندازه‌گیری. ماهیت همه کاره فناوری UWB را برای نوآوری‌های متحول کننده در این زمینه‌ها هموار کرده است که منجر به بهبود قابلیت‌ها، افزایش کارایی و بهبود عملکرد برای انواع کاربردهای عملی می‌شود [۴۵].

UWB میتواند رویکرد برای تخمین غیرتماسی ضربان تنفس (RR)<sup>۳۷</sup> و ضربان قلب (HR)<sup>۳۸</sup> ارائه کند که کاربردی امیدوارکننده برای ثبت علائم حیاتی است. قابلیت‌های رادار UWB در نظرات دقیق بر تعداد تنفس و ضربان قلب حتی در حضور حرکت، به طور گسترده نشان داده شده است. این یافته‌ها نه تنها کارایی رادار UWB را به عنوان روشی ناظارت بر علائم حیاتی غیرتماسی تأیید می‌کند، بلکه بر کاربردهای بالقوه آن در حوزه‌های مختلف که در آن اندازه‌گیری‌های دقیق و قابل اعتماد RR و HR موردنیاز است، تأکید می‌کند. [۴۶]، [۴۷]، [۴۸]

فناوری ارتباطات UWB عامل کلیدی برای کاربردهای اینترنت اشیا است که قابلیت‌های موقعیت‌یابی دقیق را برای سناریوهای مختلف ارائه می‌دهد. UWB با سیگنال‌های پالس کوتاه خود در حوزه زمان، موقعیت‌یابی دقیق را در حالی که حداقل توان مصرف می‌کند، فراهم می‌کند. این باعث می‌شود فناوری UWB برای برنامه‌های IoT که هم مصرف انرژی پایین و هم دقت موقعیت بالا را می‌طلبند، بسیار ارزشمند باشد. [۴۹]، [۵۰].

<sup>36</sup> Ground-penetrating radars

<sup>37</sup> Respiratory rate

<sup>38</sup> Heart rate

## ۹-۲- جمع بندی

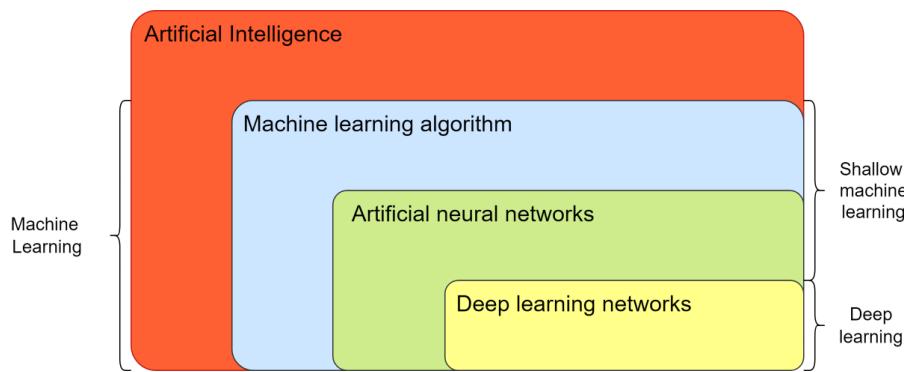
در ابتدا به بررسی انواع رویکردهای تعیین فاصله در محیط‌های داخلی پرداخته شد که این رویکردها را می‌توان تحت عنوان جدول ذکر شده با مزايا و معایب آن جمع‌بندی نمود. الگوريتم های رايچ در موقعیت‌یابی به طور خلاصه آورده شد و همچنان معيارهای تخمين موقعیت مطرح شد و همچنان به بررسی فناوری‌های موقعیت‌یابی موجود در محیط داخلی پرداخته شده که اين سيسitem را از نظر رویکرد عملکرد به دو دسته سيسitem‌های مبتنی بر RSS و مبتنی بر زمان تقسيم‌بندی شد و فناوری‌های ذکر شده را لاحظ دقت و نحوه عملکرد مورد مقایسه قرار داديم. در انتهای اين فصل نيز به ترکيب فناوری‌های مختلف موقعیت‌یابی داخلی و تأثير آن در هزينه و دقت آن پرداخته شد. سپس به اختصاص به بررسی فناوری UWB پرداختيم و از كاربردهای آن در محیط‌های واقعی بيان کردیم.

## فصل ۳: راهکارهای پیشنهادی بهبود دقت موقعیت‌یابی

### ۱-۳- مقدمه‌ای بر یادگیری عمیق

هوش مصنوعی به عنوان یکرشته دانشگاهی در سال ۱۹۵۶ بنیان‌گذاری شد. هدف در آن زمان، همانند الان این بوده است که کاری انجام شود تا کامپیوترها و ظایافی را که به طرز منحصر به فردی انسانی هستند را انجام دهند. هوش مصنوعی مفهوم ایجاد ماشین هوشمند است؛ یعنی ماشین‌های متکی به خود را بسازد که می‌تواند شبیه انسان فکر و عمل کند و به طور خلاصه رفتار انسان را تقلید نماید. به عنوان نمونه از این روش می‌توان به ماشین ترجمه گوگل و یا وسائل خودران اشاره نمود.

در حال حاضر، سیستم‌های هوش مصنوعی که قابلیت هوش مصنوعی (AI) را ارائه می‌دهند، غالب بر مبنای یادگیری ماشین (ML) و یادگیری عمیق (DL) استوار هستند. یادگیری ماشین به توانایی سیستم برای یادگیری از داده‌های آموزشی خاص، به منظور اتوماسیون فرآیند توسعه مدل‌های تحلیلی و حل وظایف مرتبط مسئله اشاره دارد. ML زیرمجموعه از هوش مصنوعی است که به دنبال یادگیری خودکار ارتباطات و الگوهای معنادار می‌باشد. یادگیری عمیق نیز به خصوص زمانی مفید است که با داده‌های بزرگ و ابعاد بالا کار می‌شود (مانند بیشتر برنامه‌هایی که نیاز به پردازش متن، سیگنال، صدا، تصویر و ویدئو دارند). قابلیت این سیستم‌ها برای حل مسائل پیچیده بر پایه مدل‌های تحلیلی است که پیش‌بینی‌ها، قوانین، پاسخ‌ها، پیشنهادها یا خروجی‌های مشابه دیگر را ایجاد می‌کنند. در چند دهه گذشته، زمینه یادگیری پیشرفتهای قابل توجهی در الگوریتم‌های پیچیده یادگیری و تکنیک‌های پیش‌پردازش کارآمد به همراه آورده است. یکی از این پیشرفتهای تکامل شبکه‌های عصبی مصنوعی (ANNs) به توبولوژی‌های شبکه عصبی عمیق‌تر با قابلیت‌های یادگیری بهتر بود که به صورت خلاصه به عنوان یادگیری عمیق خلاصه می‌شود. رابطه سلسله‌مراتبی بین تمام این اصطلاحات در شکل زیر نشان داده شده است.



شکل (۱-۳) دسته بندی شبکه های هوش مصنوعی

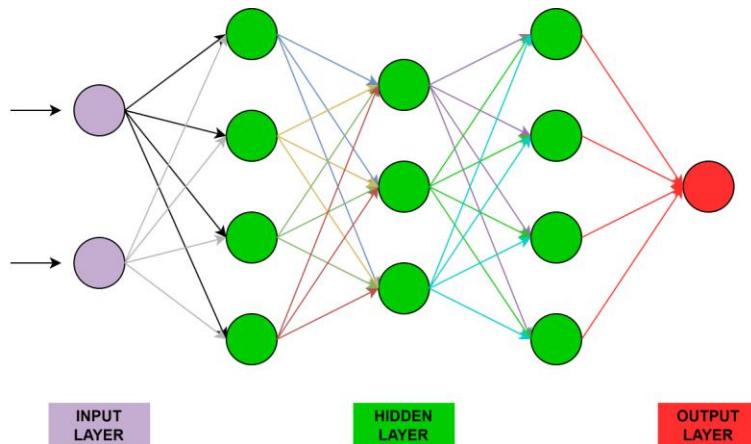
برای داشتن تمایز مفهومی بهتر، هوش مصنوعی هر روشی را شامل می‌شود که امکان می‌دهد کامپیوترها تصمیم‌گیری مشابه یا بهتر از انسان را برای حل مسائل پیچیده به تنها یی یا با دخالت کمتر انسان انجام دهند. یادگیری ماشین و یادگیری عمیق این‌گونه محدودیت‌ها را بر طرف می‌کند. به عبارت دیگر، هدف آن اتوماسیون فرآیند ساخت مدل‌های تحلیلی برای انجام وظایف شناختی؛ مانند تشخیص اشیاء یا ترجمه زبان طبیعی است. این کار با استفاده از الگوریتم‌هایی صورت می‌گیرد که به صورت تکراری از داده‌های آموزشی خاص مسئله یاد می‌گیرند که این امکان را به کامپیوترها می‌دهد تا الگوهای پنهان و پیچیده را بدون برنامه‌ریزی صریح به صورت خودکار کشف کنند [۵۱].

یادگیری عمیق زیرمجموعه ایی از یادگیری ماشین است که از داده‌های وسیع و الگوریتم‌های پیچیده برای آموزش<sup>۳۹</sup> مدل استفاده می‌کند. یادگیری عمیق درباره استفاده شبکه‌های عصبی از نورون‌ها، لایه‌ها و ارتباطات داخلی بیشتر است. DL را می‌توان با استفاده از داده‌های برچسبدار و بدون برچسب تحت نظرات و بدون نظرات قرار داد. جنبه کلیدی DL تنظیم وزن تکراری در بین هر جفت نورون است. مدل‌های DL با استفاده از مجموعه‌های بزرگی از داده‌های برچسب گذاری شده که ویژگی‌ها را مستقیماً بدون نیاز به استخراج دستی ویژگی‌ها یاد می‌گیرند، آموزش داده می‌شوند. [۵۲] در بیشتر مواقع از روش‌های یادگیری عمیق برای کاربردهایی همچون شناسایی و تشخیص اجسام استفاده می‌شود. به عنوان نمونه در مرجع [۵۳] از تکنیک یادگیری عمیق برای کاهش NLOS استفاده شده و همچنین در [۵۴] یک شبکه عصبی بازگشتی یادگیری عمیق برای مقابله با نوسانات سیگنال RSSI با بررسی همبستگی دامنه زمانی آن به کار رفته است.

الهام گرفته شده از اصل شبکه‌های عصبی زیستی که مغز حیوانات را تشکیل می‌دهند، شبکه‌های عصبی مصنوعی به عنوان نمایش ریاضی از مجموعه‌ای از واحدهای یا گره‌های متصل به نام عصب‌های (نورون‌های) مصنوعی هستند.

<sup>39</sup> Train

هر ارتباط بین عصبها مانند اتصالات سیناپسی<sup>۴۰</sup> در مغز، سیگنال‌هایی را منتقل می‌کند که قدرت آن‌ها می‌تواند توسط یک وزن که در طول فرآیند یادگیری به صورت پیوسته تنظیم می‌شود، تقویت یا ضعیف شود. شبکه‌های عصبی مصنوعی می‌توانند با توجه به لایه‌ها تفاوت کرده داشته باشند. به طور معمول می‌توان این لایه‌ها را به سه بخش تقسیم کرد: لایه ورودی که ورودی داده را دریافت می‌کند (مانند تصاویر یا سیگنال)، لایه خروجی که نتیجه نهایی را بازمی‌گرداند (مثلًاً طبقه‌بندی)، و لایه‌های مخفی که به طور مؤثر مسئول یادگیری نگاشتی غیرخطی بین ورودی و خروجی هستند (شکل ۲-۳).



شکل (۲-۳) نمونه‌ای از ساختار شبکه عصبی مصنوعی

خروجی نورون به طور معمول جمع وزن دار تمام ورودی‌ها به علاوه یک عبارت تعیین‌کننده انحراف یا بایاس است. سپس جمع وزن دار از طریق تابع فعال‌سازی (معمولًاً غیرخطی) عبور داده می‌شود تا خروجی تولید شود. تعداد لایه‌ها و نورون‌ها، همچنین پارامترهای داخلی دیگر مانند نرخ یادگیری یا تابع فعال‌سازی نمی‌توانند توسط الگوریتم یادگیری شوند. این به معنای آن است که آن‌ها پارامترهای فراپارامترهای مدل هستند که به صورت دستی و معمولاً بر اساس تجربه تعیین شوند.

شبکه‌های عصبی عمیق از شبکه‌های عصبی مصنوعی تشکیل شده‌اند که معمولاً بیش از یک لایه مخفی دارند و در ساختارهای شبکه عمیق و پیچیده‌ای سازماندهی شده‌اند. این شبکه‌ها با شبکه‌های عصبی معمول متفاوت هستند؛ زیرا شامل نورون‌های پیشرفته‌تری هستند و علاوه بر اینکه عملیات پیچیده‌تری مانند کانولوشن یا اتصالات بازگشتی را انجام می‌دهند. این ویژگی‌ها به شبکه‌های عصبی عمیق این امکان را می‌دهند که به طور خودکار اطلاعات اصلی را از ورودی استخراج کنند.

<sup>40</sup> Synapses

## ۲-۳- توابع فعالساز

تابع فعالساز با یادگیری ویژگی‌های انتزاعی از طریق تبدیلات غیرخطی، نقش بسیار مهمی در شبکه‌های عصبی ایفا می‌کنند. برخی از ویژگی‌های مشترک این توابع به شرح زیر است:

الف) جهت بهبود همگرایی آموزشی شبکه، ضروری است که انحنای غیرخطی در منظر بهینه‌سازی مورد توجه قرار گیرد ب) نباید پیچیدگی محاسباتی مدل را به طور گستردگی افزایش دهد (ج) گرادیان در طول فرآیند آموزش باید به صورت پیوسته جریان داشته باشد (د) باید توزیع داده‌ها را حفظ کند تا آموزش بهتر شبکه را تسهیل کند. در سال‌های اخیر چندین تابع فعالساز برای یادگیری عمیق باهدف دستیابی به ویژگی‌های ذکر شده مورد بررسی قرار گرفته‌اند. دیدگاه‌های توابع فعالساز مختلف به همراه استدلال برای بهره‌مندی از جامعه یادگیری عمیق ارائه می‌شود. توابع فعالساز زیادی در حال حاضر در ادبیات مقالات تعریف شده‌اند که در ادامه این بخش نمای کلی از عملکرد توابع فعالساز مورد استفاده در این پایان‌نامه ارائه می‌شود.

## ۱-۲-۳- سیگموید

به‌منظور معرفی غیرخطی‌بودن در شبکه‌های عصبی، سیگموید و تائزانت هایپربولیک به عنوان تابع فعالساز در ابتدا مورد استفاده قرار گرفته‌اند. تابع فعالساز منطقی سیگموید تابعی غیرخطی بسیار محبوب و سنتی است که به صورت زیر تعریف شده است:

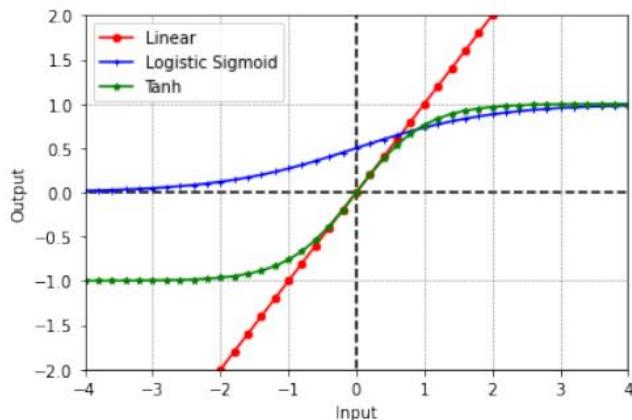
$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (1-3)$$

این فعالساز خروجی را بین ۰ تا ۱، همان‌طور که در شکل ۳-۳ نشان‌داده شده است، مقداردهی می‌کند. خروجی تابع سیگموید برای ورودی‌های بسیار بزرگ یا بسیار کوچک به حداقل یا حداقله مقدار خود می‌رسد که باعث رفع مشکل گرادیان می‌شود مشکل ناپدیدشدن گرادیان، وضعیتی است که گرادیان تابع هدف نسبت به یک پارامتر به نزدیکی صفر می‌رسد و در نتیجه، به طور تقریبی منجر به عدم به روزرسانی پارامترها در طول آموزش شبکه با استفاده از تکنیک گرادیان نزولی می‌شود. به همین دلیل، در شرایط ناپدیدی گرادیان، آموزش به طور کامل متوقف می‌شود. به علاوه، عدم پیروی خروجی از محور صفر باعث ضعف در همگرایی مدل می‌شود.

## ۲-۴- تائزانت هایپربولیک

تائزانت هایپربولیک نیز در شبکه‌های عصبی به عنوان تابع فعالساز استفاده می‌شود که شبیه به تابع سیگموید عمل می‌کند، با این تفاوت که مرکز آن در نقطه صفر قرار دارد. از شکل زیر نیز می‌توان درک نمود که تابع فعالساز

تائزانت هایپربولیک خروجی را بین  $-1$  و  $+1$  منتقل می‌نماید. اشکالات تابع سیگموید، مانند کاهش گرادیان و پیچیدگی محاسباتی، با تابع تائزانت هایپربولیک نیز وجود دارد.



شکل (۳-۳) توابع فعالساز خطی، سیگموید و تائزانت هایپربولیک

### ۳-۲-۳ واحد خطی اصلاح شده ReLU

خروجی اشباع شده و افزایش پیچیدگی، محدودیت‌های اصلی فعالسازهای مبتنی بر سیگموید و تائزانت هایپربولیک هستند. واحد خطی تصحیح شده به دلیل سادگی و عملکرد بهبودیافته، تبدیل به پیشرفته‌ترین تابع فعالساز شده است. انواع مختلف ReLU با رفع اشکالات آن، مانند عدم استفاده از مقادیر منفی، غیرخطی‌بودن محدود و خروجی نامحدود، بررسی شده است. ReLU یک تابع ساده است که تابع شناسایی برای ورودی مثبت و صفر برای ورودی منفی است و به صورت زیر تعریف می‌شود:

$$\text{ReLU}(x) = \max(0, x) = \begin{cases} x, & \text{if } x \geq 0 \\ 0, & \text{otherwise} \end{cases} \quad (2-3)$$

بنابراین، محدوده بین صفر تا بینهایت است. گرادیان ورودی‌های مثبت و منفی به ترتیب یک و صفر است. تابع ReLU مشکل پیچیدگی محاسباتی توابع سیگموید و تائزانت هایپربولیک را حل می‌کند.

### ۳-۳-۳ روش‌های یادگیری عمیق

در ادامه به بررسی دو مورد از الگوریتم‌های مورداستفاده در پایان‌نامه یعنی طبقه‌بندی و رگرسیون خواهیم پرداخت. قبل از شرح این دو مورد مناسب است که دلایل استفاده از الگوریتم‌های یادگیری عمیق می‌توان به موارد زیر اشاره نمود:

- ✓ تکنیک‌های یادگیری عمیق اغلب راه حلی فراهم می‌کنند که در آن وظیفه استخراج ویژگی به صورت خودکار انجام می‌شود و به طور ضمنی در ساختار تعییه شده است که نیاز به ویژگی‌هایی که به صورت دستی طراحی شده و یک فرآیند زمانی بر و نیازمند دانش را از بین می‌برد. این ویژگی به خصوص زمانی حیاتی است که با ویژگی‌های بُعد بالا و به سختی قابل استخراج است، روبرو هستیم.
- ✓ یادگیری عمیق به خوبی برای پردازش حجم عظیمی از داده‌های خام بهینه شناخته شده است، در حالی که در صورت نبود این حجم داده‌های بزرگ، وظیفه آموزش الگوریتم‌های یادگیری عمیق دشوار و گاهی غیرممکن خواهد بود. به عبارت دیگر، عملکرد پیش‌بینی الگوریتم‌های یادگیری عمیق با افزایش تعداد نمونه‌های آموزشی بهبود می‌یابد؛ بنابراین، هیچ محدودیت خاصی برای حجم داده‌های لازم برای آموزش الگوریتم‌های یادگیری عمیق وجود ندارد و می‌توان هر چه بیشتر داده‌های مؤثر را برای آموزش استفاده کرد.
- ✓ یادگیری عمیق برای یادگیری انتقالی مناسب است که شامل انتقال دانش از شبکه‌های پیش‌آموزش دیده به منظور کاهش جمع‌آوری داده و تلاش‌های آموزش است.
- ✓ یادگیری عمیق روشی انتخابی برای مسائل طبقه‌بندی و رگرسیون است که ماهیت مرزهای توصیف‌کننده ویژگی‌ها در فضای ورودی بسیار پیچیده و غیرخطی است. این مورد در این پایان‌نامه همین‌طور است که هدف اصلی تفکیک بین دو سیگنال خط دید مستقیم و خط دید غیرمستقیم است و همچنین از الگوریتم رگرسیون به منظور تخمین موقعیت هدف استفاده می‌شود.

### ۱-۳-۳- الگوریتم‌های دسته‌بندی

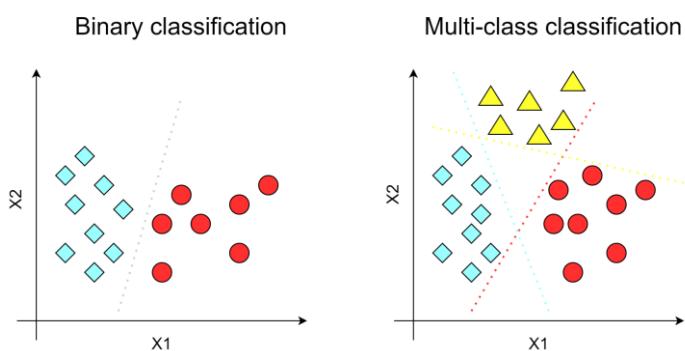
الگوریتم‌های طبقه‌بندی یا دسته‌بندی در یادگیری عمیق بخشی اساسی از یادگیری محسوب می‌شوند که بر تقسیم داده‌ها به دسته‌ها یا گروه‌های پیش تعريف شده تمرکز داردند. این شاخه از هوش مصنوعی به دنبال آموزش مدل‌هایی است که به طور خودکار برچسب‌ها را به داده‌های ورودی بر اساس الگوها و ویژگی‌های استخراج شده در فرآیند یادگیری، اختصاص دهند.

الگوریتم‌های دسته‌بندی در یادگیری عمیق از شبکه‌های عصبی با چندین لایه استفاده می‌کنند که به سیستم امکان می‌دهد نمایش‌های سلسله‌مراتبی پیچیده از داده‌ها را یاد بگیرند. این الگوریتم‌ها در پردازش حجم عظیمی از داده‌های بدون ساختار مانند تصاویر، متون و صدا عملکرد بسیار دقیقی دارند و به پیش‌بینی‌ها و طبقه‌بندی‌های بسیار دقیقی انجام می‌دهند.

با بهره‌گیری از تکنیک‌هایی مانند شبکه‌های عصبی پیچشی (CNN)، شبکه‌های عصبی بازگشتی (RNN) و معماری‌های پیشرفته‌تری می‌توانند ویژگی‌های پیچیده را از داده‌های خام یاد بگیرند که منجر به عملکرد برجسته

در وظایف مختلف طبقه‌بندی می‌شود. از طریق تکرارهای انتشار به جلو و به عقب، الگوریتم‌های طبقه‌بندی یادگیری عمیق پارامترهای خود را بهینه‌سازی می‌کنند تا خطاهای را کاهش داده و دقت در طبقه‌بندی داده‌ها به دسته‌های مختلف را افزایش دهند.

الگوریتم‌هایی که برای طبقه‌بندی دودویی (دارای دو کلاس) طراحی شده‌اند، می‌توانند با تغییراتی برای مسائل چند کلاسه استفاده شوند. این شامل استفاده از یک استراتژی برای ساخت چندین مدل طبقه‌بندی دودویی برای هر کلاس نسبت به تمام کلاس‌های دیگر یا استفاده از یک مدل برای هر زوج کلاس می‌شود.



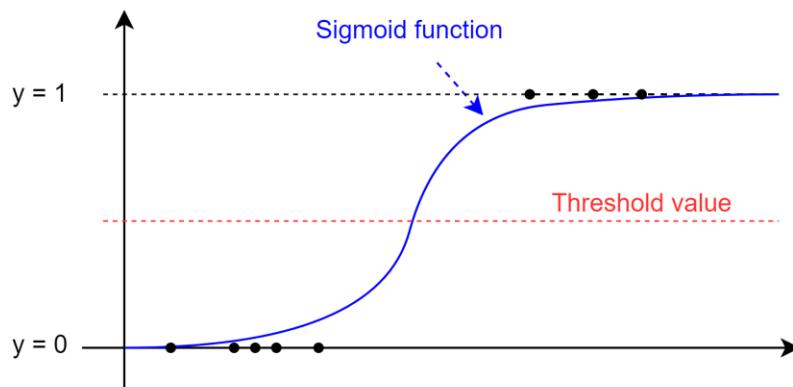
شکل (۴-۳) دسته بندی دودویی و چند کلاسه

### ۱-۱-۳-۳ طبقه‌بندی یا رگرسیون منطقی

رگرسیون منطقی<sup>۴۱</sup> (LR) یک مدل خطی و نظارت شده است که برای مسائل طبقه‌بندی استفاده می‌شود. این به این معناست که فضا می‌تواند با خط (در دو بعد)، هایپرپلین (در سه بعد) تقسیم شود. اغلب برای طبقه‌بندی دودویی استفاده می‌شود، اما به راحتی می‌توان آن را برای طبقه‌بندی چند کلاسه تطبیق داد. با استفاده ازتابع سیگموید به عنوان تابع فعال سازی، این مدل احتمال تعلق یک مورد به هر کلاس را برمی‌گرداند. سپس مورد به کلاسی با احتمال بالاتر تعلق خواهد گرفت. با توجه به اینکه خروجی رگرسیون لجستیک احتمال است، آستانه‌ای که بالاتر از آن طبقه‌بندی انجام می‌شود، متغیری بسیار مهم است.<sup>[۵۵]</sup>

به عنوان مثال، آستانه در شکل ۳-۵ برابر با  $0.5$  استفاده شده است که به معنای آن است که اگر احتمال خروجی  $P \geq 0.5$  باشد،  $y = 1$  به دست می‌آید، در غیر این صورت خروجی  $0$  است. در همین مثال اگر از مقدار آستانه‌ای برابر با  $0.2$  استفاده شود، طبقه‌بندی تغییر می‌کند.

<sup>41</sup> Logistic Regression



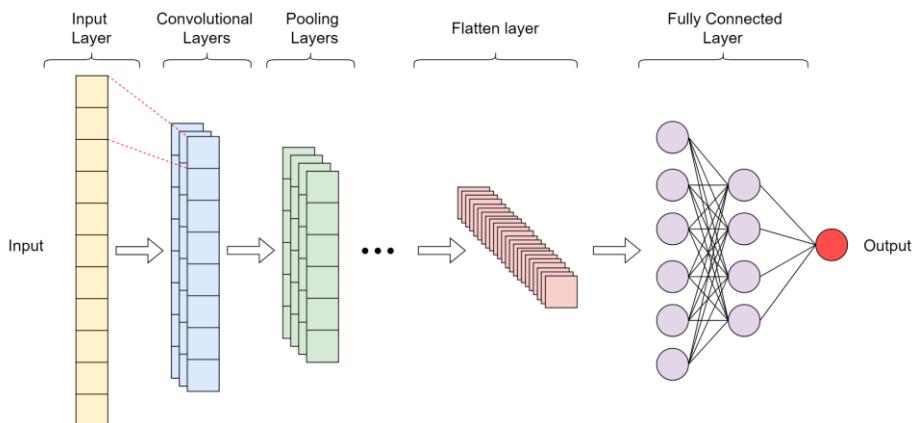
شکل (۵-۳) رگرسیون منطقی برای طبقه‌بندی دودویی

جدول (۱-۳) مزایا و معایب استفاده از رگرسیون منطقی

مزایا	معایب
سادگی پیاده‌سازی	عدم توانایی در حل مسائل غیرخطی، زیرا سطح تصمیم آن خطی است
Input نیاز به مقیاس‌دادن ویژگی‌های ورودی (features scaling)	تمایل به بیش‌پرازش (overfitting)
آسانی در تنظیم (رگولاریزاسیون)	
کارآیی محاسباتی	

### ۲-۱-۳-۳ شبکه عصبی پیچشی (CNN)

نکته مهم و مفید در مورد شبکه‌های عصبی کانولوشنال (CNN) کاهش تعداد پارامترهای موجود در شبکه‌های عصبی است. به همین دلیل از آن به طور گسترده در انواع زمینه‌های مرتبط با تشخیص الگو، پردازش زبان طبیعی، پردازش تصویر، تشخیص صدا و غیره استفاده شده است. ساختار اصلی بر پایه لایه‌های پیاپی کانولوشن و نمونه‌برداری است. سری از لایه‌های کانولوشن چندگانه از استخراج ویژگی‌های پیشرفته‌تر به صورت پیشخورنده در هر لایه انجام می‌دهند و از لایه ورودی به لایه خروجی حرکت می‌کنند. لایه‌های زیرنمونه‌برداری یا ادغام به طور معمول بین هر لایه کانولوشنی قرار می‌گیرند تا بعد مسئله را کاهش دهند. از آنجا که استفاده از CNN برای تجزیه و تحلیل سیگنال خواهد بود. نتیجه نهایی شبکه در شکل زیر به عنوان نمونه نشان‌داده شده است. برای هر لایه، عمق‌های مختلف وجود دارد که متناظر با تعداد فیلترهای اعمال شده هستند.



شکل (۶-۳) ساختار یک بعدی CNN [۵۶]

برخلاف شبکه‌های دیگر، نورون‌ها به همه نورون‌های لایه مجاور متصل نیستند که منجر به کاهش تعداد پارامترها می‌شود [۵۶]. این عوامل باعث افزایش سرعت یادگیری می‌شود و نیازهای حافظه برای شبکه را کاهش می‌دهد. طبقه‌بندی نهایی تنها توسط لایه آخر انجام می‌شود، جایی که نورون‌های بین لایه‌ها به طور کامل متصل شده‌اند. الگوریتم اصلی برای آموزش پارامترها معمولاً بازگشت رو به عقب<sup>۴۲</sup> است.

### ۳-۱-۳ شبکه عصبی تلقینی

ایده اصلی معماری تلقینی این است که در شبکه عصبی کانولوشنی، بهترین الگوهای محلی و پراکنده را کشف کند. این شبکه با استفاده از بلوک‌های فشرده و آماده‌ای که دارد، بهبود می‌آید. اصلی‌ترین موضوعی که ما به دنبالش هستیم، پیدا کردن الگوهای بهینه در جزئیات مختلف است.

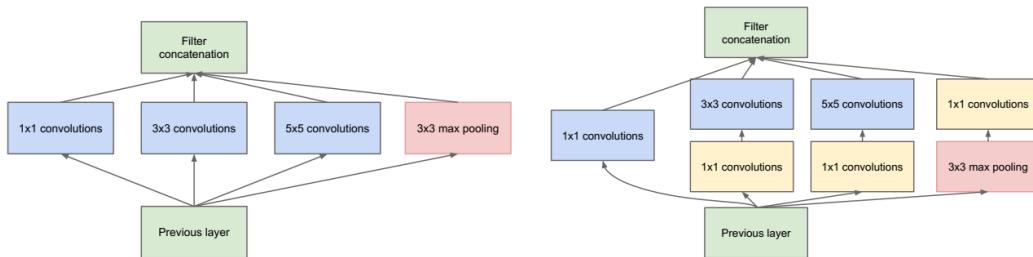
در پژوهش [۵۷] روشی ساختاری به نام "لایه به لایه" را برای تجزیه و تحلیل همبستگی بین نورون‌ها در شبکه‌های عصبی عمیق ارائه داده اند. شبکه Inception شبکه عصبی عمیق است که از بلوک‌های تکراری تشکیل شده است که خروجی یک بلوک به عنوان ورودی بلوک بعدی عمل می‌کند. هر بلوک به عنوان بلوک Inception تعریف می‌شود. انگیزه طراحی این شبکه‌ها در دو مفهوم مختلف نهفته است:

- برای مقابله با وظایف چالش برانگیز، شبکه عصبی عمیق باید بزرگ باشد، به این معنی که باید از چندین لایه و واحدهای زیادی در هر لایه تشکیل شده باشد، مشابه شبکه‌های باقیمانده<sup>۴۳</sup>.
- ویژگی‌های استخراج شده توسط شبکه‌های عصبی باید چند مقیاسی باشند به طور خاص، چشم انسان ابتدا الگوهای بصری را در مقیاس‌های مختلف شناسایی می‌کند و سپس این اطلاعات را با هم ادغام

<sup>42</sup> Backpropagation

<sup>43</sup> Residual Networks

می‌کند تا در ک سطح بالایی از جهان ایجاد کند. بنابراین، یک شبکه عصبی عمیق باید قادر به یادگیری ویژگی‌ها در مقیاس‌های چندگانه باشد. با الهام از موارد فوق، محققان شبکه‌های Inception را پیشنهاد کردند که شبکه‌های عصبی بسیار عمیقی هستند که ویژگی‌ها را در مقیاس‌های مختلف یاد می‌گیرند.



شکل (۷-۳) شبکه تلقینی، شکل سمت چپ تلقیتی از نوع naive و شکل سمت راست از نوع کاهش ابعاد است [۵۷]

بلوک‌های اصلی این شبکه به صورت زیر هستند:

- کانولوشن ۱\*۱: هدف از اعمال این کانولوشن کاهش ابعاد داده‌های ورودی با ادغام کانال است. به این ترتیب، عمق شبکه می‌تواند بدون مشکل بیش از حد برازش افزایش یابد. همچنین می‌توانیم مشاهده کنیم که به شبکه کمک می‌کند تا ویژگی‌های عمیقی را که در سراسر کانال‌های تصویر پخش می‌شوند، بیاموزد.
- کانولوشن‌های ۳\*۳ و ۵\*۵: هدف این مدل از کانولوشن‌ها یادگیری ویژگی‌های فضایی در مقیاس‌های مختلف است. به طور خاص، با استفاده از فیلترهای کانولوشنال در اندازه‌های مختلف، شبکه الگوهای فضایی را در مقیاس‌های مختلف مانند چشم انسان می‌آموزد. همانطور که می‌توانیم به راحتی درک کنیم، کانولوشن ۳\*۳ ویژگی‌ها را در مقیاس کوچک یاد می‌گیرد در حالی که کانولوشن ۵\*۵ ویژگی‌ها را در مقیاس بزرگتر یاد می‌گیرد.

به طور کلی، هر معماری اولیه شامل بلوک‌های ابتدایی فوق است که ذکر کردیم، به همراه یک لایه حداکثر تجمعی<sup>۴۴</sup> که در هر شبکه عصبی وجود دارد و یک لایه ادغام که به ویژگی‌های استخراج شده توسط بلوک‌های اولیه می‌پیوندد. در این گزارش، ما دو معماری Inception را شرح می‌دهیم که از یک معماری ساده شروع می‌شود و به معماری اصلی که نسخه بهبود یافته اولی است می‌رویم.

مطابق با شکل ۷-۳ پیاده سازی Naive این است که هر بلوک ابتدایی را در ورودی به طور جداگانه اعمال می‌کند و سپس ویژگی‌های خروجی را در بعد کانال به هم متصل می‌کند. برای این کار باید اطمینان حاصل کنیم

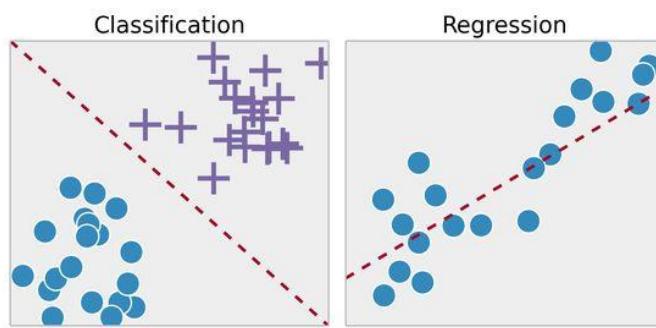
<sup>44</sup> Maxpooling

که ویژگی‌های استخراج شده دارای ابعاد عرض و ارتفاع یکسان هستند. بنابراین، ما در هر کانولوشن یک لایه را اعمال می‌کنیم.

اشکال پیاده سازی Naive، هزینه محاسباتی به دلیل تعداد زیادی پارامتر در لایه‌های کانولوشنی است. راه حل پیشنهادی استفاده از کانولوشن  $1 \times 1$  است که قادر به کاهش ابعاد ورودی و در نتیجه هزینه محاسباتی بسیار کمتر است. (شکل سمت چپ ۷-۳)

### ۲-۳-۳- رگرسیون

رگرسیون روشی است که وابستگی داده‌های داده شده با نتایج آن‌ها را تعیین می‌کند. در اینجا، رابطه بین یک متغیر وابسته و یک یا چندین متغیر مستقل را مورد مطالعه قرار می‌گیرد. استفاده اصلی از روش رگرسیون پیش‌بینی است. به عنوان نمونه وضعیت یک متغیر خاص را پیش‌بینی کنیم، مانند وضعیت هوای باتوجه به اطلاعاتی که در مورد عواملی که وابسته به هوا هستند، مانند دما، محتوای رطوبت و غیره داریم. رگرسیون به طور مداوم ابزار مهمی در اقتصاد و تجارت نیز بوده است. به عنوان مثال، می‌توان هزینه سالانه غذا بر اساس حداقل یک متغیر، مانند درآمد، پیش‌بینی کرد. معلوم است که هزینه غذا با افزایش درآمد هم افزایش می‌یابد [۵۸]. بنابراین، این می‌تواند به عنوان یک مسئله رگرسیون خطی مدل شود. افزایش تعداد متغیرهای مستقل آن را مسئله رگرسیون خطی چندگانه می‌کند.



شکل (۸-۳) مثالی از تفاوت رگرسیون و طبقه‌بندی [۵۹]

شکل ۸-۳ نمونه‌ای از رگرسیون خطی را نشان می‌دهد و نحوه عمل رگرسیون را توضیح می‌دهد، به سادگی یک خط که بهترین شکل ممکن با تمام نقاط داده‌ها همخوانی داشته باشد (ساده‌ترین نوع رگرسیون). رگرسیون بر اساس عوامل مختلفی نظیر تعداد متغیرهای مستقل و وابسته و طبیعت نمودار رگرسیون، دسته‌بندی می‌شود. انواع محبوب رگرسیون شامل: لجستیک (منطقی)، چندجمله‌ای، خطی و ریج می‌باشد.

### ۳-۲-۱ رگرسیون شبکه‌های عصبی کانولوشن

همان‌طور که در بخش طبقه‌بندی گفته شد، شبکه‌های عصبی کانولوشن ابزاری قدرتمند برای پردازش و تحلیل تصویر، بهویژه در کارهای مانند طبقه‌بندی و تشخیص اشیا هستند. با این حال، CNN همچنین می‌توانند برای وظایف رگرسیونی استفاده شوند، جایی که هدف پیش‌بینی مقدار عددی پیوسته به جای برچسب کلاس گسته است. معماری اصلی مدل رگرسیون CNN شبیه مدل طبقه‌بندی CNN است، با این تفاوت که لایه نهایی طبقه‌بندی‌کننده softmax نیست، بلکه یک لایه خطی است. لایه خطی مقداری واحد را تولید می‌کند که نشان‌دهنده مقدار پیوسته پیش‌بینی شده است [۶۰].

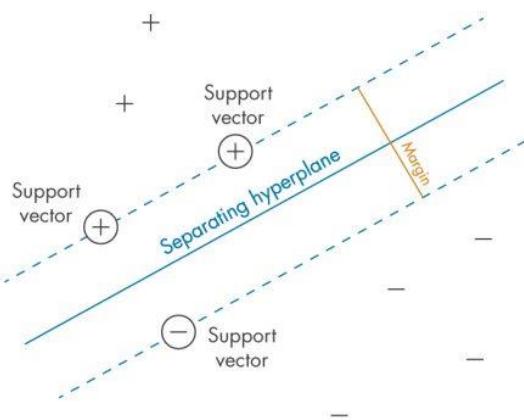
مدل‌های رگرسیون CNN با استفاده از همان الگوریتم پس انتشار که برای آموزش مدل‌های طبقه‌بندی CNN استفاده می‌شود، آموزش داده می‌شوند. با این حال، تابع هزینه متفاوت است. برای رگرسیون CNN، متداول‌ترین تابع هزینه استفاده شده، میانگین مربعات خطأ است.

### ۳-۲-۲ رگرسیون ماشین‌های بردار پشتیبان<sup>۴۵</sup>

ماشین‌بردار پشتیبانی (SVM) مدل یادگیری ماشین بسیار قدرتمند و همه‌کاره است که قادر به انجام طبقه‌بندی خطی یا غیرخطی، رگرسیون و حتی تشخیص دور<sup>۴۶</sup> است. یکی از محبوب‌ترین مدل‌ها در یادگیری ماشین است و SVM بهویژه برای طبقه‌بندی مجموعه داده‌های پیچیده؛ اما کوچک یا متوسط مناسب هستند. علی‌رغم اینکه در درجه اول الگوریتم یادگیری ماشینی تحت نظرارت است، از آن برای موارد مختلف مانند رگرسیون، طبقه‌بندی خطی و غیرخطی و حتی خوش‌بندی استفاده می‌شود [۶۱]. SVM از هسته‌هایی استفاده می‌کند که نحوه خواندن ورودی و تبدیل آن به یک فرم خاص را مشخص می‌کند. هسته‌ها به ما کمک می‌کنند تا یک ابر صفحه را در داده‌های با ابعاد بالا پیدا کنیم. این ابر صفحه دو کلاس داده را در صورت طبقه‌بندی بردار پشتیبان جدا می‌کند و در صورت رگرسیون بردار پشتیبان یک مرز تصمیم ایجاد می‌کند [۶۲]. انواع پرکاربرد هسته‌های مورداستفاده در SVM عبارت‌اند از: تابع پایه خطی، شعاعی (RBF)، چندجمله‌ای و سیگموید. اصل SVM به صورت گرافیکی در شکل ۹-۳ آورده شده است.

<sup>45</sup> Support Vector Machines

<sup>46</sup> Outlier



شکل (۹-۳) ماشین بردار پشتیبان [۶۲]

رگرسیون SVM، همچنین به عنوان رگرسیون بردار پشتیبانی (SVR) شناخته می‌شود. SVR با یافتن یک ابر صفحه که نقاط داده را در فضای ویژگی جدا می‌کند کار می‌کند. این هایپرپلین را می‌توان تغییر داد تا نقاط داده را تا حدامکان نزدیک کند و در عین حال محدودیت‌هایی را برای به حداقل رساندن خطا اعمال کند. این بردارهای پشتیبانی نقش مهمی در تعیین مرز تصمیم و پیش‌بینی مقادیر هدف دارند. رگرسیون SVM چندین مزیت را نسبت به روش‌های رگرسیون سنتی ارائه می‌دهد:

**مدیریت ارتباط غیرخطی:** SVM می‌تواند روابط غیرخطی پیچیده‌ای را بین ویژگی‌ها و مقادیر هدف ثبت کند و آنها را برای برنامه‌های کاربردی دنیای واقعی متنوع‌تر کند.

**تحمل پذیری<sup>۴۷</sup> داده پرت:** SVR در مقایسه با روش‌های رگرسیون استاندارد، حساسیت کمتری نسبت به نقاط پرت دارد، زیرا به جای تمام نقاط داده، بر بردارهای پشتیبانی تمرکز می‌کند.

**مقیاس‌پذیری:** SVM می‌تواند مجموعه داده‌های بزرگ را به طور مؤثر مدیریت کند و آنها را برای داده‌های با ابعاد بالا مناسب کند.

## ۴-۳- چالش‌های فناوری UWB

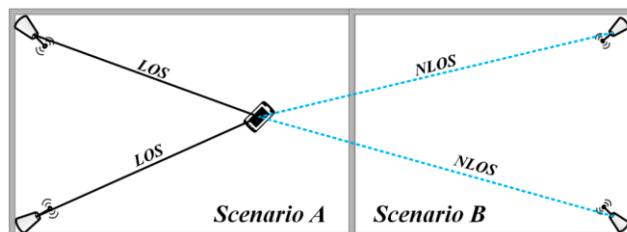
على‌رغم داشتن مزایای فراوان در موقوعیت‌های مختلف در مقایسه با سایر فناوری‌های IPS بی‌سیم، فناوری UWB مشابه با فناوری‌های موقوعیت‌یابی داخلی دارای چالش‌ها مهمی است که تعدادی از آنها در این بخش مورد بحث قرار خواهند گرفت.

<sup>۴۷</sup> Tolerance

## ۱۴-۳- خط دید غیرمستقیم

عوامل زیادی به خصوص در محیط‌های واقعی وجود دارد که می‌تواند باعث ایجاد خطاهای محدوده‌ای<sup>۴۸</sup> شود، به عنوان مثال خط دید غیرمستقیم، انتشار چند مسیری، رابط دسترسی چندگانه و وضوح بالای سیگنال‌های UWB [۶۴] شاید بتوان گفت چالش اصلی در نه تنها فناوری UWB بلکه در سایر فناوری‌های موقعیت‌یاب در سناریوهای NLOS است. بر خلاف محیط‌های سر باز که در آن می‌توان دید واضح از آسمان برای ارتباطات ماهواره‌ای را داشت، فضای بین منبع و هدف در محیط‌های داخلی اغلب توسط موادی مانند افراد، دیوارها و غیره مسدود می‌شود که این امر منجر به تعریف دو حالت مختلف که اغلب موارد در محیط‌های داخلی با آن روبرو می‌شویم را ایجاب می‌کند [۶۵]، یکی خط دیدمستقیم زمانی که مسیر بین منبع و هدف آزاد است و دومی خط غیردیدمستقیم زمانی که مسیر با مانع مسدود شده است. حالت LoS هم از نظر تغییرات قدرت(شدت) سیگنال و هم زمان انتشار نسبت به حالت NLoS بهتر است.

همان‌طور که ذکر شد NLOS به شرایطی اشاره دارد که مسیر مستقیم بین فرستنده UWB (انکر) و گیرنده (تگ) توسط اشیاء فیزیکی یا عوامل محیطی مانند عبور انسان مسدود شده و منجر به کاهش دقت مؤثر در فواصل محاسبه شده می‌شود. [۶۶] وجود شرایط NLOS به طور قابل توجهی بر عملکرد سیستم‌های UWB، به ویژه از نظر دقت و قابلیت اطمینان موقعیت‌یابی تأثیر می‌گذارد و می‌تواند منجر به خطاهای موقعیت‌یابی قابل توجهی شود. در شکل زیر می‌توان به خوبی تفاوت محیط‌های LoS و NLoS را تحت یک مثال ساده نمایش داد. [۶۷]



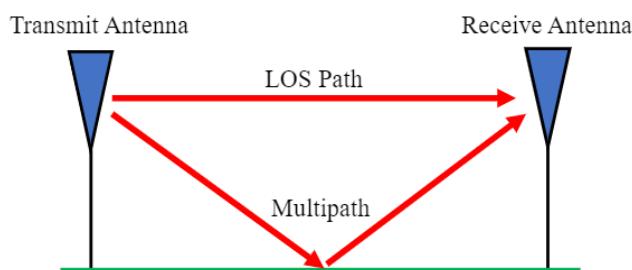
شکل (۱۰-۳) مثالی از سناریو LoS (سمت چپ) و NLoS (سمت راست) [۶۸]

انتشار چند مسیره ناشی از شرایط NLOS معمولاً منجر به تأخیر زمانی در انتشار سیگنال ارسالی می‌شود. [۶۹] و همچنین دامنه‌ی کمتر سیگنال دریافتی به دلیل حداقل تضعیف یا از دست دادن سیگنال است [۷۰]. این تضعیف می‌تواند محدوده ارتباط قابل دستیابی را محدود کند. این نرخ خطا می‌تواند ناشی عوامل متعددی شامل قرار دادن نادریق و ناکارآمد انکرهای UWB، تردد زیاد در محیط باشد و روش‌هایی مانند تکنیک‌های وزن‌دهی NLOS برای کاهش اثر تضعیف سیگنال در تحقیقات انجام شده است [۷۱].

<sup>48</sup> Ranging errors

### ۴-۴-۳-پدیده چند راهه

همان‌طور که در بخش قبل ذکر شد پدیده چند راهه در محیط‌های سرپوشیده برای تمام فناوری‌های موقعیت‌یابی رخ می‌دهد و ممکن است مانع بین هدف و منبع وجود داشته باشد و بازتاب سیگنال از سطوح موانع با سیگنال اصلی تداخل پیدا کند (توان سیگنال از دست می‌رود)، اتفاق خواهد افتاد. در مرجع [۷۲] ذکر شده که پیش‌بینی اثر پدیده چند راهه در محیط‌های سرپوشیده معمولاً دشوار است اما الگوریتم‌هایی برای تصحیح برخی از اثرات محو شدن چند راه وجود دارد که می‌تواند در جبران این پدیده سودمند باشد. برای درک بهتر این پدیده به شکل زیر توجه کنید. طبق تحقیقات صورت گرفته تاثیر این خطا به نسبت خطای NLOS در امر موقعیت‌یابی بسیار کمتر است.



شکل ۱ پدیده چند راهه [۷۳]

### ۴-۴-۳-تداخل

باتوجه به پهنای باند وسیع این فناوری پتانسیل تداخل با سایر سیستم‌های ارتباطی بی‌سیم را دارد. برای کاهش این تداخل و اطمینان از عدم ایجاد اختلال با سایر سیستم‌ها، کشورهای مختلف مقررات خاص خود را برای UWB ایجاد کرده‌اند که ماهیت مشابهی دارند. در حال حاضر، هیچ کشوری از جمله ایالات متحده، سنگاپور، ژاپن و کشورهای اروپایی اجازه استفاده از UWB را در فضای بازنمی‌دهند؛ زیرا ممکن است با سیستم‌های دیگر مانند سیستم کنترل برج فرودگاه تداخل داشته باشد [۷۴].

### ۴-۴-۴-امنیت

باتوجه به این واقعیت که اغلب، سیستم‌های موقعیت‌یابی مبتنی بر UWB در مکان‌هایی با تنظیمات ایمنی حیاتی استفاده می‌شوند [۷۵]، توسعه سیستم‌های موقعیت‌یابی ایمن UWB بسیار مهم است. سیستم موقعیت‌یابی مطلوب باید دارای چهار ویژگی باشد:

<sup>49</sup> Interference

اصالت: داده‌های مربوط به موقعیت باید منحصرأً از انکرهای موجود در محل زیرساخت و تگ‌های احراز هویت شده باشد. به عبارت دیگر منبع اطلاعات باید مورد اعتماد و تأیید آن محیط خاص باشد.

تمامیت: داده‌های مورد استفاده برای محاسبه موقعیت هدف باید از نظر محتوای داده و کیفیت سیگنال بدون تغییر باقی بماند. این اصل تضمین می‌کند که داده‌ها دقیق و بدون دستکاری باقی می‌مانند [۷۶].

محرمانه بودن: موقعیت محاسبه شده هدف باید محرمانه باشد و در معرض نهادهای غیررسمی قرار نگیرد. این ویژگی تضمین می‌کند که اطلاعات مکان حساس توسط اشخاص ثالث غیرمجاز قابل دسترسی نباشد. به عنوان مثال، هنگامی که برای ردیابی افراد استفاده می‌شود، مکان هر فرد همیشه برای سیستم شناخته شده است [۷۷].

حریم خصوصی: حضور و هویت یک دستگاه باید از دستگاه‌های مجاور که بخشی از شبکه نیستند غیرقابل تشخیص باشد. این موضوع از هرگونه نظارت یا ردیابی ناخواسته جلوگیری می‌کند [۷۸].

### ۵-۴-۳- هزینه

فناوری UWB در مقایسه با سایر سیستم‌های مبتنی بر فرکانس رادیویی پرهزینه‌تر است و هزینه تولید و نصب بالایی دارد [۷۹]. علاوه بر این، به چندین ایستگاه پایه یا انکر مشابه با فناوری موقعیت‌یابی دیگر مانند بلوتوث نیاز دارد.

### ۵-۴-۶- سایر چالش‌ها

علاوه بر چالش‌های فوق، سیستم‌های موقعیت‌یابی UWB با چالش‌هایی مانند جمع‌آوری یا اخذ سیگنال‌ها<sup>۵۰</sup> [۸۰]، UWB در برابر خطاهای ثابت زمانی ناشی از انحراف سیگنال‌ها آسیب‌پذیر است [۸۱]، برد کوتاه ارتباطی دارد [۸۲]، اگرچه سیگنال‌های UWB می‌توانند از بیشتر مصالح ساختمانی نفوذ کنند، آنها نمی‌توانند به سطوح فلزی نفوذ کنند، و تراشه‌های UWB در اکثر تلفن‌های همراه در مقایسه با WIFI یکپارچه نیستند و به سخت‌افزار اضافی در دستگاه‌های کاربر مختلف نیاز دارد که کاربردهای آن را شاید محدودتر کند [۷۱].

<sup>۵۰</sup> Signal acquisition

## فصل ۴: نتایج و تفسیر آن‌ها

### ۱-۴-۱- تجزیه و تحلیل پایگاهداده

قبل از بیان شبکه‌های عصبی استفاده شده در این پایان‌نامه، ضروری است که پیش‌دانشی از مجموعه‌داده مورداستفاده در شبکه‌سازی‌ها داشته باشیم. این مجموعه‌داده‌های محلی‌سازی UWB شامل اندازه‌گیری‌هایی از چهار محیط داخلی مختلف است. مجموعه‌داده شامل اندازه‌گیری‌هایی است که می‌تواند برای ارزیابی موقعیت‌یابی مبتنی بر محدوده در محیط‌های مختلف داخلی استفاده شود. در ادامه آن سخت‌افزار مورداستفاده در اندازه‌گیری مجموعه‌داده و پارامترهایی که در این مجموعه‌داده جمع‌آوری شده است را ذکر می‌کنیم. همچنین در نهایت در قالب یک جدول ویژگی‌های مهم این مجموعه داده استفاده شده در شبکه‌های عصبی را به طور جامع بیان نموده‌ایم.

### ۱-۱-۴- سخت‌افزار مورداستفاده برای جمع‌آوری داده

مجموعه‌داده‌ها با استفاده از برد DecaWave DWM1000 UWB با مازول رادیویی SNPN-UWB ایجاد شده است که در شکل ۱-۴ نمونه تجاری از نوع مینی<sup>۵۱</sup> این مازول قابل مشاهده است.



شکل (۱-۴) نسخه تجاری مازول DWM1000

<sup>۵۱</sup> Mini

ماژول DWM1000 مبتنی بر آی سی فرستنده گیرنده (UWB) است. آنچن، تمام مدارهای RF، مدیریت انرژی و مدارهای ساعت را در یک ماژول یکپارچه می‌کند. می‌توان از آن در سیستم‌های محدوده دوطرفه یا مکان‌یابی TDOA برای مکان‌یابی اشیا بادقت مناسب استفاده کرد و همچنین از سرعت انتقال داده تا ۶.۸ مگابیت بر ثانیه پشتیبانی می‌کند. از ویژگی‌های اساسی این ماژول می‌توان به موارد زیر اشاره نمود:

- پشتیبانی از ۴ باند RF از ۳.۵ گیگاهرتز تا ۶.۵ گیگاهرتز
- توان خروجی فرستنده قابل برنامه‌ریزی
- ولتاژ تقذیه: ۲.۸ تا ۳.۶ ولت
- سرعت داده ۱۱۰ کیلوبیت بر ثانیه، ۸۵۰ کیلوبیت بر ثانیه، ۶.۸ مگابیت بر ثانیه
- رابط SPI به پردازنده میزبان

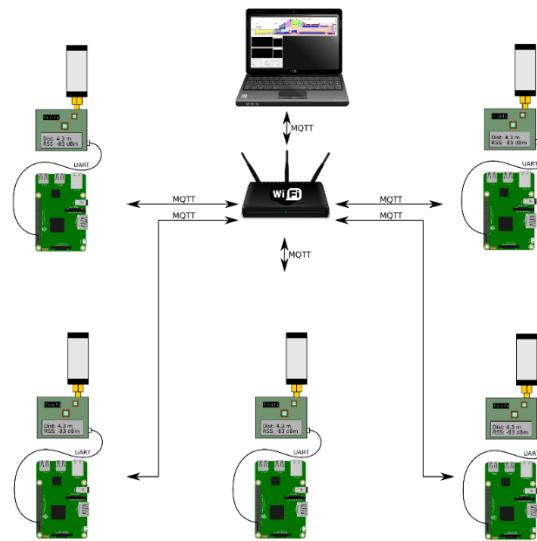
جدول (۱-۴) پارامترهای نسخه تجاری ماژول DWM1000

کانال‌های UWB	۷, ۵, ۴, ۳, ۲, ۱
آنتن یکپارچه	بله
MCU Flash(KB)	N/A <sup>۵۲</sup>
بلوتوث	خیر
حسگر حرکتی	خیر
موارد استفاده موردنظر	TDoA Tag or Anchor
تعداد تگ	1000s (TDoA)
عمر باتری	TDoA ها سال‌ها
دقت مکان‌یابی (سانتی‌متر)	15 (2D)>.20 (3D)>
ولتاژ (ولت)	۳.۶ تا ۲.۸

<sup>۵۲</sup> Not Available

## ۲-۱-۴- سیستم اندازه‌گیری

اندازه‌گیری‌ها با استفاده از ۹ عدد فرستنده-گیرنده UWB DW1000 متصل به رایانه شبکه‌شده رزبری پای<sup>۵۳</sup> با استفاده از برد رادیویی داخلی SNPN\_UWB انجام شده است. ۸ گره به عنوان گره‌های انکر محلی‌سازی با مکان‌های ثابت در محیط داخلی فردی و یک گره به عنوان برچسب محلی‌سازی متحرک استفاده شد.



شکل (۲-۴) سیستم جمع‌آوری داده [۸۳]

هر گره UWB با اتصال به رزبری پای طراحی شده است و به صورت بی‌سیم به کنترل‌کننده (به عنوان مثال لپ‌تاپ) با استفاده از فناوری‌های ارتباطی WiFi و MQTT متصل می‌شود. جمع‌آوری و ذخیره اطلاعات و درنهایت پردازش اطلاعات در این سیستم صورت می‌گیرد.

## ۲-۱-۴- توضیحات مجموعه‌داده

اندازه‌گیری‌های انجام شده در ۴ محیط مختلف داخلی زیر صورت گرفته است:

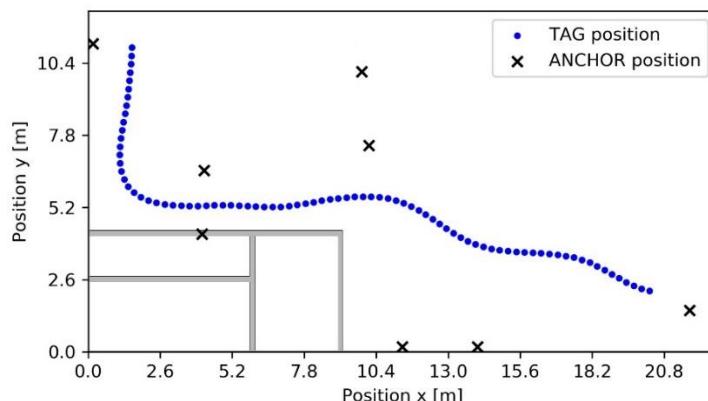
- خانه
- اداری
- آپارتمان
- صنعتی

<sup>۵۳</sup> RaspberryPi

در هر محیط به تعداد ۱۱۹۰۴۰ اندازه‌گیری داریم، با توجه به اینکه در هر محیط ۸ انکر وجود دارد، پس برای هر انکر ۱۴۸۸۰ نمونه برداری صورت گرفته است. در هر یکی از ۴ محیط داخلی فوق ذکر شده و برای هر انکر تعدادی از اندازه‌گیری‌ها در شرایط NLOS و همچنین تعدادی در شرایط LOS انجا گرفته شده است. از این مجموعه داده و ساختار فایل که در ادامه ذکر شده در ابتدا برای تشخیص نوع سیگنال و سپس برای تخمین موقعیت هدف استفاده می‌شود.

#### ۴-۱-۴- وضعیت نمونه برداری

همه موقعیت‌های تگ محلی‌سازی از قبل ایجاد شده‌اند به منظور اینکه تاحدامکان شبیه مسیر راه‌رفتن انسان باشند. همه نقاط مسیر پیاده‌روی به طور مساوی فاصله دارند تا نمونه‌های مسیر پیاده‌روی را در یک حوزه زمان نشان دهند. در شکل ۳-۴ نمونه‌ای از اندازه‌گیری موقعیت تگ در محیط داخلی وجود دارد. نقاط آبی نشان‌دهنده موقعیت تگ‌ها و صلیب‌های سیاه نشان‌دهنده موقعیت انکرهای مرجع هستند. مسیر پیاده‌روی نمونه‌برداری شده (موقعیت‌های اندازه‌گیری تگ) در فایل مجموعه‌داده‌های قابل دانلود در بخش دانلودها از مرجع [۸۳] گنجانده شده است.



شکل (۳-۴) مختصات انکرهای و مسیر حرکت تگ در دو بعد [۸۴]

#### ۵-۱-۴- فرمت داده‌ها

اندازه‌گیری‌ها در پرونده‌های به فرمت CSV ذخیره می‌شوند. هر فایل با یک سرتیفتر<sup>۵۴</sup> شروع می‌شود که در آن خط اول نسخه فایل و خط دوم نشان‌دهنده نام ستون داده‌ها که مرتبط با ویژگی‌های مجموعه داده است. عنوان ستون‌های موجود در فایلهای CSV به ترتیب از ستون چپ به راست عبارت‌اند از:

- TAG\_ID - ANCHOR\_ID - X\_TAG - Y\_TAG - Z\_TAG

<sup>54</sup> Header

- X\_ANCHOR - Y\_ANCHOR - Z\_ANCHOR - NLOS - RANGE
- FP\_INDEX - RSS - RSS\_FP - FP\_POINT1 - FP\_POINT2 - FP\_POINT3
- STDEV\_NOISE - CIR\_POWER - MAX\_NOISE - RXPACC
- CHANNEL\_NUMBER - FRAME\_LENGTH - PREAMBLE\_LENGTH - BITRATE
- PRFR - PREAMBLE\_CODE - CIR

بدون درنظر گرفتن ستون‌های CIR در مجموع ۲۶ ستون در هر فایل اکسل اندازه‌گیری‌ها داریم و همچنین به تعداد اندازه‌گیری‌ها برای هر محیط و انکر، سطر در هر فایل اکسل وجود دارد.

#### ۶-۱-۴- متغیرهای مورد استفاده از مجموعه‌داده

در جدول ۴-۴ می‌توان پارامترهای مهم که در ادامه پایان‌نامه موردنیاز می‌باشد رو به همراه توضیحات آن در جدول زیر مشاهده نمود (ویژگی پاسخ ضربه کanal در بخش بعد آورده شده است):

جدول (۴-۴) پارامترهای مهم نسخه تجاری مازول DWM1000

پارامترهای نسخه تجاری DWM1000	توضیحات
تعداد نمونه	تعداد نمونه‌ها در قالب هر سطر فایل اکسل بیان شده است و برای هر ۴ محیط به میزان یکسان یعنی ۱۱۹۰۴۰ تعداده جمع‌آوری شده است.
موقعیت تگ	موقعیت تگ در این مجموعه‌داده در سه بعد (x,y,z) مورد بررسی قرار گرفته است. با سه سرتیتر X_TAG - Y_TAG - Z_TAG در مجموعه‌داده نشان‌داده شده است.
موقعیت انکر	در این مجموعه‌داده از ۸ انکر با موقعیت‌های متفاوت در هر ۴ محیط استفاده شده است. موقعیت هر انکر با سر تیتر X_ANCHOR - Y_ANCHOR - Z_ANCHOR در سه بعد بیان شده است.
فاصله	فاصله را تحت عنوان RANGE ذکر شده و تخمین محدوده بر اساس برآورد ToA مقدار RSS، سطح نویز و مجموعه ایی از CIR است.
NLOS	یکی از مهم‌ترین ویژگی‌های مهم در این پایان‌نامه است. در حالتی که شرایط LOS وجود داشته باشد مقدار "۰" و در حالتی که NLOS باشد مقدار "۱" را نشان میدهد که به عنوان خروجی شبکه عصبی در نظر گرفته می‌شود.

## ۴-۲-۴- پاسخ ضربه کانال<sup>۵۵</sup> (CIR)

پاسخ ضربه کانال (CIR) مفهومی اساسی در ارتباطات و پردازش سیگنال است که نحوه ارسال سیگنال از طریق کانال ارتباطی را توصیف می‌کند. می‌توان گفت نوعیتابع ریاضی است که نشان‌دهنده پاسخ کانال به پالس یا ضربه کوتاه است. CIR معمولاً به صورت دنباله‌ای از مقادیر نشان داده می‌شود که مربوط به لحظه‌های زمانی مختلف است. هر ضربه نشان‌دهنده دامنه و مرحله پاسخ کانال در آن لحظه است. CIR را می‌توان با استفاده از انواع مختلف تجهیزات، از جمله اسیلوسکوپ، تحلیلگر شبکه و ژنراتور سیگنال اندازه‌گیری کرد. انتخاب تجهیزات به محدوده فرکانس، پهنای باند و سایر مشخصات کانال بستگی دارد. هنگامی که CIR اندازه‌گیری شد، می‌توان از آن برای تجزیه و تحلیل ویژگی‌های کانال، مانند پاسخ فرکانسی، تضعیف و اعوجاج آن استفاده کرد [۸۵].

در اینجا به تعداد ۱۰۱۶ نمونه برداری از پاسخ ضربه کانال گرفته شده است. مقادیر CIR0-CIR1015 که در مجموعه داده ذکر شده است نشان‌دهنده دامنه و فاز پاسخ کانال در ۱۰۱۶ لحظه زمانی مختلف است. یعنی CIR کانال را با دقت بسیار بالا اندازه‌گیری شده است. مقادیر CIR0-CIR1015 را می‌توان برای محاسبه انواع خواص کانال، مانند گسترش تاخیر، گسترش داپلر<sup>۵۶</sup> [۸۶] و پاسخ فرکانسی استفاده کرد. از این اطلاعات می‌توان برای طراحی سیستم‌های ارتباطی و بهینه سازی عملکرد آنها استفاده کرد. به عنوان مثال، مقادیر CIR0-CIR1015 را می‌توان برای طراحی اکولایزرها برای کاهش اثرات انتشار چند مسیری یا طراحی فیلترهایی برای رد تداخل استفاده کرد.

لحظه‌های زمانی که برای اندازه‌گیری CIR کانال استفاده می‌شود به برنامه خاص بستگی دارد. به عنوان مثال، اگر در حال طراحی سیستم ارتباطی برای محیط تلفن همراه هستیم، ممکن است نیاز باشد CIR را با سرعت بالایی اندازه‌گیری نماییم تا شرایط کانال در حال تغییر را ردیابی نماییم. در شکل زیر می‌توان بخشی از نمونه داده‌های CIR مجموعه داده مورد استفاده را مشاهده نمود.

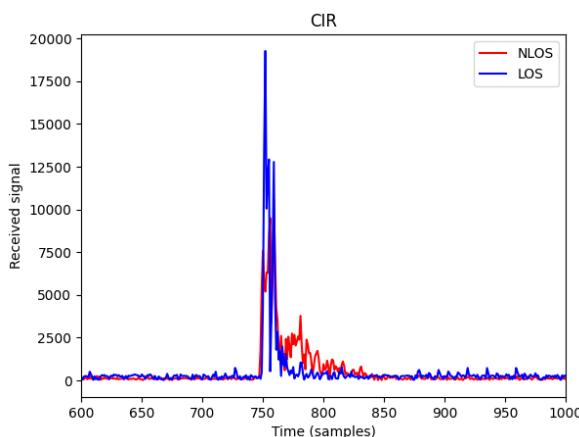
(482-213j)	(123-246j)	(237-608j)	(199-89j)	(108+9j)	(33+175j)	(-226-29j)	(-91-404j)	(319+221j)
(-74-251j)	(-138-28j)	(-353-236j)	(59+11j)	(-154-47j)	(-358-234j)	(10+137j)	(133+13j)	(224-57j)
64j	(90+52j)	(68+126j)	(-4-53j)	(-127+69j)	(-105+284j)	(-296-181j)	(-62-76j)	(43+49j)
(241-219j)	(33+19j)	(138+15j)	(16+469j)	(-89+57j)	(134+35j)	(255+278j)	(501+184j)	(-26-74j)
(247+34j)	(387+229j)	(-254+198j)	(-35-137j)	(241+97j)	(483+141j)	(504-199j)	(8+118j)	(20+83j)
(197-294j)	(70-427j)	(503-65j)	(163+206j)	(-178+82j)	(-77-250j)	(149-252j)	(204-225j)	(63-104j)
(51-97j)	(9+111j)	(142-493j)	(77-43j)	(88+64j)	(141+214j)	(-22-111j)	(-71-304j)	(113-495j)
(79+71j)	(157+225j)	(-244+167j)	(-118+162j)	(-142+443j)	(-285-94j)	(-91-70j)	(252-227j)	(432+92j)
(75+12j)	(204+246j)	(-49+227j)	(-482+248j)	(-86+0j)	(11+660j)	(-196+84j)	(-95-15j)	(-229+119j)
(180-205j)	(12+34j)	(241-183j)	(121+34j)	(61+12j)	(38+364j)	(152+616j)	(507+194j)	(-96-90j)
(25+71j)	(236-149j)	(3+88j)	(60+41j)	(145+199j)	(-193+213j)	(-189+446j)	(-216+548j)	(-211+105j)

شکل (۴-۴) برشی از داده‌های پاسخ ضربه کانال

<sup>۵۵</sup> Channel Impulse Response

<sup>۵۶</sup> Doppler spread

برای دو نمونه اندازه‌گیری شده تصادفی از پاسخ ضربه کanal در دو شرایط مختلف یعنی حالت خط دید مستقیم و خط دید غیرمستقیم می‌توان پاسخ ضربه کanal را مشاهده نمود.



شکل (۵-۴) پاسخ ضربه کanal برای دو سیگنال LOS و NLoS

همان‌طور که از شکل فوق واضح است مقدار دامنه سیگنال NLoS مطابق با انتظار به نسبت LOS میزان بسیار کمتری دارد به عبارت دیگر می‌توان گفت به دلیل وجود مانع بین فرستنده و گیرنده یعنی حالت NLOS مقدار دامنه کمتری از لحظه اندازه در گیرنده بدست می‌آید. توجه به اینکه ضروری است که صرفاً از روی پاسخ ضربه کanal نمی‌توان متوجه شد که سیگنال LOS یا NLOS می‌باشد چرا که شاید یکی از دلیل کمبودن دامنه در پاسخ ضربه کanal دورتر بودن فاصله گیرنده از فرستنده است و بر عکس.

### ۳-۴- پیش‌پردازش داده‌های ورودی

پیش‌پردازش داده‌های ورودی یک مرحله مهم در تحلیل داده و یادگیری شبکه‌های عصبی است که شامل تمیزکردن، تبدیل، و تجهیز داده‌های ورودی برای مدل‌های یادگیری می‌شود. داده‌های ورودی بی‌کیفیت می‌توانند منجر به نتایج نادرست و بی‌دقیقت در مدل‌های یادگیری و همچنین کاهش شدید سرعت آموزش شبکه شوند. پیش‌پردازش داده‌های ورودی می‌تواند به بهبود دقیقت و قابلیت اطمینان مدل‌ها کمک کند. این مرحله می‌تواند شامل چندین گام مختلف باشد. این گام‌ها به ترتیب عبارت‌اند از:

- پاکسازی داده‌ها: پاکسازی داده‌ها شامل شناسایی و تصحیح خطاهای در داده‌ها مانند داده‌های گم شده، داده‌های نادرست و داده‌های پرت است.
- تبدیل داده‌ها: تبدیل داده‌ها شامل تغییر فرمت داده‌ها برای سازگاری با نیازهای مدل است. به عنوان مثال، داده‌های متنی ممکن است نیاز به تبدیل به مقادیر عددی یا دسته‌ای داشته باشند.

- استخراج ویژگی: استخراج ویژگی شامل شناسایی و حذف ویژگی‌های نامربوط یا غیرمفید از داده‌ها است که می‌تواند به بهبود دقت و سرعت مدل کمک کند.
- متعادل‌سازی داده‌ها: متعادل‌سازی داده‌ها شامل تنظیم توزیع داده‌ها برای کاهش اثر داده‌های ناهموار است.

### ۱-۳-۴-پاکسازی داده‌ها

باتوجه به مجموعه داده ای که در اختیار داریم و بر اساس نوع داده، تغییرات آنها و همچنین نتایج شبیه‌سازی در این بخش می‌توان گفت، تعدادی از ستون‌های مجموعه داده، شامل ANCHOR\_ID, TAG\_ID, CHANNEL\_NUMBER، داده‌های اثر انگشت مانند RSS\_FP و FP\_POINT، همچنین پارامترهای نویز، PREAMBLE\_CODE، BITRATE، FRAME\_LENGTH و غیره است. موارد ذکر شده نه تنها باعث افزایش حجم پایگاه داده شده بلکه سرعت و دقت شبکه را نیز کمتر می‌کند و به همین منظور مجموعه داده اصلاح شده فاقد این ستون‌ها است.

### ۲-۳-۴-تبديل روی داده‌های CIR

همان‌طور که در بخش قبل هم ذکر شد، پاسخ ضربه کانال ویژگی‌های کانال ارتباطی، معمولاً در سیستم‌های ارتباطی بی‌سیم را نشان می‌دهد. CIR می‌تواند هر دو اطلاعات دامنه و فاز سیگنال را داشته باشد. با این حال، هنگامی که از این داده‌ها به عنوان ورودی برای مدل شبکه، به ویژه شبکه‌های عصبی یا سایر مدل‌های یادگیری استفاده شود، دلایل متعددی وجود دارد که نشان می‌دهد اندازه (دامنه) این اعداد مختلط مفیدتر می‌باشد:

- ✓ ساده‌سازی داده‌ها: شبکه‌های عصبی عموماً با ورودی‌های اعداد حقیقی به خوبی کار می‌کنند و داده‌های حقیقی برای پردازش شبکه آسان‌تر است.
- ✓ ابعاد کاهش‌یافته: اعداد مختلط حاوی اطلاعات دامنه و فاز هستند و به طور مؤثر ابعاد را در مقایسه با اعداد حقیقی دوبرابر می‌کنند. با استفاده از دامنه، ابعاد داده‌های ورودی کاهش داده می‌شود و به خصوص اینکه اطلاعات فاز در شبکه تشخیص سیگنال NLOS تأثیرگذار نیست. همچنین با توجه به اینکه تعداد ستون‌های ویژگی پاسخ ضربه (۱۶×۱۰) به عنوان ورودی های شبکه می‌باشد پس با استفاده از اندازه آن می‌توان حجم فایل مجموعه داده را به میزان قابل توجهی کاهش داد و سرعت اجرای آموزش را افزایش داد.

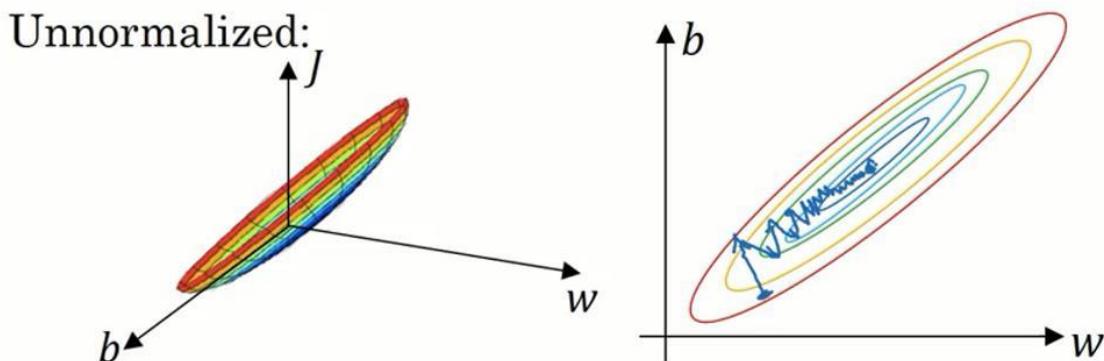
### ۳-۳-۴- استانداردسازی داده‌های CIR

گام بعد استانداردسازی یا نرم‌الیزه ورودی‌ها یعنی اندازه پاسخ ضربه کanal بخش قبل است. استانداردسازی داده‌ها مرحله ای ضروری در بهبود پایداری و عملکرد آموزش شبکه‌های عصبی است، در ادامه برخی از دلایل کلیدی استانداردسازی داده‌ها آورده شده است:

۱. جلوگیری از ناپایداری عددی: شبکه‌های عصبی بر الگوریتم‌های بهینه سازی مبتنی بر گرادیان تکیه می‌کند، که می‌تواند در برخورد با ویژگی‌های ورودی که مقیاس‌های بسیار متفاوتی دارند، ناپایدار شوند. استانداردسازی ورودی تضمین می‌نماید که یک ویژگی خاص تاثیرگذاری شدیدی در مرحله آموزش نداشته باشد.
۲. بهبود مقدار اولیه وزن: مقادیر اولیه وزن‌ها در شبکه عصبی می‌تواند به طور قابل توجهی بر همگرایی و عملکرد آن تأثیر بگذارد. استانداردسازی داده‌های ورودی تضمین می‌کند که وزن‌ها به محدوده‌ای اولیه‌سازی می‌شوند که برای توابع فعال‌سازی مورداستفاده در شبکه مناسب است و منجر به یادگیری پایدار و کارآمدتر می‌شود.
۳. کاهش بایاس<sup>۵۷</sup> در بهروزرسانی وزن: شبکه‌های عصبی با به روز رسانی وزن‌های خود بر اساس گرادیان‌های تابع می‌آموزند. اگر ویژگی‌های ورودی دارای مقیاس‌های متفاوتی باشند، گرادیان‌ها نیز مقیاس‌های متفاوتی خواهند داشت که می‌تواند منجر به بهروزرسانی وزن دارای بایاس شود. استاندارد کردن داده‌های ورودی تضمین می‌کند که همه گرادیان‌ها در مقیاسی مشابه هستند، و از تسلط هر ویژگی منفرد بر بهروزرسانی‌های وزن و بهبود فرآیند کلی یادگیری جلوگیری می‌کند.
۴. همگرایی سریعتر: استاندارد کردن داده‌های ورودی می‌تواند به شبکه‌های عصبی کمک کند تا سریعتر به راه حلی بهتر همگرا شوند، به این دلیل است که شبکه نیازی به تنظیم وزن‌های خود برای تطبیق با مقیاس‌های مختلف ویژگی‌های ورودی ندارد [۸۷].
۵. کاهش حساسیت به نقاط پرت: نقاط پرت، داده‌ای هستند که به طور قابل توجهی از بقیه داده‌ها منحرف می‌شوند، می‌توانند بر عملکرد شبکه‌های عصبی تأثیر منفی بگذارند. استانداردسازی داده‌های ورودی با نزدیکتر کردن آنها به میانگین، به کاهش تأثیر نقاط پرت کمک می‌کند و شبکه را نسبت به حضور آنها کمتر حساس می‌کند.

<sup>۵۷</sup> Bias

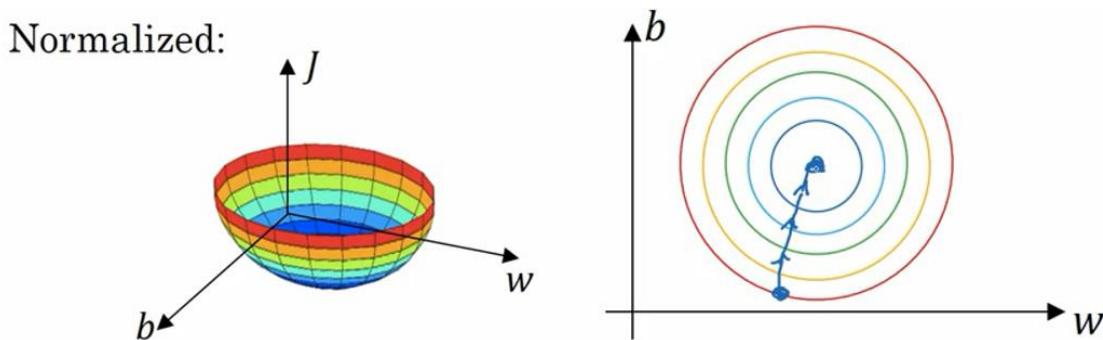
اگر ویژگی‌ها (ورودی‌ها) از نظر مقیاس با یکدیگر متفاوت باشند، به عنوان مثال ویژگی  $x_1$  از ۱۰۰۰ و ویژگی  $x_2$  از ۰ تا ۱ مقادیری داشته باشند، در این صورت نسبت یا محدوده مقادیر پارامترهای  $w$  و  $b$  مقادیر بسیار متفاوتی خواهد داشت. اما نمودار  $w$  و  $b$ ،تابع هزینه می‌تواند به شکل ۶-۴ بخش سمت چپ داشته باشد.



شکل (۶-۴) تابع هزینه و همگرایی پارامترهای یادگیری به ازای ورودی‌های بدون نرمالیزه شده

اگر در حال اجرای کاهش گرادیان در یک تابع هزینه مانند آنچه در شکل بالا سمت چپ هستیم، ممکن است لازم باشد از یک نرخ یادگیری بسیار کوچک استفاده کنیم تا به مقدار بهینه پارامترهای  $w$  و  $b$  (مرکز کمترین مقدار تابع هزینه را دارد) با نوسانات بالا نزدیک شویم.

در حالی که اگر منحنی کروی شکل داشته باشیم (به دلیل نرمالیزه کردن ویژگی‌های ورودی)، کاهش گرادیان می‌تواند مستقیماً به حداقل برسد یعنی بتوان گام‌های بزرگ‌تری برداشت تا با نوسانات کمتری به مقدار بهینه تابع هزینه دست یافت . (در شکل‌های این بخش بهمنظور ترسیم تابع هزینه فرض بر اسکالر بودن  $w$  و  $b$  می‌باشد در حالی که در اغلب مسائل  $w$  و  $b$  بردارهایی با بعد بالا هستند).



شکل (۷-۴) تابع هزینه و همگرایی پارامترهای یادگیری به ازای ورودی‌های نرمالیزه شده

تنها با تنظیم ورودی شبکه به میانگین صفر و واریانس یک، تضمین می‌شود که همه ویژگی‌های در مقیاسی مشابه هستند و در بیشتر اوقات به الگوریتم یادگیری کمک می‌کند تا سریع‌تر اجرا شود. به عنوان اثبات این موضوع برای

شبکه عصبی تک‌لایه مخفی برای ورودی CIR و خروجی NLOS مطابق با نتایج به‌دست‌آمده شبیه‌سازی، در حالتی که شبکه از داده‌های ورودی نرمالیزه شده استفاده می‌کند، زمان اجرای کد به میزان ۶ برابر نسبت به حالت استفاده از ورودی بدون نرمالیزه شده سریع‌تر اجرا شده و هم‌چنین دقت برای ورودی‌های نرمالیز شده نیز بالاتر بدست آمده است. به همین دلیل داده‌های پاسخ ضربه کانال برای آموزش شبکه و همچنین آزمون به صورت نرمالیزه شده به شبکه‌های عصبی که در ادامه معرفی می‌شود، اعمال می‌شود.

## ۴-۴- سخت‌افزار شبیه‌سازی

باتوجه‌به اینکه در بخش نتایج گزارش پایان‌نامه در مورد زمان اجرای شبکه صحبت به عمل آمده است، ذکر ویژگی‌ها و مدل سخت‌افزاری سیستم مفید خواهد بود. به منظور انجام شبیه‌سازی‌ها و پیاده‌سازی الگوریتم‌های یادگیری عمیق در این پایان‌نامه، از یک سیستم کامپیوتوری با سخت‌افزار شامل پردازنده Intel i7-4720HQ با فرکانس ۲.۶ گیگاهرتز، همراه با یک کارت گرافیک GeForce GTX 960M و حافظه RAM با ظرفیت ۸ گیگابایت استفاده شده است. همچنین حافظه داخلی این سسیتم از نوع SSD با ظرفیت ۵۱۲ گیگابایت برای ذخیره‌سازی داده‌های موردنیاز در طول اجرای شبیه‌سازی‌ها بوده است. این ترکیب از سخت‌افزارها، توان محاسباتی و گرافیکی لازم برای اجرای موثر الگوریتم‌های پیچیده یادگیری عمیق و شبیه‌سازی‌های پیچیده را فراهم نمود و در بهبود دقت و قابلیت اعتماد نتایج شبیه‌سازی و پژوهش‌های انجام شده در حوزه یادگیری عمیق و فناوری UWB بسیار کارآمد بوده است.

## ۴-۵- تفکیک شرایط LOS و NLOS از یکدیگر

همان‌طور که در بخش قبل گفته شد، یکی از راه‌های تشخیص سیگنال LOS و NLOS از یکدیگر استفاده از داده‌های پاسخ ضربه کانال است. اما صرفاً با استفاده از دامنه CIR نمی‌توان به طور قطعی اظهار کرد که در شرایط LOS یا NLOS سیگنال دریافت شده است. به همین منظور پژوهشگران در این باره راهکارهایی را برای تفکیک این دو شرایط ارائه نموده‌اند. به عنوان مثال فوهو چه<sup>۵۸</sup> و همکاران در مرجع [۸۸] تشخیص شرایط NLoS با استفاده از توزیع گاوی مبتنی بر ویژگی و الگوریتم‌های GD تعیین‌یافته مورد بررسی قرار داده اند، که از ویژگی‌های استخراج شده از داده‌های سیگنال دریافتی برای طبقه‌بندی دقیق بین سیگنال‌های NLoS و LoS استفاده می‌کند. به عنوان پژوهشی دیگر آقای کیم<sup>۵۹</sup> و همکاران در تحقیق [۸۹] با ایجاد یک سیستم هیبریدی<sup>۶۰</sup> که فناوری‌های UWB و PDR<sup>۶۱</sup> را ترکیب می‌کند، به چالش‌های موقعیت‌یابی داخلی پرداخته اند. این سیستم ترکیبی از یک

<sup>58</sup> Fuhu Che

<sup>59</sup> Dae-Ho Kim

<sup>60</sup> Hybrid system

<sup>61</sup> Pedestrian Dead Reckoning

روش ادغام<sup>۶۲</sup> مبتنی بر فیلتر کالمن برای شناسایی و کاهش اثر محیط‌های NLOS استفاده می‌کند که منجر به بهبود عملکرد موقعیت‌یابی، بهویژه در سناریوهای NLOS، در مقایسه با موقعیت‌یابی تنها می‌شود.

الگوریتم‌های یادگیری عمیق، روش‌های جدید و قدرتمندی برای شناسایی NLOS و LOS هستند. این الگوریتم‌ها می‌توانند به طور خودکار ویژگی‌های مهم سیگنال‌های NLOS و LOS را یاد بگیرند و از این ویژگی‌ها برای شناسایی نوع ارتباط استفاده کنند. در این بخش از پایان‌نامه، از روش‌های یادگیری عمیق برای تفکیک این شرایط بهره برده شده است. الگوریتم‌های یادگیری عمیق مزایای متعددی نسبت به روش‌های سنتی شناسایی NLOS و LOS دارند که به طور خلاصه می‌توان به چهار دیدگاه مورد بررسی قرار بگیرد:

- دقت: یادگیری عمیق در شناسایی الگوهای پیچیده در داده‌ها برتر است. در سناریوهایی که تمایز بین موقعیت‌های NLOS و LOS به دلیل شرایط پیچیده محیطی یا تغییرات سیگنال چالش‌برانگیز است، مدل‌های یادگیری عمیق، می‌توانند به طور مستقل یاد بگیرند و ویژگی‌های مربوطه را از داده‌های خام استخراج کنند.
- سرعت: الگوریتم‌های یادگیری عمیق می‌توانند به طور قابل توجهی سریع‌تر از روش‌های سنتی عمل کنند. علاوه بر این، یادگیری عمیق با مجموعه داده‌های بزرگ رشد می‌کند. با توجه به تنوع در شرایط محیطی، قدرت سیگنال و موانعی که بر موقعیت‌های NLOS و LOS تأثیر می‌گذارند، داشتن داده‌های متنوع و فراوان این مدل‌ها را قادر می‌سازد تا در سناریوهای مختلف بهتر تعمیم پیدا کنند.
- انعطاف‌پذیری: الگوریتم‌های یادگیری عمیق می‌توانند برای شناسایی NLOS و LOS در شرایط و محیط‌های مختلف تنظیم شوند. به جای تکیه بر ویژگی‌های دست‌ساز، مدل‌های یادگیری عمیق می‌توانند به صورت خودکار از ویژگی‌های مربوطه از داده‌های ورودی در محیط‌های متمایز استفاده کنند.
- سازگاری: نقطه قوت دیگر در سازگاری مدل‌های یادگیری عمیق با انواع مختلف داده‌های ورودی نهفته است. چه تصاویر، حسگرهای متفاوت اطلاعات متنی و یا سیگنال‌های متفاوت که مدل‌های یادگیری عمیق می‌توانند این منابع متنوع را به طور مؤثر مورد بررسی قرار دهند.

## ۱-۵-۴- ساختار شبکه عصبی کانولوشنال

CNN ساختاری لایه‌ای سازماندهی شده است. هر نورون در یک لایه کانولوشنی تکی دارای زمینه محلی مخصوص خود (برش اختصاصی) از ورودی است. از چندین نورون منفرد تشکیل شده است که به صورت عمودی در مجموعه وزن‌های مختلف سازماندهی شده‌اند تا ویژگی‌های مشابه ورودی را استخراج کنند. وزن یک نورون با تمام نورون‌ها

<sup>62</sup> Fusion

در یک لایه، یکسان است. همه نورون‌های لایه، مجموعه‌ای از خروجی‌هایی به نام نقشه ویژگی<sup>63</sup> تولید می‌کنند که به لایه بعدی ارسال می‌شود.

تابع فعال ساز برای هر نورون منفرد در ساختار CNN پیشنهادی تابع نورون خطی اصلاح شده است. ReLU مقدار مناسبی از غیرخطی بودن سیستم را فراهم می‌کند و محاسبه آن آسان و سریع است. همچنین عملکرد واقعی CNN را در مقایسه با توابع فعال سازی پیچیده‌تر، مانند سیگموئید یا Tanh تحت تأثیر قرار نمی‌دهد.

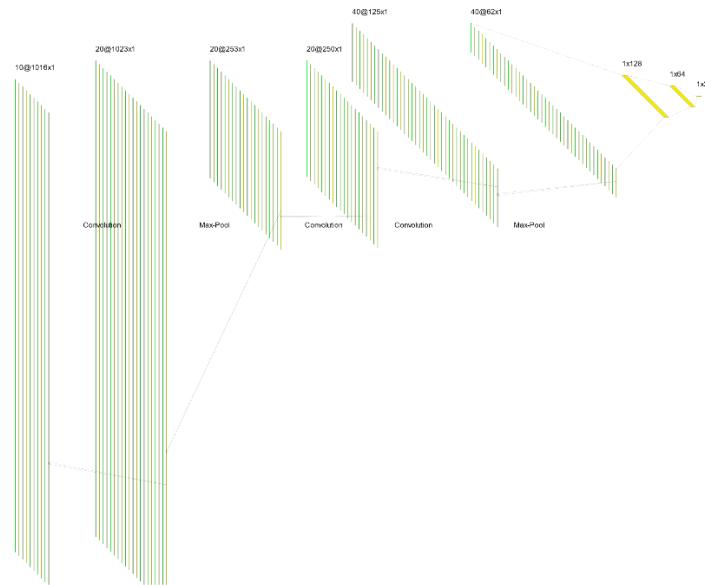
همان‌طور که در فصل گذشته اشاره شد، یکی از لایه‌های کاربردی در شبکه‌های عصبی کانولوشنی، لایه ادغام است که برای کاهش اثرات ویژگی‌های شناسایی شده از داده‌های خروجی لایه قبل، از نمونه‌برداری استفاده می‌کند. در اینجا، تابع کاهش max pooling به کار گرفته شده است که بیشترین مقدار موجود در هر پنجره از داده‌ها را انتخاب کرده و آن را به لایه بعدی منتقل می‌کند. اندازه پنجره ادغام ورودی را مشخص می‌کند که با استفاده از آن، کاهش ابعاد ویژگی‌های ورودی انجام می‌شود. اگر عرض پنجره ادغام ۲ و اندازه گام<sup>64</sup> ۲ باشد، max pooling دو مقدار ورودی را انتخاب می‌کند و پنجره ادغام برای دو مقدار ورودی در یک‌زمان جایه‌جا می‌شود. در چنین حالتی، ابعاد ورودی به میزان نصف کاهش می‌یابد.

بعد از مراحل لایه‌های کانولوشنی و ادغام، دولایه کاملاً متصل به عنوان آخرین مراحل اعمال می‌شوند. این دولایه که ترکیبی از لایه‌های کانولوشنی و لایه‌های کاهش ابعاد هستند، به عنوان نوعی پیش‌پردازش خودکار برای ورودی‌ها عمل می‌کنند که به جای روش‌های سنتی استخراج ویژگی‌ها از داده استفاده می‌شود. این لایه‌ها وظیفه استخراج خودکار ویژگی‌ها را برای لایه عصبی کاملاً متصل دارند. لایه کاملاً متصل شامل تمامی نورون‌ها با تمام خروجی‌های آخرین لایه کانولوشنی است. در نهایت در لایه خروجی، با استفاده از تابع فعال‌ساز سیگموئید یا softmax خروجی باینری بدست می‌آید.

ساختار شبکه CNN پیشنهادی را می‌توان در شکل زیر مشاهده کرد:

<sup>63</sup> Feature map

<sup>64</sup> Stride



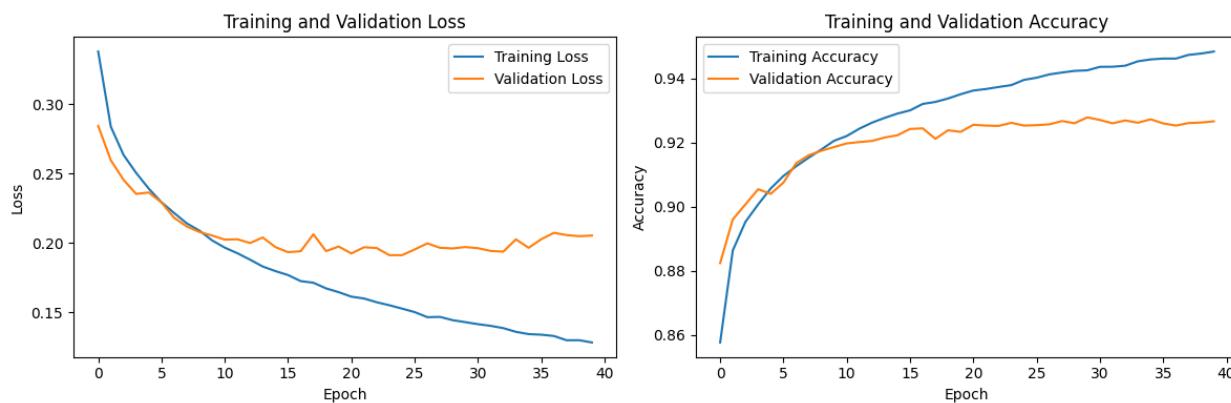
شکل (۸-۴) ساختار شبکه عصبی کانولوشنال پیشنهادی

همچنین جزئیات مقادیر پارامتری شبکه پیشنهادی از جمله تابع فعالساز، تعداد نورون‌ها، فیلتر و... را می‌توان به طور جامع در جدول زیر مشاهده نمود:

جدول (۳-۴) جزئیات ساختار شبکه CNN پیشنهادی

Layer Type	Operation
Conv1D (10 filters, size 4, ReLU)	Conv1D(10, 4, activation='relu', padding='valid')
Conv1D (20 filters, size 5, stride 2, ReLU)	Conv1D(20, 5, activation='relu', padding='same', strides=2)
MaxPooling1D (pool size 2, stride 2)	MaxPooling1D(pool_size=2, strides=2, padding='valid')
Conv1D (20 filters, size 4, ReLU)	Conv1D(20, 4, activation='relu', padding='valid')
Conv1D (40 filters, size 4, stride 2, ReLU)	Conv1D(40, 4, activation='relu', padding='same', strides=2)
MaxPooling1D (pool size 2, stride 2)	MaxPooling1D(pool_size=2, strides=2, padding='valid')
Flatten	Flatten
Fully Connected (128 neurons)	Dense(128, activation='relu')
DropOut (50%)	DropOut(0.5)
Fully Connected (64 neurons)	Dense(64, activation='relu')
DropOut (50%)	DropOut(0.5)
Output (2 neurons, softmax)	Dense(2, activation='softmax')

نتایج شبیه‌سازی که در ادامه آورده شده است، از ساختار جدول ۳-۴ آورده شده است با این تفاوت که در استفاده از DropOut دو مقدار ۰.۵ و ۰.۸ اتخاذ شده است. در حالتی که مقدار ۰.۵ برای شبکه عصبی کانولولوشنی استفاده شده به نتایج ۹-۴ دست پیدا می‌کنیم. مطابق با شکل ۹-۴ پس از دوره ۲۰ تابع ضرر حوالی مقداری ثابت باقی می‌ماند و همچنین از نمودار دقت نیز این مورد قابل مشاهده است که پس از دوره ۲۰ میزان دقت آزمون ثابت و حدود ۹۲ درصد را دارد است در حالی که دقت آموزش ۹۵ درصد است. پس می‌توان گفت بعد از دوره ۲۰ اختلاف دقت آزمون و آموزش را داریم که دائما در حال افزایش است و منجر به بیش برآذش خواهد شد.



شکل (۹-۴) دقت و تابع ضرر مدل برای شبکه CNN با  $\text{DropOut} = 0.5$

همچنین ماتریس سردرگمی<sup>۶۵</sup> در این شبکه نیز در شکل ۱۰-۴ آورده شده است. ماتریس سردرگمی ابزار مفید برای ارزیابی عملکرد الگوریتم یادگیری است که معمولاً برای الگوریتم‌های طبقه‌بندی استفاده می‌شود. این ماتریس جدول دو بعدی است که در آن هر سطر نشان‌دهنده کلاس واقعی (Actual Class) و هر ستون نشان‌دهنده کلاس پیش‌بینی شده (Predicted Class) است.

در پیش‌بینی شبکه عصبی، ماتریس سردرگمی می‌تواند برای ارزیابی عملکرد شبکه در طبقه‌بندی نمونه‌های داده استفاده شود. این ماتریس می‌تواند اطلاعاتی در مورد میزان دقت، صحت، حساسیت و ویژگی شبکه ارائه دهد.

هر سلول در ماتریس سردرگمی نشان‌دهنده تعداد نمونه‌هایی است که در کلاس واقعی و کلاس پیش‌بینی شده قرار دارند. به عنوان مثال، سلول در گوش بالا سمت چپ ماتریس تعداد نمونه‌هایی را نشان می‌دهد که در کلاس واقعی "۰" قرار دارند و در کلاس پیش‌بینی شده نیز "۰" قرار دارند. که در اینجا کلاس "۰" همان شرایط LOS است.

عناصر ماتریس سردرگمی به شرح زیر تعریف می‌شوند:

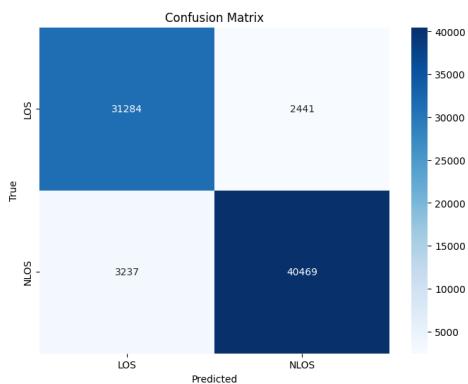
<sup>۶۵</sup> Confusion matrix

True Positive: تعداد نمونه‌هایی که در کلاس واقعی "۱" قرار دارند و در کلاس پیش‌بینی شده نیز "۱" قرار دارند.

True Negative: تعداد نمونه‌هایی که در کلاس واقعی "۰" قرار دارند و در کلاس پیش‌بینی شده نیز "۰" قرار دارند.

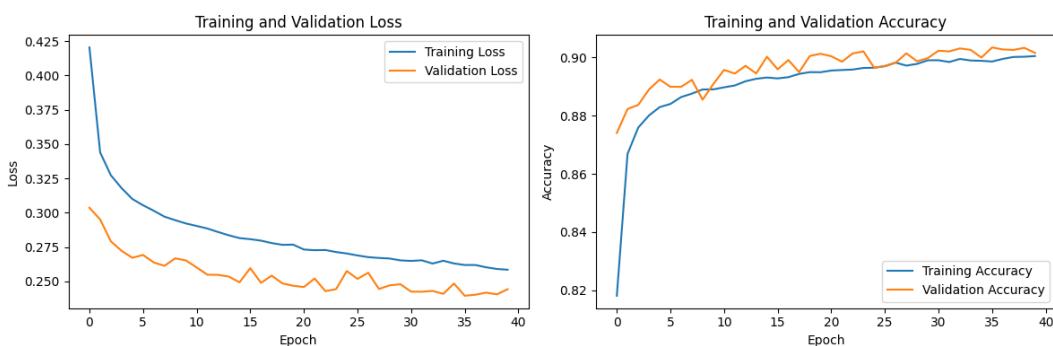
False Positive: تعداد نمونه‌هایی که در کلاس واقعی "۰" قرار دارند و در کلاس پیش‌بینی شده "۱" قرار دارند.

False Negative: تعداد نمونه‌هایی که در کلاس واقعی "۱" قرار دارند و در کلاس پیش‌بینی شده "۰" قرار دارند.



شکل (۱۰-۴) ماتریس سردرگمی برای شبکه عصبی CNN با  $\text{DropOut} = 0.5$

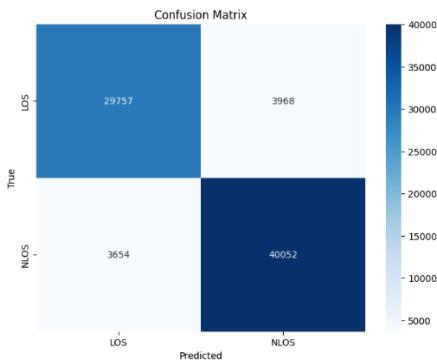
به منظور بررسی تأثیر DropOut و کاهش بیش برازش مدل مقدار آن را از ۰.۵ به ۰.۸ تغییر داده که به نتایج شکل زیر دست پیدا می‌کنیم. همانطور که از نمودار تابع ضرر شکل ۱۱-۴ مشخص است میزان تابع ضرر از دوره ۳۰ به بعد تقریباً ثابت مانده همچنین دقت آزمون نیز با دقت آموزش به میزان تقریباً یکسانی رسیده و حدود ۹۰ درصد می‌باشد که به نسبت دقت شبکه CNN قبل کمتر است اما از بیش برازش آن نیز جلوگیری شده است.



شکل (۱۱-۴) دقت و تابع ضرر مدل برای شبکه عصبی CNN با  $\text{DropOut} = 0.8$

همچنین ماتریس سردرگمی را نیز برای این شبکه در شکل ۱۲-۴ آورد که می‌توان با شبکه قبل مقایسه نمود. به عنوان مثال در حالتی که شرایط LOS می‌باشد در شبکه قبل ۲۴۴۱ پیش‌بینی اشتباه بوده و این شرایط را

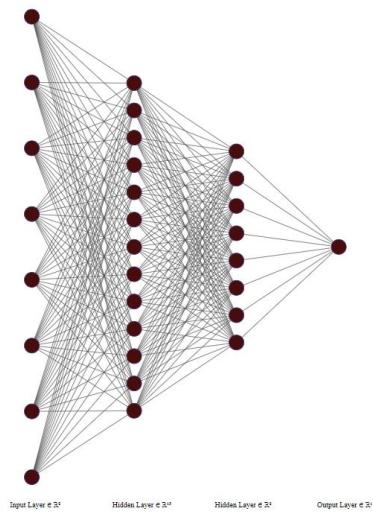
NLOS پیش‌بینی نموده؛ اما برای این شبکه این میزان به مقدار ۳۹۶۸ مورد رسیده است که مطابق با نتایج نمودار دقیق شکل ۱۱-۴ است.



شکل (۱۲-۴) ماتریس سردرگمی برای شبکه عصبی CNN با  $\text{DropOut} = 0.8$

## ۲-۵-۴- ساختار شبکه عصبی پیشخور

شبکه‌های عصبی از لحاظ ساختار می‌توانند به صورت گسترده و متنوعی طراحی شوند، اما معماری مرسوم و پراستفاده در این زمینه، شبکه عصبی پیشخور<sup>۶۶</sup> است. این نوع شبکه در ساختار افقی بوده و دادها از لایه ورودی به سمت لایه خروجی جریان می‌یابند بدون این که اطلاعات به سمت عقب حرکت کنند. در شکل زیر ساختار اصلی شبکه عصبی پیشخور را به عنوان نمونه مشاهده می‌کنید:



شکل (۱۳-۴) نمونه ساختار شبکه عصبی پیشخور با دو لایه مخفی

<sup>۶۶</sup> Feedforward Neural Network

ساختار شکل ۱۳-۴، از یک لایه ورودی، دولایه مخفی و یک لایه خروجی تشکیل شده است. این ساختار در پایان‌نامه مشابهت دارد تنها در تعداد لایه‌های مخفی و همچنین نورون‌ها در این لایه‌ها تفاوت وجود دارد. در لایه‌های زیر برای مجموعه‌داده توضیحات مختصری داده شده است:

### لایه ورودی

لایه ورودی، مجموعه‌داده‌های ورودی را دریافت می‌کند. این داده‌ها می‌توانند به صورت اعداد، رشته‌ها یا تصاویر باشند. تعداد نورون‌های لایه ورودی با تعداد ویژگی‌های داده‌های ورودی برابر است. به عنوان مثال، اگر داده‌های ورودی شامل دو ویژگی باشند، لایه ورودی باید دو نورون داشته باشد. در اینجا ورودی شبکه مشابه با بخش قبل پاسخ ضربه‌های کانال که برای هر اندازه‌گیری ۱۰۱۶ ویژگی را دارد.

### لایه پنهان

لایه پنهان، مجموعه‌داده‌های ورودی را پردازش معمولاً با استفاده از یک تابع فعال‌سازی انجام می‌شود. همان‌طور که در بخش قبل ذکر شده تابع فعال‌سازی، مقدار خروجی هر نورون در لایه پنهان را تعیین می‌کند. در این بخش پایان‌نامه برای تمامی لایه‌های پنهان از تابع فعال‌ساز RELU استفاده شده است.

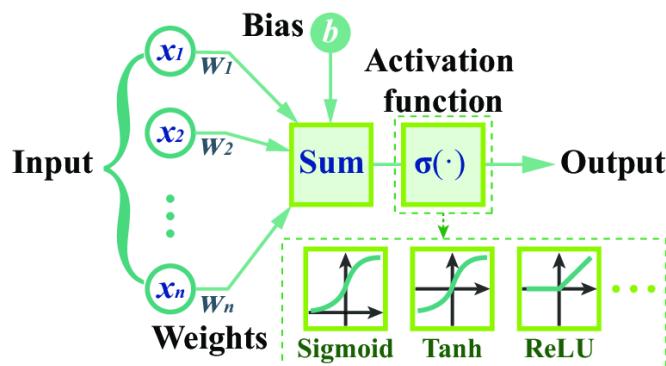
### لایه خروجی

لایه خروجی، مقدار خروجی شبکه عصبی را تولید می‌کند. تعداد نورون‌های لایه خروجی با تعداد کلاس‌های موردنظر برابر است. در این بخش به توجه به این نکته که خروجی از دو نوع صفر و یک هست، پس در لایه آخر یک نورون با تابع فعال‌ساز سیگموید قرار گرفته شده است.

### انتشار روبه‌جلو<sup>۶۷</sup>

در انتشار روبه‌جلو، اطلاعات از لایه ورودی به لایه پنهان و سپس به لایه خروجی منتقل می‌شود. در لایه پنهان، هر نورون با استفاده از تابع فعال‌سازی، مقدار خروجی خود را محاسبه می‌کند. سپس، مقدار خروجی هر نورون در لایه پنهان به عنوان ورودی برای نورون‌های بعدی در لایه پنهان استفاده می‌شود. این فرآیند تا زمانی که به لایه خروجی برسیم، ادامه می‌یابد. در لایه خروجی، مقدار خروجی هر نورون، احتمال قرار گرفتن داده ورودی در کلاس مربوطه را نشان می‌دهد. نورون با بیشترین مقدار خروجی، کلاس موردنظر را تعیین می‌کند.

<sup>۶۷</sup> Forward propagation

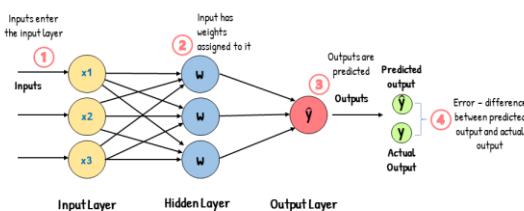


شکل ۲ مرحله انتشار روبه‌جلو [۹۰]

### ۶۸ انتشار روبه‌عقب

در انتشار روبه‌عقب، خطاهای مدل محاسبه می‌شوند. خطاهای، تفاوت بین مقدار خروجی واقعی و مقدار خروجی پیش‌بینی شده توسط شبکه عصبی هستند. سپس، این خطاهای برای بهروزرسانی وزن‌های شبکه عصبی استفاده می‌شوند. بهروزرسانی وزن‌ها، باعث بهبود عملکرد شبکه عصبی در پیش‌بینی می‌شود.

### Feed-Forward Neural Network



شکل (۱۴-۴) مرحله انتشار روبه‌عقب [۹۱]

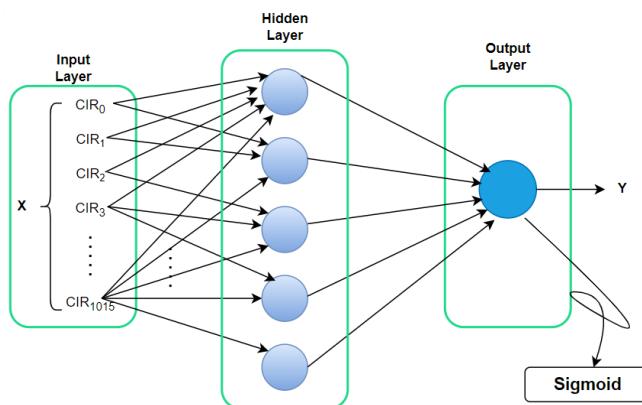
### ۴-۵-۱-۲ ساختار شبکه عصبی پیشنهادی

به منظور مقایسه نتایج ساختار شبکه عصبی پیشخور با یکدیگر از ساختار متفاوتی استفاده شده است. همچنین موارد زیر ثابت در اجرای این شبکه‌ها ثابت فرض شده‌اند:

- تابع هزینه
- توابع فعالساز
- سیستم‌عامل اجرای شبیه‌سازی

<sup>68</sup> Back propagation

ساختار شبکه عصبی تک لایه زیر برای یک شبکه تک لایه مخفی فرض شده، مشابه با همین ویژگی تعداد لایه‌های مخفی و نورون‌ها می‌توان افزایش داد و لایه‌های ورودی و خروجی ثابت می‌مانند.



شکل (۱۵-۴) شبکه عصبی پیشخور با ورودی پاسخ ضربه

#### ۶۹-۲-۲-۵-۴ هایپرپارامترها<sup>۶۹</sup>

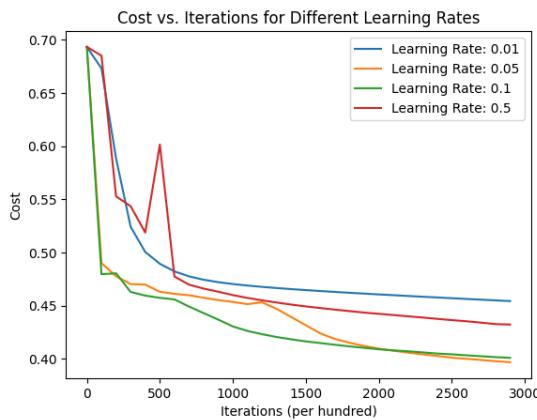
همان‌طور که در پژوهش‌ها به اثبات رسیده است، انتخاب صحیح هایپرپارامترها در شبکه عصبی، می‌تواند به بهبود عملکرد و سرعت شبکه کمک کند. با این حال، انتخاب هایپرپارامترها، فرآیندی تجربی است و مقدار بهینه هایپرپارامترها برای هر مسئله متفاوت است. مطابق به بخش قبل که به بررسی چندین هایپرپارامتر پرداختیم در این بخش نیز به بررسی موارد زیر می‌پردازیم. توجه شود که هایپرپارامتری مانند تابع هزینه هم می‌تواند در این بخش آورده شود که با فرض انتخاب ثابت تابع هزینه شبیه‌سازی‌ها صورت گرفته است. هایپرپارامترها را موارد زیر تشکیل می‌دهند:

- تعداد لایه‌های مخفی
- نرخ یادگیری
- تعداد نورون‌ها
- تعداد تکرار شبکه
- الگوریتم بهینه‌ساز

که مطابق با نتایج شبیه‌سازی و مواردی که تحقیقات و مقالات معتبر به ثبت رسیده، مقدار نرخ یادگیری بیشترین تأثیر را در دقت و سرعت اجرای شبکه را دارد. به همین منظور در ابتدا برای این موضوع شبکه را به‌ازای نرخ

<sup>۶۹</sup> Hyper Parameters

یادگیری متفاوت اجرا کرده که به نتیجه زیر دست یافته‌ایم و پس از اجرای آن با توجه به نتایج نرخ یادگیری مقدار ثابت ۰.۰۵ فرض می‌شود.



شکل (۱۶-۴) نمودار تابع هزینه برای نرخ یادگیری‌های متفاوت

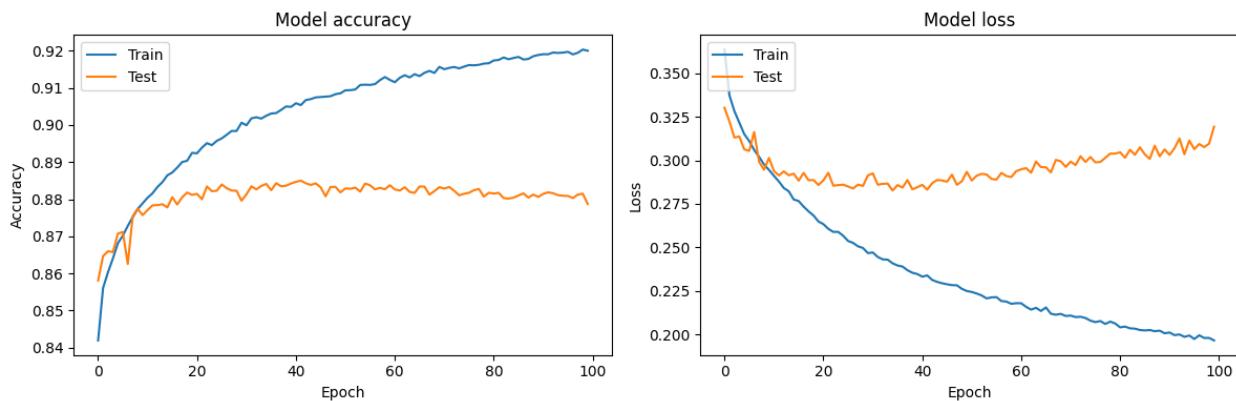
در نهایت جزئیات شبکه عصبی پیشخور در نظر گرفته شده برای شبیه‌سازی را می‌توان در جدول ۴-۴ مشاهده نمود:

جدول (۴-۴) ساختار شبکه عصبی پیشخور

عنوان شبکه	تعداد لایه‌های مخفی	تعداد نورون‌ها در لایه مخفی	الگوریتم‌های بهینه‌ساز
شبکه عصبی نوع ۱	۱	[۱۲۸]	Adam,SGD
شبکه عصبی نوع ۲	۱	[۲۵۶]	Adam,SGD
شبکه عصبی نوع ۳	۱	[۵۱۲]	Adam,SGD
شبکه عصبی نوع ۴	۳	[۲۵۶ ۱۲۸ ۶۴]	Adam,SGD

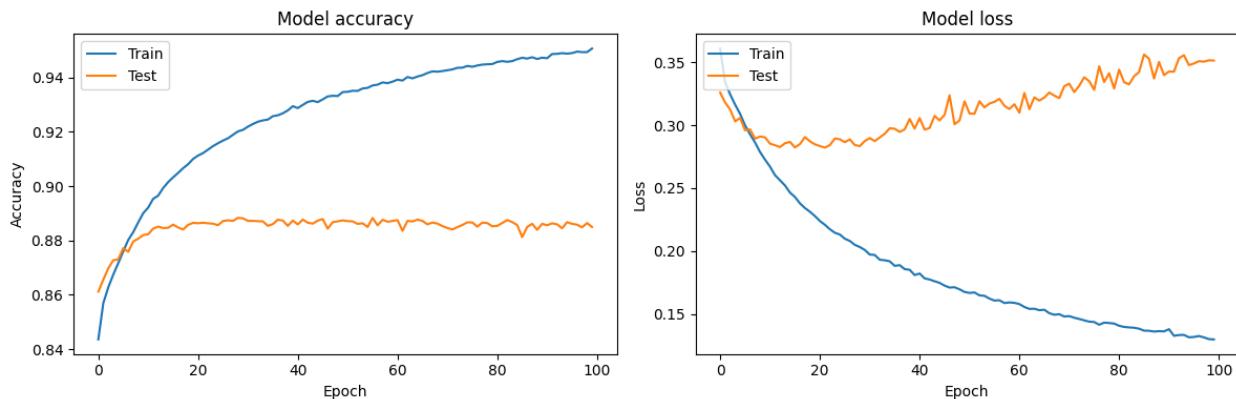
در این بخش می‌توان نتایج این ۴ مدل شبکه عصبی پیشخور را با هدف دسته بندی شرایط NLOS/LOS مشاهده نمود توجه شود که در شبیه‌سازی‌های صورت گرفته تعداد نورون‌ها و لایه‌های مخفی تغییر داده شده است. این شبکه بر روی مجموعه داده‌ای از ۱۰۱۶ ویژگی آموزش داده شد و توانست به دقت حدود ۹۲ درصد در داده‌های آموزشی و ۸۸ درصد در داده‌های آزمایشی دست یابد. این مدل همچنین مشکل بیش برآذش جزئی را نشان می‌دهد، زیرا تلفات آموزشی همچنان کاهش می‌یابد در حالی که مدل ضرر آموزش بعد از دوره ۶۰ شروع به افزایش می‌کند. دلیل بیش برآذش میتواند این باشد که مدل برای مجموعه داده، بسیار پیچیده است و شروع به

خاطر سپردن آموزش می‌کند. همچنین این نکته حائز اهمیت است که در بیشتر شبکه‌های عصبی پیشخور مشکل بیش برآش رخ میدهد.



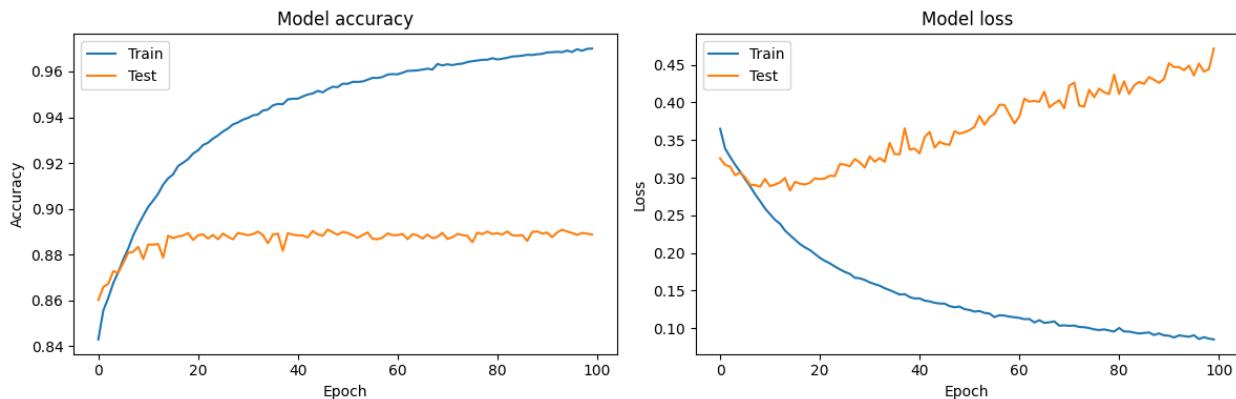
شکل (۱۷-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۱

برای شبکه عصبی نوع ۲ نیز موضوع بیش برآش با وجود استفاده از  $\text{DropOut}=0.5$  رخ میدهد و این مقدار نسبت به شبکه عصبی نوع ۱ بیشتر است. می‌توان گفت در شبکه عصبی نوع ۲ تنها دقت آموزش مقدار بیشتر یعنی حدود ۹۵ درصد دارد و دقت آزمون همان مقدار را دارد و از دوره ۳۰ به بعد نه تنها مدل تابع ضرر کاهش پیدا نکرده بلکه افزایش هم داشته است.



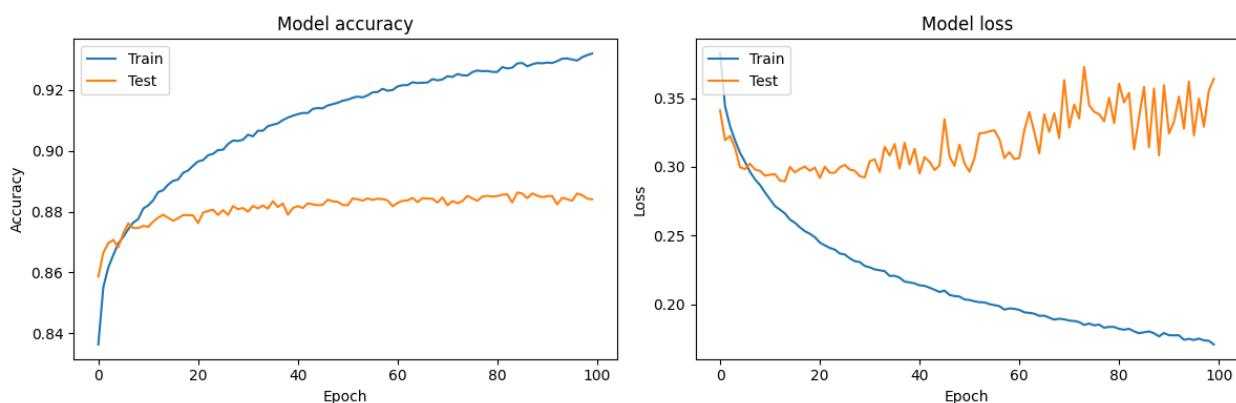
شکل (۱۸-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۲

در قسمت بعد شبکه عصبی نوع ۳ مورد بررسی قرار گرفته است. مطابق با انتظار و نتیجه بخش قبل در این نوع شبکه عصبی نیز دقت مدل تنها در بخش آموزش افزایش پیدا کرده و به میزان حدود ۹۷ درصد رسیده اما دقت مدل آموزش ۸۸ درصد باقی مانده و تابع ضرر بعد از دوره ۲۰ رو به افزایش است که باعث افزایش میزان بیش برآش مدل می‌شود.



شکل (۱۹-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۳

در شبکه عصبی نوع ۴ همانطور که ساختار آن توضیح داده شد از یک مدل شبکه عصبی با سه لایه مخفی با تعداد نورون‌های کاہشی استفاده شده است. همچنین برای جلوگیری از  $\text{DropOut}=0.5$  برای هر سه لایه مخفی استفاده شده است اما همچنان مطابق با شکل زیر دقت آموزش تغییر چندانی ندارد.



شکل (۲۰-۴) دقت و تابع ضرر مدل برای شبکه عصبی نوع ۴

### ۳-۵-۴ شبکه پیشنهادی Inception

شبکه Inception که با نام GoogLeNet نیز شناخته می‌شود، معماری شبکه عصبی کانولوشن عمیق است که انقلابی در زمینه تشخیص تصویر ایجاد کرد. شبکه‌های Inception که در سال ۲۰۱۴ توسط محققان معرفی شدند، به مبنای یادگیری عمیق مدرن تبدیل شده‌اند و به طور قابل توجهی پیشرفته‌ترین فناوری‌ها را در کارهای مختلف بینایی کامپیوتری ارتقا داده‌اند.

یکی از چالش‌های مهم در طراحی شبکه‌های عصبی مؤثر، یافتن تعادل مناسب بین عمق مدل، راندمان محاسباتی و امکان ضبط ویژگی‌های پیچیده در داده‌های ورودی است که Inception این چالش را برطرف می‌کند. این مازول

چندین فیلتر با اندازه‌های مختلف را در همان لایه به کار می‌برد و به شبکه اجازه می‌دهد تا به طور همزمان جزئیات و اطلاعات را ثبت کند. ایده اصلی استفاده از فیلترهایی با اندازه هسته‌های مختلف به طور همزمان برای استخراج ویژگی‌ها در وضوح‌های زمانی مختلف است.

### ۳-۵-۱ ساختار کلی شبکه تلقینی

در ساختار Inception از چهارشاخه تشکیل شده است که هر کدام داده‌های ورودی را به روشهای متفاوت پردازش می‌کنند:

- **شاخه کانولوشنال ۱\*۱**: این شاخه از یک لایه کانولوشنال  $1 \times 1$  برای ثبت الگوهای محلی در داده‌های سری زمانی استفاده می‌کند.
- **شاخه کانولوشنال ۳\*۳**: با استفاده از یک لایه کانولوشنال  $3 \times 3$ ، این شاخه بر استخراج ویژگی‌های زمانی میان‌برد تمرکز دارد.
- **شاخه کانولوشنال ۵\*۵**: این شاخه وظیفه گرفتن الگوهای زمانی با برد بلندتر را با استفاده از یک لایه کانولوشنال  $5 \times 5$  دارد.
- **شاخه ماکریزم ادغام**: یک لایه max-pooling برای ثبت برجسته‌ترین ویژگی‌ها به صورت نمونه‌برداری شده استفاده می‌شود.

سپس خروجی‌های این شاخه‌ها به هم متصل می‌شوند و مجموعه ویژگی ترکیبی ایجاد می‌کنند که طیف وسیعی از ویژگی‌ها را در بر می‌گرد.

### ۳-۵-۲ کاهش بعد

بعد از گام فوق، یک لایه ادغام متوسط<sup>۷۰</sup> برای پایین آوردن ابعاد زمانی اعمال می‌شود. این نمونه‌برداری به کاهش پیچیدگی محاسباتی مدل در عین حفظ اطلاعات ضروری کمک می‌کند. لایه‌های ادغام همچنین به توانایی مدل در تشخیص الگوهای مختلف کمک می‌کند.

### ۳-۵-۳ لایه‌های کاملاً متصل

پس از گذراندن این دو گام، ویژگی به دست آمده به صورت یک بردار تک‌بعدی مسطح می‌شوند. سپس این بردار از لایه‌های کاملاً متصل عبور داده می‌شود. ابعاد این لایه‌ها ۱۲۸ و ۶۴ بر اساس مشاهدات تجربی و آزمایش انتخاب شدند.

<sup>70</sup> average pooling

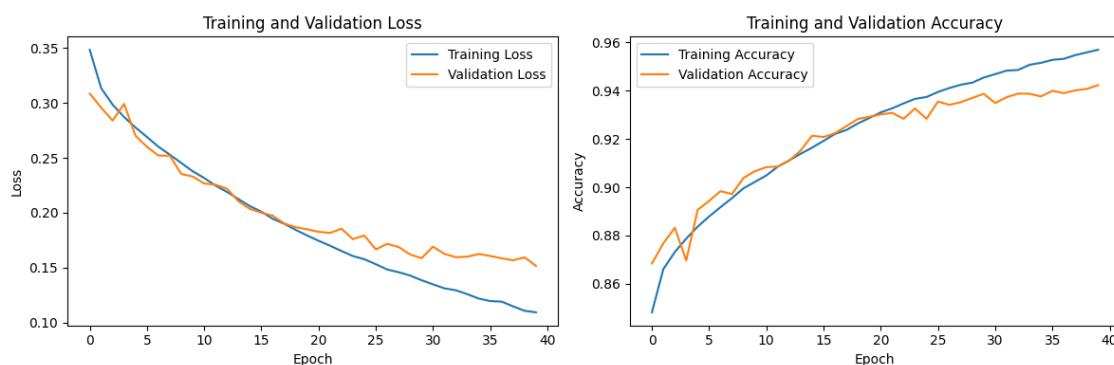
### ۴-۳-۵-۴ جزئیات پارامترهای شبکه تلقینی

تمامی پارامترها و لایه‌های شبکه تلقینی پیشنهادی که از ترکیب سه شبکه تلقینی تشکیل شده به طور جامع در جدول زیر آورده شده است: (نخ یادگیری در این شبکه ۱۰۰۰ در نظر گرفته شده و الگوریتم بهینه‌ساز در این شبکه می‌تواند Adam یا SGD باشد)

جدول (۵-۴) جزئیات پارامترهای شبکه تلقینی

Layer Type	Operation
Inception Module 1	inception_module(x, 32)
Average Pooling 1	AveragePooling1D(pool_size=3, strides=2)
Inception Module 2	inception_module(x, 64)
Average Pooling 2	AveragePooling1D(pool_size=3, strides=2)
Inception Module 3	inception_module(x, 128)
Average Pooling 3	AveragePooling1D(pool_size=3, strides=2)
Flatten	Flatten()
Dense (128, ReLU, L2 Reg.)	Dense(128, activation='relu', kernel_regularizer=l2(0.001))
Dense (64, ReLU, L2 Reg.)	Dense(64, activation='relu', kernel_regularizer=l2(0.001))
Output Layer	Dense(1, activation='sigmoid')

به منظور شبیه‌سازی شبکه تلقینی از سه شبکه با ساختار یکسان و الگوریتم‌های بهینه‌ساز متفاوت به همراه نخ یادگیری مختلف استفاده شده است. در شبکه عصبی تلقینی نوع ۱ از بهینه‌ساز گرادیان نزولی به همراه نخ یادگیری ۰.۵ استفاده کرده ایم. نتایج دقت آزمون و آموزش به همراه تابع ضرر را می‌توان در شکل زیر مشاهده نمود. بر خلاف دو مدل شبکه بخش قبل اختلاف دقت آزمون و آموزش در شبکه تلقینی به میزان مناسبی کمتر شده که نشان میدهد مشکل بیش برآذش در یادگیری این مدل شبکه عصبی رخ نداده است و همچنین تابع ضرر نیز تا دوره ۴۰ در حال کاهش است. به منظور یکسان بودن تعداد دوره‌ها در الگوریتم‌های یادگیری مختلف آموزش در دوره ۴۰ متوقف شده است.



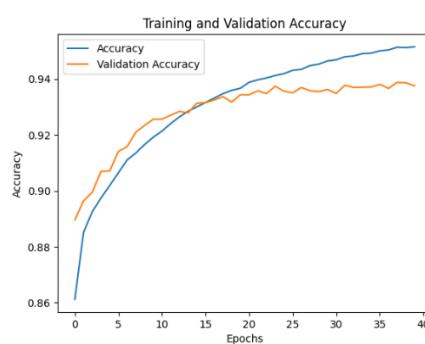
شکل (۲۱-۴) دقت و تابع ضرر مدل برای شبکه تلقینی نوع ۱

در شبکه تلقینی نوع دوم نیز از ساختار مشابه قبل استفاده شده با این تفاوت که از الگوریتم بهینه‌ساز Adam به همراه نرخ یادگیری  $0.0001$  استفاده نموده ایم. مشابه با الگوریتم‌های یادگیری قبل  $40$  دوره شبکه آموزش دیده و نتایج نشان میدهد که نسبت به شبکه نوع  $1$  دقت آزمون به میزان  $3$  درصد کاهش داشته و تفاوت آن نسبت به دقت آزمون  $93$  درصد است، میزان کمی است پس میتوان گفت که این شبکه نیز دچار مشکل بیش برآش نشده است.



شکل (۲۲-۴) دقت و تابع ضرر مدل برای شبکه تلقینی نوع  $2$

یکی از چالش‌های دو شبکه تلقینی ذکر شده، زمان آموزش و آزمون این شبکه‌ها می‌باشد. با توجه به سخت افزار معرفی شده در بخش‌های قبل میزان زمان اجرای این دو شبکه هر کدام نزدیک به  $20$  ساعت بوده است؛ اما در شبکه تلقینی نوع سوم از روش نمونه پایین<sup>۷۱</sup> بهره می‌بریم. این روش به طور خلاصه استفاده از کانوولوشن  $1 \times 1$  قبل از اعمال کانوولوشن‌های مرتبه بالاتر می‌باشد. این امر منجر به کاهش حجم محاسبات و داده‌های خروجی می‌باشد. نتیجه استفاده از شبکه تلقینی نوع  $3$  نه تنها سرعت آموزش شبکه را بالاتر برده؛ بلکه دقت آن نیز به نسبت شبکه تلقینی نوع دوم بهبود یافته است.



شکل (۲۳-۴) دقت مدل برای شبکه تلقینی نوع  $3$

<sup>71</sup> downsample

## ۴-۶- خلاصه نتایج تفکیک سیگنال NLOS/LOS

در این بخش نتایج ارائه شده را با دو پژوهش دیگر که از مجموعه‌داده مشابه استفاده نموده اند یعنی مقاله آقای جیانگ<sup>۷۲</sup> و همکاران [۵۴] به علاوه مقاله آقای بریگار<sup>۷۳</sup> و همکاران [۸۴] مقایسه شده است. برای مشاهده جزئیات دقیق مقادیر پارامتر در نظر گرفته شده برای شبیه‌سازی می‌توان به این دو مرجع رجوع نمود. با توجه به تعاریف و مقداردهی شبکه که در بخش قبل آورده شد می‌توان به طور خلاصه به نتایج جدول ۴-۶ دست یافت. توجه شود که عنوان شبکه‌های ذکر شده در جدول از قبل در بخش‌های مربوطه تعریف شده اند.

نویسنده‌گان مقاله [۵۴] از روش یادگیری عمیق به نام CNN-LSTM برای طبقه‌بندی سیگنال‌های LOS و سیگنال‌های NLOS در سیستم‌های موقعیت‌یابی داخلی استفاده می‌کنند. تمرکز اولیه بر بهبود دقت سیستم‌های موقعیت داخلی با طبقه‌بندی مناسب سیگنال‌های LOS و NLOS قبل از استفاده از اطلاعات محدوده برای محاسبه موقعیت است.

نویسنده‌گان مقاله [۸۴] شرایط NLoS را در محیط‌های داخلی با استفاده از اطلاعات پاسخ ضربه‌ای به دست آمده از UWB تشخیص می‌دهند. آنها روشی را بر اساس طبقه‌بندی کانال NLoS با استفاده از شبکه‌های عصبی کانولوشنال پیشنهاد کردند.

جدول (۴-۶) خلاصه نتایج شبکه‌های عصبی برای طبقه‌بندی شرایط NLOS/LOS

شبکه‌های عصبی	آموزش (دقیقه)	مدت زمان آموزش (ms)	دقت آموزش	دقت آزمون	تابع هزینه	مدت زمان اجرا بی‌درنگ (ms) برای هر نمونه آزمون
شبکه کانولوشنال نوع ۱	۱۰۵	۹۴.۸۴	۹۲.۶۷	۰.۲۰	۰.۳۵	
شبکه کانولوشنال نوع ۲	۹۷	۹۰.۱۶	۹۰.۰۵	۰.۲۴	۰.۳۰	
شبکه عصبی نوع ۱	۴۰	۹۲.۰۰	۸۷.۸۷	۰.۳۱	۰.۲۱	
شبکه عصبی نوع ۲	۴۴	۹۵.۰۶	۸۸.۵۰	۰.۳۵	۰.۲۱	
شبکه عصبی نوع ۳	۴۹	۹۷.۰۰	۸۸.۸۷	۰.۴۷	۰.۲۲	
شبکه عصبی نوع ۴	۶۲	۹۳.۱۹	۸۸.۴۰	۰.۳۶	۰.۲۳	
تلقینی نوع ۱	۱۲۶۶	۹۵.۶۹	۹۴.۲۳	۰.۱۵	۰.۰۹	
تلقینی نوع ۲	۱۹۶۵	۹۲.۳۷	۹۰.۹۰	۰.۲۴	۰.۲۶	
تلقینی نوع ۳	۲۴۰	۹۵.۱۵	۹۳.۷۵	۰.۱۶	۰.۷۰	
بریگار و همکاران	؟	۸۷.۴	؟	؟	؟	؟
جیانگ و همکاران	؟	۸۲.۱۴	؟	؟	؟	؟

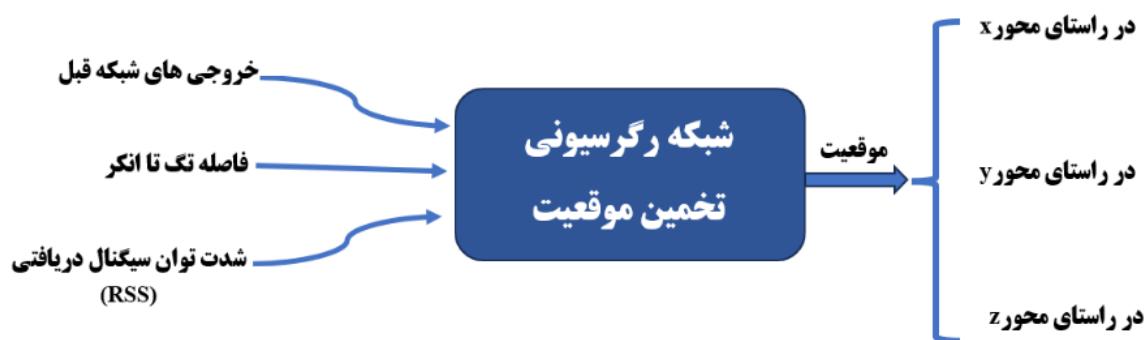
<sup>72</sup> Changhui Jiang

<sup>73</sup> Kalman Bregar

## ۷-۴- موقعیت‌یابی با استفاده از الگوریتم‌های رگرسیون

در روش‌های کلاسیک تخمین موقعیت، مانند روش حداقل مربعات و یا حداقل مربعات وزن‌دهی شده با استفاده از موقعیت انکرها که معلوم می‌باشند و همچنین فاصله اندازه‌گیری شده بین هر انکر تا تگ، موقعیت تگ موردنظر با استفاده از یک سری روابط ریاضی که در فصل قبل هم به آن اشاره شد، را می‌توان تخمین زد. در این مجموعه‌داده موقعیت تگ در دو راستای  $x$  و  $y$  تغییر می‌کند و در بعد  $z$  یعنی ارتفاع ثابت می‌ماند. همچنین موقعیت هر هشت انکر و فواصل آنها نیز مشخص است. رویکرد مرسوم استفاده از الگوریتم LS و WLS برای تخمین موقعیت است. رویکرد حداقل مربعات خطی برای زمانی مناسب است مورداً استفاده قرار بگیرد که هر هشت انکر در شرایط LOS قرار داشته باشند؛ بنابراین تخمین مکان قابل انجام است. اما در حالتی بر اساس هر رویکردی بتوان تشخیص داد که هر یک از انکرها در شرایط NLOS در آن لحظه قرار دارد، می‌توان با استفاده از الگوریتم حداقل مربعات تخمین وزن‌دهی شده به این انکر عدد کمتر و یا حتی مقدار صفر را نسبت داد.

به عبارت دیگر انکرهایی که در شرایط NLOS قرار دارند، اطلاعات معتبری از فاصله تک تا انکر را به ما نمی‌دهند پس عدم توجه به آن برای تخمین موقعیت امری ضروری است. در عمل هدف این است بدون اینکه انسان در تعیین شرایط NLOS دخالت کند، بتوان تشخیص شرایط LOS/NLOS داد. به طور خلاصه می‌توان گفت که از بخش قبل که مربوط به طبقه‌بندی سیگنال‌های NLOS/LOS بوده است، برای پیش‌بینی سیگنال دریافت شده استفاده می‌نماییم که با توجه به نتایج بدست آمده بیشترین دقت را شبکه تلقینی در تفکیک این شرایط از خود به نمایش گذاشت که موارد تخمین زده شده را NLOS پیش‌بینی شده نام‌گذاری کرده و دیتابست جدید تشکیل داده و از این شرایط پیش‌بینی شده به عنوان ورودی شبکه رگرسیون جدید برای تخمین موقعیت استفاده می‌کنیم.



شکل (۲۴-۴) ساختار شبکه رگرسیونی تخمین موقعیت پیشنهادی

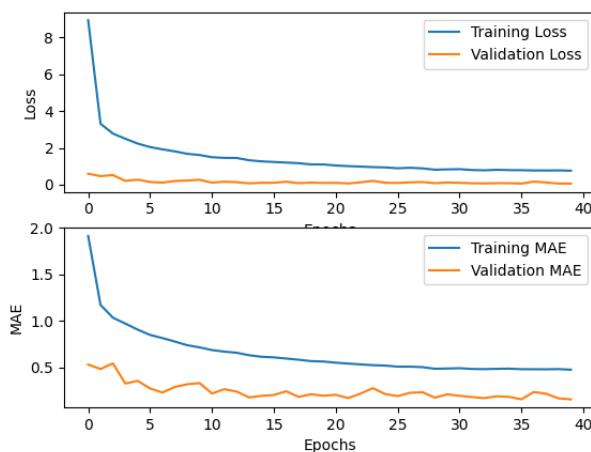
## ۴-۸-۴- ساختار الگوریتم‌های رگرسیون پیشنهادی

در این بخش هدف تعیین موقعیت تگ با استفاده از ورودی‌های RSS، فاصله تگ تا هر انکر و همچنین خروجی‌های شبکه طبقه‌بندی قبل است. در اینجا خروجی از نوع موقعیت در سه بعد است؛ بنابراین لایه آخر از تابع فعالساز سیگموید یا softmax استفاده نمی‌شود. در تمامی ساختارهای رگرسیون پیشنهاد شده است از ویژگی‌های ذکر شده به عنوان ورودی شبکه رگرسیونی و خروجی مشترک این الگوریتم‌ها موقعیت تخمین زده شده تگ است. همچنین تخمین موقعیت را برای شرایطی که سیگنال LOS یا NLOS را مدنظر قرار نداده ایم، مقایسه نموده‌ایم. در نهایت روش‌های رگرسیونی ذکر شده را با مرجع [۸۴] در هر دو حالت مورد مقایسه قرار گرفته شده است.

### ۱-۸-۴- تخمین موقعیت بدون در نظر گرفتن شرایط NLOS

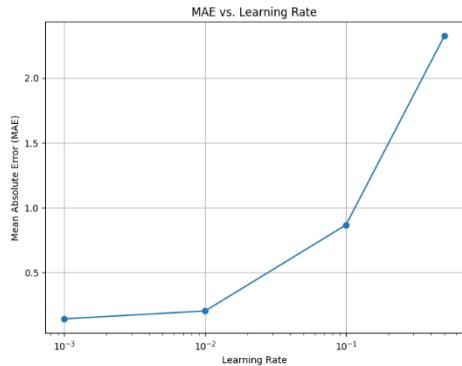
همان‌طور که ذکر شد در این شبیه‌سازی تنها از ویژگی‌های RSS و فاصله مجموعه‌داده برای اجرای شبکه رگرسیونی استفاده شده است. در مرجع [۸۴] پژوهشگران از الگوریتم حداقل مربعات استفاده نموده و موقعیت تگ را بدون در نظر گرفتن شرایط NLOS محاسبه می‌کنند.

در الگوریتم رگرسیون پیشنهادی اول، که تحت عنوان رگرسیون چندمتغیره ۱ آورده شده، ساختار آن به این شکل است که لایه مخفی اول با ۶۴ نورون، لایه مخفی دوم نیز از ۶۴ نورون با توابع فعالساز Relu است. همچنین از تکنیک DropOut به منظور جلوگیری از بیش برازش برای هر لایه مخفی استفاده کرده‌ایم. رگرسیون چند متغیره ۲ نیز مشابه همین ساختار را دارد است با این تفاوت که لایه مخفی اول از ۱۲۸ نورون تشکیل شده است. نتایج استفاده از مدل الگوریتم رگرسیونی برای ۴۰ دوره در دو نمودار زیر آورده شده است. دقت بدست آمده هر دو رگرسیون چند متغیره برابر با ۱۵.۸ سانتی متر است.



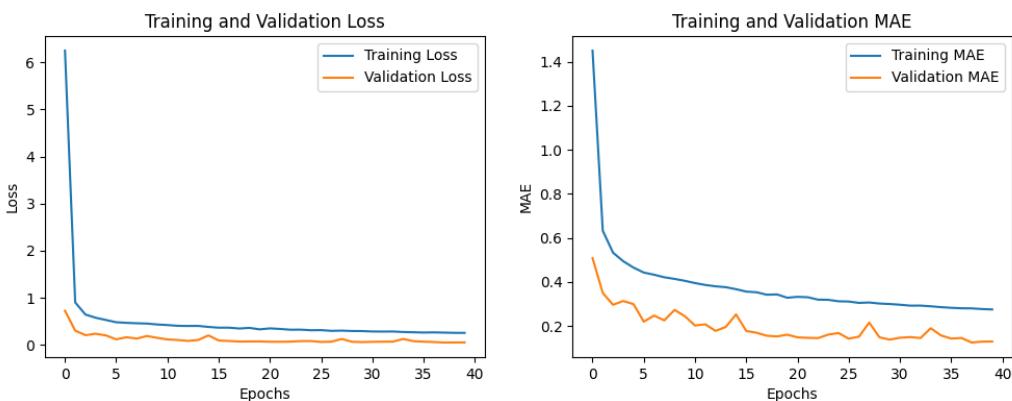
شکل (۲۵-۴) دقت و تابع ضرر مدل رگرسیونی چند متغیره بدون در نظر گرفتن شرایط NLOS

نرخ یادگیری الگوریتم رگرسیون چند متغیره را باتوجه به نتیجه شکل ۲۶-۴، ۰۰۱، ۲۶-۴ در نظر گرفته شده است. در مرجع [۲] زمانی که شرایط NLOS در نظر گرفته نشده است، از روش حداقل مربعات برای تخمین موقعیت استفاده شده است.



شکل (۲۶-۴) میانگین خطای مطلق به ازای نرخ یادگیری‌های مختلف

در الگوریتم رگرسیون نوع دوم از ساختار شبکه‌های عصبی کانولوشنی بهره برده‌ایم. ساختار رگرسیون CNN پیشنهادی از ۲ لایه کانولوشنی تکبعده و دولاپیه حداکثر ادغام تشکیل شده است. همچنین از دولاپیه کاملاً متصل به بعد ۱۲۸ نورون استفاده نموده‌ایم. در نهایت سه شبکه بدست می‌آوریم به‌طوری‌که لایه خروجی از تابع فعالساز خطی استفاده نموده‌ایم. دقت الگوریتم رگرسیونی کانولوشنی در این شبکه رگرسیونی ۱۴.۳ سانتی متر بدست آمده است.



شکل (۲۷-۴) دقت و تابع ضرر مدل رگرسیونی کانولوشنی بدون در نظر گرفتن شرایط NLOS

الگوریتم رگرسیون بردار پشتیبانی (SVR) پیشنهادی برای موقعیت‌یابی سه‌بعدی پیاده‌سازی می‌شود و می‌تواند مختصات  $x$ ،  $y$  و  $z$  را به طور جداگانه پیش‌بینی می‌کند. سه مدل SVR با استفاده از هسته تابع پایه شعاعی ( $\text{Y}_{\text{train}}$ ) با پارامتر تنظیم ( $C$ ) ۱۰ ایجاد می‌شود. داده‌های آموزشی ( $X_{\text{train}}$ ) و مقادیر هدف مربوطه (RBF) با

برای آموزش هر مدل SVR به صورت جداگانه برای هر بعد ایجاد می‌شود. این رویکرد به مدل‌های رگرسیون اجزه می‌دهد تا روابط غیرخطی بین ویژگی‌ها و مختصات هدف را در هر بعد ثبت کنند. پیش‌بینی‌های جداگانه برای بعد  $x$ ,  $y$ , و  $z$  موقعیت‌یابی دقیق را در فضای سه‌بعدی امکان‌پذیر می‌سازد. در این الگوریتم رگرسیون دقت تخمین به میزان ۱۲.۱ سانتی متر می‌رسد که نسبت به الگوریتم رگرسیون قبل دقت بالاتری را در تخمین موقعیت را دارد.

در جدول ۷-۴ نتایج موقعیت‌یابی بدون نظر گرفتن شرایط NLOS را به طور خلاصه به ازای ۴۰ دوره برای تمامی الگوریتم‌های رگرسیون بیان شده است و همچنین زمان اجرای یادگیری تمامی الگوریتم‌ها کمتر از ۵ دقیقه می‌باشد.

جدول (۷-۴) میانگین خطای مطلق موقعیت‌یابی بدون درنظر گرفتن شرایط NLOS

الگوریتم رگرسیون	MAE	مدت زمان اجرا بی‌درنگ برای هر نمونه آزمون (ms)
چندمتغیره ۱	۰.۱۵۸	۰.۵۱
چندمتغیره ۲	۰.۱۵۸	۰.۵۳
کانولوشنی	۰.۱۴۳	۰.۶۱
بردار پشتیبانی	۰.۱۲۱	۰.۵۶
مرجع [۸۴]	۰.۱۸	؟

## ۲-۸-۴- تخمین موقعیت به همراه درنظر گرفتن شرایط NLOS

در این بخش با استفاده از خروجی‌های شبکه قبل که برای پیش‌بینی شرایط NLOS یا LOS بوده بهره برده و به عنوان ورودی‌های جدید به شبکه‌های تخمین موقعیت بخش قبل داده و همچنین موقعیت تخمین زده شده را نیز با مرجع [۸۴] که از روش حداقل مربعات وزن‌دهی شده استفاده می‌کند، مقایسه شده است. در نهایت مطابق با نتایج موقعیت‌یابی بدست آمده و مقایسه با جدول ۷-۴ می‌توان به این نتیجه دست یافت که در حالت درنظر گرفتن شرایط NLOS به دقت بالاتری در تخمین موقعیت دست یافته‌ایم. ساختار الگوریتم‌های رگرسیون در جدول زیر مشابه با بخش قبل می‌باشد و این نتایج برای ۴۰ دوره اجرا می‌باشد. مدت زمان اجرا بی‌درنگ برای استفاده از مجموعه داده‌های آزمون برای الگوریتم‌های رگرسیونی ذکر شده به طور میانگین ۵.۰ میلی ثانیه می‌باشد.

جدول (۸-۴) میانگین خطای مطلق موقعیت‌یابی به همراه درنظرگرفتن شرایط NLOS

الگوریتم رگرسیون	MAE	مدت زمان اجرا بی‌درنگ برای هر نمونه آزمون (ms)
چندمتغیره ۱	۰.۱۲	۰.۵۲
چندمتغیره ۲	۰.۱۲	۰.۵۴
کانوولوشنی	۰.۱۰	۰.۶۳
بردار پشتیبانی	۰.۸	۰.۵۷
مرجع [۸۴]	۰.۱۱	؟

به عنوان نمونه برای تخمین موقعیت، ورودی‌ها به شبکه تخمین موقعیت داده شده و شبکه به طور کامل آموزش دیده است. حال برای تست این شبکه، مقادیر شدت توان، فاصله و NLOS موقعیت تگ لحظه خاص را به شبکه می‌دهیم. موقعیت واقعی تگ در  $x = 1.91$  و  $y = 5.58$  قرار دارد و شبکه آموزش دیده موقعیت  $x = 5.48$  و  $y = 5.48$  را تخمین زده است که با دقت بسیار مناسب‌تری را نسبت به مرجع [۲] دارد.

## فصل ۵: جمع‌بندی و پیشنهادها

### ۱-۵- جمع‌بندی

در طول انجام این پایان‌نامه، پروژه تحقیقاتی را با تمرکز بر کاربرد شبکه‌های عصبی عمیق برای طبقه‌بندی سیگنال‌ها بر اساس پاسخ ضربه‌ای کanal (CIR) انجام شده است. هدف اصلی تمایز بین سیگنال‌های غیر خط دید (NLOS) و سیگنال‌های خط دید (LOS) بود که نقش به سزایی در تخمین موقعیت هدف موردنظر دارد. مجموعه‌داده‌های مورداستفاده برای آموزش و ارزیابی شامل پاسخ ضربه‌ای با ابعاد ۱۰×۱۶ ویژگی است. برای دستیابی به دسته‌بندی بدقت بالا، از سه معماری شبکه عصبی متمایز استفاده شد: شبکه عصبی کانولوشن (CNN)، شبکه عصبی پیشخور با تعداد لایه‌های مخفی متفاوت و شبکه عصبی تلقینی.

از مهمترین دلایل استفاده از شبکه عصبی کانولوشنال (CNN) می‌توان به توانایی یادگیری مدل‌های پیچیده و همچنین تغییرناپذیر نسبت به ورودی اشاره کرد. در شبکه‌های عصبی تلقینی، اصلی‌ترین موضوعی که ما به دنبالش هستیم، پیدا کردن الگوهای بهینه در جزئیات مختلف است که در اینجا جزئیات این شبکه به طور مفصل مطرح گردید و در نهایت مطابق با تحقیقاتی که در این مورد به طور معمول مورداستفاده قرار می‌گیرد، مقایسه با شبکه‌های عصبی مرسوم با چندلایه مخفی مختلف و همچنین سایر مراجع که از این مجموعه‌داده استفاده نموده‌اند. مطابق با نتایج شبیه‌سازی با درنظرگرفتن معیار دقت می‌توان گفت، شبکه عصبی تلقینی نسبت به سایر شبکه‌های عصبی در دسته‌بندی شرایط LOS و NLOS عملکرد بهتری از خود نشان‌داده شده است.

در گام بعد پس از تشخیص شرایط LOS و NLOS بودن هر یک از انکرها نوبت به تخمین موقعیت با استفاده از الگوریتم‌های رگرسیون مانند CNN، SVM و... بوده است. برای مشاهده تأثیر پیش‌بینی شبکه قبل، یکبار بدون درنظرگرفتن NLOS به عنوان ورودی شبکه رگرسیونی و بار دیگر با درنظرگرفتن این شرایط و در نهایت نتایج را با مرجع [۲] که از روش‌های حداقل مربعات و حداقل مربعات خطی بهره است، مقایسه در هر دو حالت صورت گرفته است.

## ۲-۵- پیشنهادها

استفاده از روش‌های استخراج ویژگی در تحقیقات آتی می‌تواند رویکردن مؤثر، بهویژه در زمینه پردازش سیگنال و وظایف یادگیری باشد. استخراج ویژگی شامل تبدیل داده‌های خام به مجموعه‌ای از ویژگی‌های مرتبط است که می‌تواند ویژگی‌های اساسی داده‌ها را ثبت کند و آن را برای تحلیل و مدل‌سازی مناسب‌تر کند. همان‌طور که ذکر شد در این مجموعه‌داده از ۱۰۱۶ ویژگی برای آموزش شبکه‌ها به کاررفته است. زمینه تحقیقاتی مؤثر در آینده می‌تواند تحقیق بر روی کاهش ابعاد ورودی شبکه با حفظ دقت دسته‌بندی سیگنال NLOS/LOS به کمک الگوریتم‌هایی مانند<sup>74</sup> PCA<sup>75</sup>, LDA<sup>75</sup>, t-SNE<sup>76</sup> و غیره باشد.

از دیگر پیشنهادهای آینده می‌توان به بررسی کاربرد تکنیک‌های یادگیری انتقال برای استفاده از دانش به‌دست‌آمده از محیطی خاص (به عنوان مثال، یک ساختمان) برای بهبود عملکرد موقعیت‌یابی در محیط‌های دیگر اشاره نمود. این مدل را می‌توان برای پیاده‌سازی بلاذرنگ با درنظر گرفتن محدودیت‌ها در کاربردهای عملی بهینه شود به عنوان نمونه ممکن است شامل فشرده‌سازی مدل، کوانتیزاسیون<sup>77</sup> یا تکنیک‌های دیگر باشد.

و یا می‌توان به این موضوع نیز اشاره نمود که ترکیب اطلاعات از انواع مختلف منابع داده، مانند داده‌های بصری، داده‌های محیطی، یا سایر ورودی‌های حسگر مرتبط در نظر گرفته شود تا دقت کلی سیستم محلی‌سازی را نه تنها در محیط داخلی بلکه در محیط‌های بیرونی نیز بهبود بخشد.

<sup>74</sup> Principal Component Analysis

<sup>75</sup> Linear Discriminant Analysis

<sup>76</sup> t-Distributed Stochastic Neighbor Embedding

<sup>77</sup> quantization

## پیوست الف

روشی معمول برای محاسبه موقعیت پس از اندازه‌گیری محدوده استفاده از روش حداقل مربعات خطی است. الگوریتم قابل اجرا که در سیستم‌های موقعیت‌یابی مبتنی بر محدوده به عنوان چند لایه‌سازی شناخته می‌شود. این الگوریتم با تعریف ریاضی فاصله‌های فردی بین تگ و هر انکر به عنوان فاصله اقلیدسی مشخص می‌شود.

$$r_i = \sqrt{(x_i - x)^2 + (y_i - y)^2}$$

که  $r_i$  فاصله اندازه‌گیری شد بین انکر  $i$  با موقعیت  $(x_i, y_i)$  و تگ با موقعیت نامعلوم  $(x, y)$  است. با نوشتן معادلات برای همه جفت تگ - انکر، سیستمی از پیش تعریف شده معادلات به دست می‌آوریم. برای خطی کردن سیستم معادلات غیرخطی حاصل، متغیر جدیدی را مانند معادله زیر معرفی می‌شود.

$$R = x^2 + y^2$$

اکنون موقعیت را می‌توان با روابط زیر تخمین زد:

$$\hat{\theta} = [x \quad y \quad R]^T$$

سیستم از پیش تعریف شده معادلات خطی شده به صورت ماتریسی به صورت  $H$  و  $x$  نشان داده می‌شود.

$$\mathbf{H} = \begin{vmatrix} -2x_1 & -2y_1 & 1 \\ -2x_2 & -2y_2 & 1 \\ \vdots & \vdots & \vdots \\ -2x_N & -2y_N & 1 \end{vmatrix}$$

$$\mathbf{x} = \begin{bmatrix} \hat{d}_1^2 & -x_1^2 & -y_1^2 \\ \hat{d}_2^2 & -x_2^2 & -y_2^2 \\ \vdots & & \\ \hat{d}_N^2 & -x_N^2 & -y_N^2 \end{bmatrix}$$

سیستم از پیش تعریف شده معادلات خطی حاصل را می‌توان برای تخمین موقعیت با استفاده از الگوریتم حداقل مربعات در یک فرم عادی همان‌طور که توسط معادله ارائه شده است استفاده کرد.

$$\hat{\theta} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$

## پیوست ب

در روش حداقل مربعات وزن دار، به جای حل معادله  $A \cdot x = b$  ماتریس  $w \cdot A \cdot x = w \cdot b$  محاسبه می شود. رابطه حداقل مربعات وزن دار در نهایت به صورت رابطه زیر نوشته می شود:

$$A = 2 \begin{bmatrix} (x_n - x_1) & (y_n - y_1) \\ \vdots & \vdots \\ (x_n - x_{n-1}) & (y_n - y_{n-1}) \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_u \\ y_n \end{bmatrix},$$

$$\mathbf{b} = \begin{bmatrix} (d_1^2 - d_n^2) - (x_1^2 - x_n^2) - (y_1^2 - y_n^2) \\ \vdots \\ (d_{n-1}^2 - d_n^2) - (x_{n-1}^2 - x_n^2) - (y_{n-1}^2 - y_n^2) \end{bmatrix}.$$

$$\mathbf{x} = (A^T w^{-1} A)^{-1} A^T w^{-1} \mathbf{b}$$

که در رابطه فوق ماتریس  $w$ ، ماتریس وزن و کوواریانس بردار  $b$  است که به عنوان نمونه می تواند به صورت زیر تعریف شود:

$$w = \begin{bmatrix} \text{var}(d_1^2) + \text{var}(d_n^2) & \text{var}(d_n^2) & \cdots & \text{var}(d_n^2) \\ \text{var}(d_n^2) & \text{var}(d_2^2) + \text{var}(d_n^2) & \cdots & \text{var}(d_n^2) \\ \vdots & \vdots & \ddots & \vdots \\ \text{var}(d_n^2) & \text{var}(d_n^2) & \cdots & \text{var}(d_{n-1}^2) + \text{var}(d_n^2) \end{bmatrix}$$

## مراجع

- [1] S. M.-S. SADOUGH, "A Tutorial on Ultra Wideband Modulation and Detection Schemes," *Shahid Beheshti Univ. Fac. Electr. Comput. Eng, Tehran, I. R. Iran*, 2009.
- [2] S. Fingerman, *Introduction to GPS; the Global Positioning System*, 2d ed. 2007.
- [3] J. Torres-Sospedra, R. Montoliu, S. Trilles, Ó. Belmonte, and J. Huerta, "Comprehensive analysis of distance and similarity measures for Wi-Fi fingerprinting indoor positioning systems," *Expert Syst. Appl.*, 2015, doi: 10.1016/j.eswa.2015.08.013.
- [4] H. Park, A. Camps, J. Castellvi, and J. Muro, "Generic Performance Simulator of Spaceborne GNSS-Reflectometer for Land Applications," *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, 2020, doi: 10.1109/JSTARS.2020.3000391.
- [5] X. Guo, N. R. Elikplim, N. Ansari, L. Li, and L. Wang, "Robust WiFi Localization by Fusing Derivative Fingerprints of RSS and Multiple Classifiers," *IEEE Trans. Ind. Informatics*, 2020, doi: 10.1109/TII.2019.2910664.
- [6] L. Atzori, A. Iera, and G. Morabito, "The Internet of Things: A survey," *Comput. Networks*, 2010, doi: 10.1016/j.comnet.2010.05.010.
- [7] V. Kulkarni, K. V. L. Narayana, and S. K. Sahoo, "A survey on interference avoiding methods for wireless sensor networks working in the 2.4 GHz frequency band," *Journal of Engineering Science and Technology Review*. 2020. doi: 10.25103/jestr.133.08.
- [8] P. Davidson and R. Piché, "A Survey of Selected Indoor Positioning Methods for Smartphones," *IEEE Communications Surveys and Tutorials*. 2017. doi: 10.1109/COMST.2016.2637663.
- [9] Q. Z. Ahmed, S. Ahmed, M. S. Alouini, and S. Aïssa, "Minimizing the symbol-error-rate for amplify-and-forward relaying systems using evolutionary algorithms," *IEEE Trans. Commun.*, 2015, doi: 10.1109/TCOMM.2014.2375255.
- [10] H. Shao and N. C. Beaulieu, "Direct sequence and time-hopping sequence designs for narrowband interference mitigation in impulse radio UWB systems," *IEEE Trans. Commun.*, 2011, doi: 10.1109/TCOMM.2011.060911.100581.
- [11] J. Karedal, S. Wyne, P. Almers, F. Tufvesson, and A. F. Molisch, "A measurement-based statistical model for industrial ultra-wideband channels," *IEEE Trans. Wirel. Commun.*, 2007, doi: 10.1109/TWC.2007.051050.
- [12] M. Zhou, Y. Tang, Z. Tian, L. Xie, and W. Nie, "Robust Neighborhood Graphing for Semi-Supervised Indoor Localization with Light-Loaded Location Fingerprinting," *IEEE Internet Things J.*, 2018, doi: 10.1109/JIOT.2017.2775199.
- [13] X. Yang, "NLOS mitigation for UWB localization based on sparse pseudo-input Gaussian process," *IEEE Sens. J.*, 2018, doi: 10.1109/JSEN.2018.2818158.
- [14] J. Khodjaev, Y. Park, and A. Saeed Malik, "Survey of NLOS identification and error mitigation problems in UWB-based positioning algorithms for dense environments,"

*Annales des Télécommunications/Annals of Telecommunications.* 2010. doi: 10.1007/s12243-009-0124-z.

- [15] V. Barral, C. J. Escudero, J. A. García-Naya, and R. Maneiro-Catoira, “NLOS identification and mitigation using low-cost UWB devices,” *Sensors (Switzerland)*, 2019, doi: 10.3390/s19163464.
- [16] C. Lu, W. Xu, H. Shen, J. Zhu, and K. Wang, “MIMO Channel Information Feedback Using Deep Recurrent Network,” *IEEE Commun. Lett.*, 2019, doi: 10.1109/LCOMM.2018.2882829.
- [17] J. Wang, R. K. Ghosh, and S. K. Das, “A survey on sensor localization,” *J. Control Theory Appl.*, 2010, doi: 10.1007/s11768-010-9187-7.
- [18] Michał Szczypior, “No Title,” *Ultra-wideband - old technology discovered again*, 2021.
- [19] J. R. Fernandes and D. Wentzloff, “Recent advances in IR-UWB transceivers: An overview,” 2010. doi: 10.1109/ISCAS.2010.5537916.
- [20] Z. Yang, Z. Zhou, and Y. Liu, “From RSSI to CSI: Indoor localization via channel response,” *ACM Comput. Surv.*, 2013, doi: 10.1145/2543581.2543592.
- [21] P. Kumar, L. Reddy, and S. Varma, “Distance measurement and error estimation scheme for RSSI based localization in wireless sensor networks,” 2009. doi: 10.1109/WCSN.2009.5434802.
- [22] J. Xiong and K. Jamieson, “ArrayTrack: A fine-grained indoor location system,” 2013.
- [23] W. Dargie and C. Poellabauer, *Fundamentals of Wireless Sensor Networks: Theory and Practice*. 2011. doi: 10.1002/9780470666388.
- [24] F. Zafari, A. Gkelias, and K. K. Leung, “A Survey of Indoor Localization Systems and Technologies,” *IEEE Commun. Surv. Tutorials*, 2019, doi: 10.1109/COMST.2019.2911558.
- [25] G. Yang, L. Zhao, Y. Dai, and Y. Xu, “A KFL-TOA UWB indoor positioning method for complex environment,” 2017. doi: 10.1109/CAC.2017.8243291.
- [26] A. Waqar, I. Ahmad, D. Habibi, and Q. V. Phung, “Analysis of GPS and UWB positioning system for athlete tracking,” *Meas. Sensors*, 2021, doi: 10.1016/j.measen.2020.100036.
- [27] P. Schneider and F. Xhafa, *Anomaly Detection and Complex Event Processing Over IoT Data Streams: With Application to eHealth and Patient Data Monitoring*. 2022. doi: 10.1016/B978-0-12-823818-9.00002-X.
- [28] M. Centenaro, L. Vangelista, A. Zanella, and M. Zorzi, “Long-range communications in unlicensed bands: The rising stars in the IoT and smart city scenarios,” *IEEE Wirel. Commun.*, 2016, doi: 10.1109/MWC.2016.7721743.
- [29] K. C. Karthika, “Wireless mesh network: A survey,” 2016. doi: 10.1109/WiSPNET.2016.7566486.
- [30] S. Holm, “Hybrid ultrasound-RFID indoor positioning: Combining the best of both worlds,”

2009. doi: 10.1109/RFID.2009.4911169.

- [31] X. Li, J. Wang, and C. Liu, “A bluetooth/PDR integration algorithm for an indoor positioning system,” *Sensors (Switzerland)*, 2015, doi: 10.3390/s151024862.
- [32] P. Baronti, P. Pillai, V. W. C. Chook, S. Chessa, A. Gotta, and Y. F. Hu, “Wireless sensor networks: A survey on the state of the art and the 802.15.4 and ZigBee standards,” *Computer Communications*. 2007. doi: 10.1016/j.comcom.2006.12.020.
- [33] W. Huang *et al.*, “Swadloon: Direction Finding and Indoor Localization Using Acoustic Signal by Shaking Smartphones,” *IEEE Trans. Mob. Comput.*, 2015, doi: 10.1109/TMC.2014.2377717.
- [34] M. Hazas and A. Hopper, “Broadband ultrasonic location systems for improved indoor positioning,” *IEEE Trans. Mob. Comput.*, 2006, doi: 10.1109/TMC.2006.57.
- [35] Y. S. Kuo, P. Pannuto, K. J. Hsiao, and P. Dutta, “Luxapose: Indoor positioning with mobile phones and visible light,” 2014. doi: 10.1145/2639108.2639109.
- [36] I. Oppermann, M. Hamalainen, and J. Iinatti, *UWB: Theory and applications*. 2005. doi: 10.1002/0470869194.
- [37] J. Armstrong, Y. Sekercioglu Ahmet, and A. Neild, “Visible light positioning: A roadmap for international standardization,” *IEEE Commun. Mag.*, 2013, doi: 10.1109/MCOM.2013.6685759.
- [38] D. Feng, C. Wang, C. He, Y. Zhuang, and X. G. Xia, “Kalman-Filter-Based Integration of IMU and UWB for High-Accuracy Indoor Positioning and Navigation,” *IEEE Internet Things J.*, 2020, doi: 10.1109/JIOT.2020.2965115.
- [39] K. Zhao, M. Zhu, B. Xiao, X. Yang, C. Gong, and J. Wu, “Joint RFID and UWB Technologies in Intelligent Warehousing Management System,” *IEEE Internet Things J.*, 2020, doi: 10.1109/JIOT.2020.2998484.
- [40] QORVO, “No Title,” in *Getting Back to Basics with Ultra-Wideband*, 2021, pp. 2, 5.
- [41] Z. G. Wu, C. Y. Lin, H. W. Chang, and P. T. Lin, “Inline inspection with an industrial robot (IIIR) for mass-customization production line,” *Sensors (Switzerland)*, 2020, doi: 10.3390/s20113008.
- [42] P. T. Lin, C. A. Liao, and S. H. Liang, “Probabilistic Indoor Positioning and Navigation (PIPN) of Autonomous Ground Vehicle (AGV) Based on Wireless Measurements,” *IEEE Access*, 2021, doi: 10.1109/ACCESS.2021.3057415.
- [43] Z. Silvia, C. Martina, S. Fabio, and P. Alessandro, “Ultra Wide Band Indoor Positioning System: analysis and testing of an IPS technology,” 2018. doi: 10.1016/j.ifacol.2018.08.292.
- [44] R. J. Fontana, “Recent system applications of short-pulse ultra-wideband (UWB) technology,” 2004. doi: 10.1109/TMTT.2004.834186.
- [45] M. Matin, “Ultra Wideband Preliminaries,” in *Ultra Wideband*, 2010. doi: 10.5772/10059.

- [46] X. Hu and T. Jin, “Short-range vital signs sensing based on EEMD and CWT using IR-UWB radar,” *Sensors (Switzerland)*, 2016, doi: 10.3390/s16122025.
- [47] T. Lauteslager, M. Maslik, F. Siddiqui, S. Marfani, G. D. Leschziner, and A. J. Williams, “Validation of a new contactless and continuous respiratory rate monitoring device based on ultra-wideband radar technology,” *Sensors*, 2021, doi: 10.3390/s21124027.
- [48] P. Wang *et al.*, “Non-contact vital signs monitoring of dog and cat using a UWB radar,” *Animals*, 2020, doi: 10.3390/ani10020205.
- [49] R. S. Kshetrimayum, “An introduction to UWB communication systems,” *IEEE Potentials*, 2009, doi: 10.1109/MPOT.2009.931847.
- [50] I. Khajenasiri, P. Zhu, M. Verhelst, and G. Gielen, “A Low-Energy Ultra-Wideband Internet-of-Things Radio System for Multi-Standard Smart-Home Energy Management,” *IEIE Trans. Smart Process. Comput.*, 2015, doi: 10.5573/ieiespc.2015.4.5.354.
- [51] C. Janiesch, P. Zschech, and K. Heinrich, “Machine learning and deep learning,” *Electron. Mark.*, vol. 31, no. 3, pp. 685–695, 2021, doi: 10.1007/s12525-021-00475-2.
- [52] Z. E. Khatab, A. Hajihoseini, and S. A. Ghorashi, “A Fingerprint Method for Indoor Localization Using Autoencoder Based Deep Extreme Learning Machine,” *IEEE Sensors Lett.*, 2017, doi: 10.1109/lens.2017.2787651.
- [53] H. Wymeersch, S. Maranò, W. M. Gifford, and M. Z. Win, “A machine learning approach to ranging error mitigation for UWB localization,” *IEEE Trans. Commun.*, 2012, doi: 10.1109/TCOMM.2012.042712.110035.
- [54] C. Jiang, J. Shen, S. Chen, Y. Chen, D. Liu, and Y. Bo, “UWB NLOS/LOS Classification Using Deep Learning Method,” *IEEE Commun. Lett.*, 2020, doi: 10.1109/LCOMM.2020.2999904.
- [55] A. Poulose and D. S. Han, “UWB indoor localization using deep learning LSTM networks,” *Appl. Sci.*, 2020, doi: 10.3390/APP10186290.
- [56] A. Shrestha and A. Mahmood, “Review of deep learning algorithms and architectures,” *IEEE Access*. 2019. doi: 10.1109/ACCESS.2019.2912200.
- [57] C. Szegedy *et al.*, “Going deeper with convolutions,” 2015. doi: 10.1109/CVPR.2015.7298594.
- [58] M. C. Burk, “Ramifications of the Relationship between Income and Food,” *J. Farm Econ.*, 1962, doi: 10.2307/1235490.
- [59] J. Delua, “Supervised vs. Unsupervised Learning: What’s the Difference?,” *IBM Anal. Data Sci. Learn.*, 2021.
- [60] M. Ballesta, L. Payá, S. Cebollada, O. Reinoso, and F. Murcia, “A cnn regression approach to mobile robot localization using omnidirectional images,” *Appl. Sci.*, 2021, doi: 10.3390/app11167521.
- [61] R. Gandhi, “Support Vector Machine — Introduction to Machine Learning Algorithms,” *Towar. Data Sci.*, 2018.

- [62] R. J. Chase, D. R. Harrison, A. Burke, G. M. Lackmann, and A. McGovern, “A Machine Learning Tutorial for Operational Meteorology. Part I: Traditional Machine Learning,” *Weather Forecast.*, 2022, doi: 10.1175/WAF-D-22-0070.1.
- [63] “Support Vector Machine (SVM) Explained - MATLAB & Simulink.” <https://www.mathworks.com/discovery/support-vector-machine.html> (accessed Jan. 06, 2024).
- [64] L. Cheng, Z. Wu, B. Lai, Q. Yang, A. Zhao, and Y. Wang, “Ultra Wideband Indoor Positioning System based on Artificial Intelligence Techniques,” 2020. doi: 10.1109/IRI49571.2020.00073.
- [65] B. Silva and G. P. Hancke, “IR-UWB-Based Non-Line-of-Sight Identification in Harsh Environments: Principles and Challenges,” *IEEE Trans. Ind. Informatics*, 2016, doi: 10.1109/TII.2016.2554522.
- [66] S. Gezici *et al.*, “Localization via ultra-wideband radios: A look at positioning aspects of future sensor networks,” *IEEE Signal Process. Mag.*, vol. 22, no. 4, 2005, doi: 10.1109/MSP.2005.1458289.
- [67] I. Guvenc, C. C. Chong, and F. Watanabe, “NLOS identification and mitigation for UWB localization systems,” 2007. doi: 10.1109/WCNC.2007.296.
- [68] H. Cao, Y. Wang, J. Bi, S. Xu, M. Si, and H. Qi, “Indoor positioning method using WiFi RTT based on LOS identification and range calibration,” *ISPRS Int. J. Geo-Information*, 2020, doi: 10.3390/ijgi9110627.
- [69] A. Musa, G. D. Nugraha, H. Han, D. Choi, S. Seo, and J. Kim, “A decision tree-based NLOS detection method for the UWB indoor location tracking accuracy improvement,” *Int. J. Commun. Syst.*, 2019, doi: 10.1002/dac.3997.
- [70] S. Krishnan, R. Xenia Mendoza Santos, E. Ranier Yap, and M. Thu Zin, “Improving UWB Based Indoor Positioning in Industrial Environments Through Machine Learning,” 2018. doi: 10.1109/ICARCV.2018.8581305.
- [71] G. Retscher, V. Gikas, H. Hofer, H. Perakis, and A. Kealy, “Range validation of UWB and Wi-Fi for integrated indoor positioning,” *Appl. Geomatics*, 2019, doi: 10.1007/s12518-018-00252-5.
- [72] P. Wu, “Comparison between the Ultra-wide Band based indoor positioning technology and other technologies,” 2022. doi: 10.1088/1742-6596/2187/1/012010.
- [73] “Multipath Fading — PySDR: A Guide to SDR and DSP using Python.” [https://pysdr.org/content/multipath\\_fading.html](https://pysdr.org/content/multipath_fading.html) (accessed Jan. 08, 2024).
- [74] A. Alarifi *et al.*, “Ultra wideband indoor positioning technologies: Analysis and recent advances,” *Sensors (Switzerland)*. 2016. doi: 10.3390/s16050707.
- [75] “infsoft Use Case: Tracking of Vehicles and Goods in Logistics.” <https://www.infsoft.com/use-cases/tracking-of-floor-conveyors-and-goods-in-logistics/> (accessed Jan. 08, 2024).

- [76] N. O. Tippenhauer, K. B. Rasmussen, and S. Capkun, “Physical-layer integrity for wireless messages,” *Comput. Networks*, 2016, doi: 10.1016/j.comnet.2016.06.021.
- [77] L. Batistic and M. Tomic, “Overview of indoor positioning system technologies,” 2018. doi: 10.23919/MIPRO.2018.8400090.
- [78] M. Stocker, B. Groswindhager, C. A. Boano, and K. Romer, “Towards secure and scalable UWB-based positioning systems,” 2020. doi: 10.1109/MASS50613.2020.00039.
- [79] A. Nessa, B. Adhikari, F. Hussain, and X. N. Fernando, “A Survey of Machine Learning for Indoor Positioning,” *IEEE Access*, 2020, doi: 10.1109/ACCESS.2020.3039271.
- [80] E. Baccarelli, M. Biagi, C. Pelizzoni, and N. Cordeschi, “Noncoherent synchronization of UWB-IR multiple-antenna multipath channels,” *IEEE Trans. Veh. Technol.*, 2009, doi: 10.1109/TVT.2008.2010047.
- [81] D. Knobloch, “Practical challenges of particle filter based UWB localization in vehicular environments,” 2017. doi: 10.1109/IPIN.2017.8115895.
- [82] L. Zwirello, T. Schipper, M. Harter, and T. Zwick, “UWB localization system for indoor applications: Concept, realization and analysis,” *J. Electr. Comput. Eng.*, 2012, doi: 10.1155/2012/849638.
- [83] “LOG-a-TEC by SensorLab | UWB Localization.” <https://log-a-tec.eu/uwb-ds.html> (accessed Jan. 07, 2024).
- [84] K. Bregar and M. Mohorcic, “Improving Indoor Localization Using Convolutional Neural Networks on Computationally Restricted Devices,” *IEEE Access*, vol. 6, pp. 17429–17441, Mar. 2018, doi: 10.1109/ACCESS.2018.2817800.
- [85] Y. J. Lin, P. H. Tseng, Y. C. Chan, J. He, and G. S. Wu, “A Super-Resolution-Assisted Fingerprinting Method Based on Channel Impulse Response Measurement for Indoor Positioning,” *IEEE Trans. Mob. Comput.*, 2019, doi: 10.1109/TMC.2018.2883092.
- [86] A. Grami, “Wireless Communications,” *Introd. to Digit. Commun.*, pp. 493–527, Jan. 2016, doi: 10.1016/B978-0-12-407682-2.00012-0.
- [87] M. S. Shanker, M. Y. Hu, and M. S. Hung, “Effect of data standardization on neural network training,” *Omega*, 1996, doi: 10.1016/0305-0483(96)00010-2.
- [88] F. Che *et al.*, “Feature-Based Generalized Gaussian Distribution Method for NLoS Detection in Ultra-Wideband (UWB) Indoor Positioning System,” *IEEE Sens. J.*, 2022, doi: 10.1109/JSEN.2022.3198680.
- [89] D. H. Kim and J. Y. Pyun, “NLOS Identification Based UWB and PDR Hybrid Positioning System,” *IEEE Access*, 2021, doi: 10.1109/ACCESS.2021.3098416.
- [90] Z. Ma and G. Mei, “Deep learning for geological hazards analysis: Data, models, applications, and opportunities,” *Earth-Science Reviews*, 2021. doi: 10.1016/j.earscirev.2021.103858.

## **Abstract:**

The prolonged stay of users in indoor environments for object tracking or person localization has turned navigation and guidance within these enclosed spaces into a challenging process. According to conducted research, humans spend approximately 70-90% of their life and work time in indoor environments; therefore, developing systems to provide suitable services to users in confined spaces is deemed essential. User and device localization has extensive applications in various sectors, including healthcare, industry, crisis management, building management, surveillance, and other diverse fields.

Various technologies exist in indoor positioning systems. In this thesis, Ultra-Wideband (UWB) technology has been investigated due to its high precision in indoor positioning. UWB technology has been recognized as having significant potential in constructing accurate Indoor Positioning Systems (IPS). However, indoor environments are filled with objects and individuals, which may cause signals to be reflected by obstacles. In comparison to Line of Sight (LOS) signals, the signal path delay in Non-Line of Sight (NLOS) signals introduces positive distance errors and consequently positioning inaccuracies.

To mitigate the impact of NLOS conditions on positioning, this thesis aims to initially use deep learning networks with channel impulse response data as input, without any prior knowledge of the environment, to accurately distinguish between LOS and NLOS conditions. The classification results are also compared with two other references using the same dataset. After identifying NLOS conditions, different regression networks are presented to estimate positions under two scenarios: 1) considering NLOS conditions, and 2) disregarding NLOS conditions.

Simulation results in the first part, the classification of NLOS/LOS signals, indicate that proposed Convolutional Neural Networks (CNN) and Inception networks outperform conventional neural network methods (advanced neural networks with different hidden layers and neurons) in accurately distinguishing between these two environments. Additionally, in the positioning section using regression algorithms, in both scenarios, the Support Vector Machine (SVM) machine learning network exhibits lower error in estimating tag positions compared to itself without considering NLOS conditions.

**Keywords:** Indoor Positioning, UWB Technology, NLOS Classification, Convolutional Neural Network, Inception Neural Network, Regression Algorithms, Position Estimation.



**Iran University of Science and Technology  
School of Electrical Engineering**

# **Increasing positioning accuracy of UWB technology using deep learning methods in NLOS/LOS environments**

**A Thesis Submitted in Partial Fulfillment of the Requirement for the Degree  
of Master of Science in Control**

**By:  
Mohammad Ali Ghaemifar**

**Supervisor:  
Dr. Saeed Ebadollahi**

**Advisor:  
Dr. -----**

**February 2024**